Compléments théoriques

Fondements informationnels d'un indicateur entropique
de stress systémique : ce que le papier principal laisse de côté

Annexe au papier « Sauts d'entropie et relaxation
de l'information sur les marchés financiers »

Octobre 2026

Résumé

Le papier principal est recentré sur un seul objet destiné aux banques centrales : le canal de dépendance $-\frac{1}{2}\log\det R$ d'un panel multi-marchés, sa décomposition exacte entre blocs et à l'intérieur des blocs, et l'audit en nats des scénarios de stress publiés. Ce document rassemble tout ce que ce recentrage retire du corps du texte, pour servir d'annexe ou être fourni sur demande. On y trouve le pont qui mène du maximum d'entropie en temps-volume au mouvement brownien géométrique, la décomposition de l'entropie en trois canaux et l'indice structurel $\mathcal{J} = D_{KL}(p \,\|\, \prod_i q_i)$, la dynamique de saut et diffusion (un théorème, deux postulats, la structure d'Ornstein–Uhlenbeck imposée par le théorème de Doob), le programme empirique H1–H8 avec son verdict face aux témoins calibrés, et la géométrie complète des scénarios en boule de Kullback–Leibler. Deux résultats sont nouveaux par rapport à la version arXiv v1. Le premier est une identité de décomposition par blocs du canal de dépendance, qui relie ce document au papier principal. Le second montre que le relèvement d'un scénario de portefeuille à la dimension pleine qui minimise la divergence ambiante coûte exactement le rayon η, et qu'il s'interprète actif par actif (choc porté par la covariance de chaque actif avec le portefeuille), alors que la dilatation uniforme par défaut coûte N fois plus en variance. Ce second point corrige une remarque de la v1.

Table des matières

Avant-propos **2**

Notations **3**

1 Du flux d'ordres au prix gaussien : le pont volume **4**
1.1 Le prix comme flux d'ordres accumulé 4
1.2 Maximum d'entropie en temps-volume 4
1.3 Des incréments gaussiens au mouvement brownien puis au MBG 5
1.4 La contraposée 6
1.5 Où le pont est faible 6

2 Les trois canaux de l'entropie **6**
2.1 Échelle et dépendance 6
2.2 Forme : le déficit d'entropie et sa composition 7
2.3 L'indice structurel 7

3 Dynamique de l'information : un théorème, deux postulats **7**
3.1 Les sauts vers le bas sont un théorème . . . 7
3.2 Deux postulats . . . 8
3.3 La dynamique qui en résulte . . . 10
3.4 Pourquoi queues épaisses, corrélation et sauts arrivent ensemble . . . 11

4 Le programme empirique H1–H8 et ce que les témoins en laissent **12**
4.1 Les huit hypothèses . . . 12
4.2 Pourquoi un témoin calibré est indispensable . . . 12
4.3 Le verdict . . . 13
4.4 Ce que le verdict dit de la théorie . . . 13

5 Géométrie des scénarios en boule de Kullback–Leibler **14**
5.1 Divergence entre deux gaussiennes . . . 14
5.2 La boule projetée et le taux de change . . . 14
5.3 Du portefeuille à la dimension pleine . . . 15
5.4 Composer une sévérité donnée . . . 16
5.5 Calibrer le rayon, et la limite de cette calibration . . . 16
5.6 Le test de résistance inversé . . . 16

6 Le pont vers le papier principal : décomposition par blocs **17**
6.1 L'identité . . . 17
6.2 Où se place le canal de dépendance dans l'indice structurel . . . 17
6.3 Trois propriétés utiles à l'indicateur . . . 18

7 Indicateurs de suivi et solvabilité en assurance **18**

8 Questions ouvertes **18**

A Unités, invariance, et ce qui est calculable **19**

B Entropie gaussienne : démonstration de l'équation (5) **19**

C Le déficit d'entropie : pourquoi $\mathcal{D} = h(q) - h(p)$ **20**

D L'indice structurel est une divergence **21**

E Information mutuelle : les deux propositions et un exemple **21**

Avant-propos : ce que contient ce document, et pourquoi

L'articulation avec le papier principal. L'évaluation d'octobre 2026 a conclu qu'un seul résultat de la version arXiv v1 franchit les deux témoins calibrés sur les deux panels : l'écart de régime du canal de dépendance $H^{dep} = \frac{1}{2}\log\det R$. La phase A l'a confirmé sous trois formes (brute, dévolatilisée à la Forbes–Rigobon, en rangs) et a montré que le ratio d'absorption de Kritzman et al. (2011), mesure de référence de la même famille, échoue au témoin par blocs. Le papier principal se reconstruit donc autour d'un « CISS entropique » au sens de Holló, Kremer & Lo Duca (2012) : canal de dépendance d'un panel multi-marchés, décomposition intra/inter-blocs, validation à la manière des banques centrales, et audit des scénarios publiés en nats.

Tout le reste sort du corps du texte. Ce n'est pas parce que c'est faux : les résultats mathématiques restent exacts. C'est parce que ces éléments ne sont pas nécessaires à l'indicateur, ou parce qu'ils ne survivent pas aux témoins et ne peuvent donc pas fonder un outil de surveillance. Les rassembler ici a deux usages. Un rapporteur qui demande d'où vient le canal de dépendance, et pourquoi c'est lui et pas l'indice structurel complet, trouve la réponse. Un lecteur qui veut reprendre la théorie de la dynamique de l'information trouve la chaîne entière, avec le statut exact de chaque maillon.

Statut de chaque énoncé. Le document distingue trois catégories et les signale au fil du texte : les *théorèmes* (exacts sous leurs hypothèses), les *postulats* (hypothèses économiques substantielles, testables), et les *constats empiriques* (avec le témoin qu'ils franchissent ou non). Le tableau 1 en donne la carte.

Élément	Statut	Verdict empirique	Section
Maximum d'entropie gaussien	théorème	—	1
Pont volume (MDH, brownien subordonné)	argument sous hypothèses	non testé ici	1
Décomposition en trois canaux	identité exacte	—	2
Indice structurel $\mathcal{J}$ comme divergence	identité exacte	étendue franchit les deux témoins	2
Sauts d'entropie vers le bas	théorème (en moyenne)	non estimable directement	3
Relaxation (P1)	postulat	demi-vie non identifiée	3
Contrainte unilatérale (P2)	postulat	non établie (H5)	3
Couplage queues–corrélation	conséquence	non identifié (H6)	3
Canal de dépendance sous stress	constat	**franchit les deux témoins**	4, 6
Boule KL, 1 nat $= \sqrt{2}\,\sigma$	théorème	—	5
Relèvement minimal (rang un)	théorème (nouveau)	—	5
Calibration du rayon sur le flux	règle	trop douce face à l'histoire	5
Décomposition par blocs	identité (nouvelle ici)	objet du papier principal	6

TABLE 1 – Carte des énoncés du document et de leur statut.

Origine des textes. Les sections 1 à 3 et les annexes A à E reprennent, avec des retouches de renvois, le texte de la version française de référence (`paper/main_fr.tex`). Les sections 4 à 8 sont rédigées pour ce document. Tous les chiffres cités proviennent du même code (`python -m src.run_empirical`, témoins à deux cents réplications, phase A) ; aucun n'a été recalculé pour cette annexe.

Notations

Deux mises en garde avant le tableau. D'abord, l'entropie différentielle h **dépend des unités** : $h(aX) = h(X) + \log|a|$, de sorte qu'exprimer les rendements en pourcentages plutôt qu'en décimales déplace h d'une constante. Les divergences ($D_{KL}(\cdot\,\|\,\cdot)$, I, $\mathcal{D}$, $\mathcal{J}$) sont au contraire invariantes par tout changement de variable inversible : c'est la raison d'être de l'indice structurel. Ensuite, K désigne un kurtosis et les lettres « KL » sont les initiales de Kullback et Leibler ; il n'y a aucun lien entre les deux.

Symbole	Signification	Nature
p_t	loi conditionnelle vraie des rendements en t	—
q_t	gaussienne de mêmes moyenne et covariance que p_t	—
$h(\cdot)$	entropie différentielle	nats, *dépend des unités*
$D_{KL}(p \,\|\, q)$	divergence de Kullback–Leibler	nats, invariante
$\mathcal{D}_t$	déficit d'entropie $= D_{KL}(p_t \,\|\, q_t) \geq 0$	nats, invariante
$\mathcal{D}_1(z)$	déficit d'un scalaire standardisé (néguentropie)	nats, invariante
H_t^{vol}	canal d'échelle $= \sum_i \log \sigma_{i,t}$	nats, *dépend des unités*
H_t^{dep}	canal de dépendance $= \frac{1}{2} \log\det R_t \leq 0$	nats, invariante
H_t^{cov}	$H_t^{vol} + H_t^{dep}$; la constante $\frac{N}{2}\log 2\pi e$ est omise	nats
$\mathcal{J}_t$	indice structurel $= \mathcal{D}_t - H_t^{dep} \geq 0$	nats, invariante
$I(X;Y)$	information mutuelle	nats, invariante
$I_t^{(h)}$	flux d'information $= D_{KL}(p_t \,\|\, p_{t-h})$	nats
S, K	asymétrie, kurtosis excédentaire	sans dimension
$\Sigma_t = D_t R_t D_t$	covariance, écarts types, corrélation	—
λ_k, N_t^{eff}	valeurs propres de R_t, nombre effectif de modes	$1 \leq N^{\text{eff}} \leq N$
κ, $\sigma_{\mathcal{J}}$	taux de relaxation et coefficient de diffusion de $\mathcal{J}$	—
η	rayon d'un scénario de stress	nats
N	nombre d'actifs	—

1 Du flux d'ordres au prix gaussien : le pont volume

1.1 Le prix comme flux d'ordres accumulé

Sur $[t, t+\Delta]$, soit M le nombre de transactions exécutées, la transaction k portant le volume signé $\epsilon_k v_k$ avec $\epsilon_k \in \{-1, +1\}$ le sens (à l'initiative de l'acheteur ou du vendeur) et $v_k > 0$ la taille. Notons $V = \sum_k v_k$ le volume total et $Q = \sum_k \epsilon_k v_k$ le flux d'ordres signé net.

Hypothèse 1 (Impact linéaire)**.** *Le log-prix répond linéairement au flux d'ordres signé net,* $\Delta X_{t,\Delta} = X_{t+\Delta} - X_t = \lambda\, Q$*, avec* $\lambda > 0$ *constant sur l'intervalle.*

C'est l'équilibre de Kyle (1985) : le teneur de marché, incapable de distinguer le flux informé du flux non informé, fixe une règle de prix linéaire et λ est l'inverse de la profondeur. C'est la définition du « prix comme fonction du volume échangé » dont a besoin le reste de la section, et c'est le maillon le plus faible de la chaîne ; la section 1.5 dit ce qui se passe quand il cède.

Hypothèse 2 (Signes échangeables et variance proportionnelle au volume)**.** *Conditionnellement à* V *et à l'information disponible en* t*, la croyance du marché sur* Q *n'est contrainte que par ses deux premiers moments, avec* $\mathbb{E}[Q \mid V] = m$ *et* $\mathrm{Var}(Q \mid V) = \varsigma^2 V$*.*

La forme de la variance est celle qu'on obtient lorsque les signes des transactions sont échangeables à corrélation bornée et que les tailles ont une moyenne stable : pour des signes indépendants, $\mathrm{Var}(Q) = \sum_k v_k^2 \approx \bar{v} V$. Le contenu économique est que *le volume, et non le temps, est la mesure naturelle de ce qui peut se produire.*

1.2 Maximum d'entropie en temps-volume

Proposition 1 (Maximum d'entropie sous contraintes de moments d'ordre un et deux)**.** *Parmi les distributions absolument continues sur* $\mathbb{R}^N$ *de moyenne* μ *et de covariance* $\Sigma \succ 0$*, la gaussienne* $\mathcal{N}(\mu, \Sigma)$ *maximise de façon unique l'entropie différentielle, et* $h^{\max}(\Sigma) = \frac{1}{2}\log\big((2\pi e)^N \det\Sigma\big)$*.*

Démonstration. Soit $q = \mathcal{N}(\mu, \Sigma)$ et soit p de mêmes deux premiers moments et d'entropie différentielle finie. Comme $\log q$ est exactement quadratique, son espérance ne dépend que de ces moments, donc $\mathbb{E}_p[\log q] = \mathbb{E}_q[\log q] = -h(q)$. La positivité de l'entropie relative donne $0 \le D_{KL}(p \,\|\, q) = -h(p) + h(q)$, d'où $h(p) \le h(q)$, avec égalité si et seulement si $p = q$ presque partout. L'argument n'exige aucune différentiabilité de p ni l'existence préalable d'un maximiseur. □

La voie variationnelle — un lagrangien sur les contraintes de normalisation, de moyenne et de covariance, dont la condition du premier ordre rend $\log p$ quadratique — explique *pourquoi* le maximiseur est gaussien, mais c'est l'argument par la divergence qui établit l'optimalité et l'unicité.

En appliquant la proposition 1 à l'hypothèse 2 en dimension un, puis en transportant par l'hypothèse 1 :

$$\Delta X_{t,\Delta} \mid V \;\sim\; \mathcal{N}\big(\lambda m,\; \lambda^2 \varsigma^2 V\big)\,. \tag{1}$$

L'équation (1) est le pont. Trois points méritent d'être soulignés.

D'abord, *la variable de conditionnement est le volume, pas le temps.* Le maximum d'entropie ne délivre pas une variance ; il délivre la distribution la moins engageante étant donné une variance. L'hypothèse 2 fournit cette variance à partir d'un observable, et cet observable est le volume échangé. L'équation (1) est l'hypothèse de mélange de distributions de Clark (1973) et Tauchen & Pitts (1983), obtenue ici comme un énoncé de maximum d'entropie plutôt que posée ; Ané & Geman (2000) montrent empiriquement que les rendements mesurés en temps-transaction sont proches du gaussien alors que les rendements en temps calendaire ne le sont pas, ce qui est la prédiction de (1).

Ensuite, *la gaussianité est conditionnelle.* Inconditionnellement, ΔX est un mélange d'échelle de lois normales sur le volume aléatoire V, donc leptokurtique même si (1) est exacte. C'est le mécanisme de subordination de Mandelbrot & Taylor (1967), et cela signifie que les queues épaisses ne constituent pas à elles seules une preuve contre le maximum d'entropie.

Enfin, l'extension multivariée est immédiate : avec N actifs, $\Delta\mathbf{X} \mid V \sim \mathcal{N}(\boldsymbol{\mu} V, \Sigma V)$, et la proposition 1 s'applique telle quelle.

1.3 Des incréments gaussiens au mouvement brownien puis au MBG

Soit $\theta_t = \int_0^t v_s \, ds$ l'horloge de volume cumulé. L'équation (1) donne la loi d'un incrément ; un processus demande davantage.

Hypothèse 3 (Cohérence temporelle)**.** *Dans l'horloge de volume, les incréments sur des intervalles disjoints sont indépendants, les trajectoires sont continues, et la covariance d'un incrément est proportionnelle au volume écoulé.*

Sous l'hypothèse 3 à coefficients constants, il existe une matrice B telle que $BB^\top = \Sigma$ et $X_\theta = X_0 + \mu\theta + BW_\theta$ en temps-volume, donc en temps calendaire

$$X_t = X_0 + \mu\,\theta_t + B\,W_{\theta_t}, \tag{2}$$

un mouvement brownien *subordonné* à l'horloge de volume. Si l'intensité de négociation est constante, $\theta_t = \bar{v}\,t$ et (2) est un mouvement brownien ordinaire en temps calendaire ; en exponentiant et en appliquant Itô,

$$\frac{dS_{i,t}}{S_{i,t}} = \big(a_{i,t} + \tfrac{1}{2}\sigma_{i,t}^2\big)\,dt + \sigma_{i,t}\,dW_{i,t}, \tag{3}$$

de sorte que la dérive du prix n'est pas celle du log-prix — la même correction du second ordre qui reparaîtra à la section 2 lorsqu'on différenciera $\log\det R_t$.

Il vaut la peine d'être précis sur ce que fait l'hypothèse 3. Par le théorème de Monroe (1978), *toute* martingale locale continue est un mouvement brownien changé de temps : la subordination seule n'a donc aucun contenu empirique. Le contenu est dans l'horloge : (1) dit que la bonne horloge est le volume, et l'hypothèse 3 dit que le marché est sans mémoire dans cette horloge. C'est le maximum d'entropie qui sélectionne le mouvement brownien dans la classe qu'autorise le théorème de Monroe.

1.4 La contraposée

La proposition 1 se lit dans les deux sens. Notons q_t la gaussienne de mêmes moyenne et covariance conditionnelles que p_t. Alors

$$\mathcal{D}_t \;\equiv\; h(q_t) - h(p_t) \;=\; D_{KL}(p_t \,\|\, q_t) \;\geq\; 0, \tag{4}$$

avec égalité si et seulement si p_t est gaussienne. Donc : *les prix sont non gaussiens exactement dans la mesure où leur distribution conditionnelle n'est pas d'entropie maximale*, et $\mathcal{D}_t$ mesure cette mesure. Dans le langage de la section 1, un $\mathcal{D}_t$ positif signifie que des contraintes au-delà des deux premiers moments sont actives — que quelqu'un sait quelque chose que le moment d'ordre deux n'encode pas.

Deux sources produisent un déficit positif, et les séparer importe. Une horloge de volume aléatoire produit un mélange d'échelle, symétrique et leptokurtique. Une information directionnelle contraignante produit de l'asymétrie. La section 2 scinde $\mathcal{D}$ exactement selon cette ligne.

1.5 Où le pont est faible

L'hypothèse 1 est linéaire ; l'impact empirique d'un métaordre est plus proche d'une racine carrée de la taille, ce qui rend concave l'application du flux au prix et la distribution de rendements induite moins épaisse en queue que le flux. L'hypothèse 2 traite les signes comme échangeables ; le flux d'ordres est en réalité fortement autocorrélé, ce qui gonfle $\mathrm{Var}(Q)$ au-dessus de $\varsigma^2 V$ et fait de l'horloge de volume un substitut imparfait de la variance. Aucune de ces défaillances ne change la *forme* de l'argument — le maximum d'entropie sous budget de variance reste gaussien — mais toutes deux signifient que l'horloge de volume est une approximation de l'horloge d'information plutôt que cette horloge même. Nous utilisons le raisonnement en temps-volume pour motiver le cadre et l'estimation en temps calendaire dans tout le travail empirique, de sorte qu'aucun résultat ci-dessous ne dépend de l'exactitude de (1).

2 Les trois canaux de l'entropie

2.1 Échelle et dépendance

Écrivons $\Sigma_t = D_t R_t D_t$ avec $D_t = \mathrm{diag}(\sigma_{1,t}, \ldots, \sigma_{N,t})$. Alors $\det \Sigma_t = \left(\prod_i \sigma_{i,t}^2\right) \det R_t$ et

$$h(q_t) \;=\; \underbrace{\tfrac{N}{2}\log(2\pi e)}_{\text{constante}} \;+\; \underbrace{\sum_i \log \sigma_{i,t}}_{H_t^{vol}} \;+\; \underbrace{\tfrac{1}{2}\log\det R_t}_{H_t^{dep}}. \tag{5}$$

Par l'inégalité de Hadamard, $H_t^{dep} \leq 0$, avec égalité si et seulement si $R_t = I$: *la corrélation détruit toujours de l'entropie*, et $-H_t^{dep}$ est précisément la multi-information gaussienne (corrélation totale)

du vecteur de rendements. Une lecture utile de la même quantité est spectrale : avec λ_k les valeurs propres de R_t et $\tilde{\lambda}_k = \lambda_k / N$, le nombre de participation $N_t^{\text{eff}} = \exp\Big(-\sum_k \tilde{\lambda}_k \log \tilde{\lambda}_k\Big)$ est le nombre effectif de modes de risque indépendants ; il vaut N pour $R = I$ et tend vers 1 lorsqu'un unique mode collectif absorbe la variance.

L'équation (5) est le plafond, pas l'entropie. C'est ce qu'implique la seule matrice de covariance, et la proposition 1 dit que la vérité se situe en dessous.

2.2 Forme : le déficit d'entropie et sa composition

En soustrayant (4) de (5) on obtient la décomposition de l'article, trois canaux et une constante :

$$h(p_t) \;=\; \tfrac{N}{2}\log(2\pi e) \;+\; \underbrace{H_t^{vol}}_{\text{échelle}} \;+\; \underbrace{H_t^{dep}}_{\text{dépendance}} \;-\; \underbrace{\mathcal{D}_t}_{\text{forme}}. \tag{6}$$

Le canal de forme, ce sont l'asymétrie et les queues épaisses, et le développement d'Edgeworth le dit explicitement : pour une variable standardisée d'asymétrie S et de kurtosis excédentaire K au voisinage de la gaussianité,

$$J \;\approx\; \frac{S^2}{12} + \frac{K^2}{48}. \tag{7}$$

L'équation (7) répond à la question « où un saut d'entropie serait-il visible ? » : dans les moments d'ordre trois et quatre, de manière additive, avec un canal d'asymétrie et un canal de queue. Elle est aussi la source du problème de signe que la section 3 doit résoudre, car S y entre au carré — *la néguentropie ne distingue pas un krach d'une envolée.* Comme estimateur, (7) est inutilisable sur des rendements quotidiens ; la section 4 documente à quel point et ce que nous utilisons à la place.

2.3 L'indice structurel

Le canal d'échelle est une nuisance pour notre propos : il domine numériquement le niveau de (6), il bouge avec la volatilité, et un changement d'unités le modifie. Les deux autres canaux sont sans échelle. En les combinant, et en utilisant la règle de chaînage exacte $D_{KL}(p \,\|\, \prod_i q_i) = \sum_i D_{KL}(p_i \,\|\, q_i) + I(x)$ où I est la multi-information :

Définition 1 (Indice d'information structurelle)**.**

$$\mathcal{J}_t \;\equiv\; \mathcal{D}_t \;-\; H_t^{dep} \;=\; D_{KL}(p_t \,\|\, \textstyle\prod_i q_{i,t}) \;\geq\; 0, \tag{8}$$

la divergence de la loi jointe conditionnelle des rendements à un produit de marginales gaussiennes de mêmes échelles.

$\mathcal{J}$ est nul si et seulement si les rendements sont indépendants et gaussiens ; il s'élève quand les actifs se couplent, quand les marginales s'épaississent ou quand elles s'asymétrisent. Il est mesuré en nats, il est invariant au niveau de volatilité, et il est additif sur ses deux canaux, de sorte qu'on peut toujours demander quelle part d'un mouvement vient de la dépendance et quelle part de la forme. C'est la variable d'état de la section 3.

3 Dynamique de l'information : un théorème, deux postulats

3.1 Les sauts vers le bas sont un théorème

Deux énoncés distincts sous-tendent la moitié descendante de la dynamique postulée. Les confondre est une erreur facile, et les versions antérieures de ce travail la commettaient ; nous les séparons donc explicitement.

Rappelons d'abord la définition de l'*information mutuelle* entre le vecteur de rendements X et un signal Y :

$$I(X;Y) \;=\; D_{KL}(p_{XY} \,\|\, p_X \otimes p_Y) \;=\; \iint p(x,y)\,\log \frac{p(x,y)}{p(x)p(y)}\,dx\,dy, \tag{9}$$

c'est-à-dire la divergence de la loi jointe au produit des marginales : de combien la loi jointe s'écarte de l'indépendance. Elle est positive, symétrique, nulle si et seulement si $X \perp Y$, et — contrairement à h — invariante par reparamétrisation inversible. Pour un couple gaussien scalaire de corrélation ρ, $I = -\frac{1}{2}\log(1-\rho^2)$.

Proposition 2 (Chute de l'entropie conditionnelle moyenne)**.** *Soit X le vecteur de rendements et Y un signal. Alors*

$$\mathbb{E}_Y[h(X \mid Y)] \;=\; h(X) - I(X;Y) \;\le\; h(X),$$

avec égalité si et seulement si $X \perp Y$.

Proposition 3 (Monotonie du plafond sous contrainte)**.** *Soient $\mathcal{C} \subseteq \mathcal{C}'$ deux ensembles de contraintes et $\mathcal{Q}(\cdot)$ l'ensemble des lois qui les satisfont. Alors $\mathcal{Q}(\mathcal{C}') \subseteq \mathcal{Q}(\mathcal{C})$ et donc*

$$\sup_{p \,\in\, \mathcal{Q}(\mathcal{C}')} h(p) \;\le\; \sup_{p \,\in\, \mathcal{Q}(\mathcal{C})} h(p).$$

Les deux résultats sont classiques (Cover & Thomas, 2006) et ne sont pas équivalents ; la démonstration détaillée et un exemple gaussien chiffré figurent en annexe E. Leurs portées diffèrent sur deux axes.

La proposition 2 *quantifie* la baisse — exactement $I(X;Y)$ nats — mais seulement *en moyenne* sur les réalisations du signal. Pour un y particulier, $h(X \mid Y = y)$ peut excéder $h(X)$: un signal suffisamment déroutant laisse le marché plus incertain qu'avant. Il faut donc s'attendre à une composante de saut principalement, et non exclusivement, unilatérale — ce que trouve la section 4.

La proposition 3 vaut au contraire *pour chaque réalisation*, mais porte sur le *plafond* de maximum d'entropie et non sur l'entropie réelle, et elle ne quantifie rien : elle dit que le plafond ne peut pas monter, pas de combien il descend.

Ce que les deux disent ensemble, et qui motive tout ce qui suit : la chute est *discontinue*, car le signal arrive en un point du temps, et sa taille espérée en nats est le contenu informationnel de la nouvelle — une amplitude mesurée sur une échelle qui ne dépend ni de l'actif, ni de la devise, ni des unités.

Une réserve d'honnêteté. Aucune de ces deux propositions n'est utilisée pour calculer quoi que ce soit dans la partie empirique. Nous mesurons $\mathcal{J}$, et non $h(X) - \mathbb{E}_Y[h(X \mid Y)]$: estimer une entropie différentielle en dimension 20 sur une fenêtre de 252 jours est hors de portée (annexe A). Le lien entre le théorème et les statistiques rapportées plus loin est un raisonnement, pas une identité estimée, et le lecteur doit le tenir pour tel.

3.2 Deux postulats

Postulat 1 (Relaxation)**.** En l'absence d'information nouvelle, l'indice structurel décroît vers un niveau de long terme à taux constant : $d\mathcal{J}_t = -\kappa\left(\mathcal{J}_t - \bar{\mathcal{J}}\right)dt + \sigma_{\mathcal{J}}\,dW_t$ avec $\kappa > 0$.

L'économie derrière P1 est qu'une contrainte s'évente. La nouvelle est intégrée aux prix, le désaccord se reforme, les positions se dispersent, et la coupe transversale recouvre la liberté que le choc lui avait retirée. Rien dans la théorie de l'information ne délivre cela ; c'est l'hypothèse substantielle de l'article, et κ est l'objet à estimer.

Pourquoi un processus d'Ornstein–Uhlenbeck et pas autre chose ? Le choix n'est pas un choix de commodité : il est *forcé* dès qu'on impose trois exigences minimales, et il est le seul à les satisfaire toutes les trois.

1. *Markov.* L'avenir de $\mathcal{J}$ ne dépend du passé qu'à travers son niveau présent. C'est l'exigence de parcimonie : ne postuler aucune mémoire au-delà de ce que l'état courant contient déjà.
2. *Stationnaire.* $\mathcal{J}$ possède un niveau de long terme et une variance finis. Sans cela l'indice dérive, il n'est pas une variable d'état, et les comparaisons de régime de la section 4 n'ont pas de sens.
3. *Bruit gaussien.* Entre deux arrivées d'information, on ne prétend rien savoir du bruit au-delà de sa variance — c'est le principe de maximum d'entropie appliqué au bruit lui-même, exactement comme il l'a été aux rendements en section 1.

Le théorème de Doob (1942) énonce que **le processus d'Ornstein–Uhlenbeck est l'unique processus à la fois markovien, gaussien et stationnaire** en temps continu. Les trois exigences ne laissent donc aucune latitude sur la partie diffusive : elle est déterminée. Le terme de saut, lui, est ajouté précisément pour *briser* la gaussianité là où le cadre affirme qu'elle ne tient pas, c'est-à-dire aux arrivées d'information. La structure de (11) est ainsi un squelette imposé plus une composante délibérément non gaussienne, ce qui est exactement la classe introduite par Barndorff-Nielsen & Shephard (2001).

Ce qui, en revanche, reste arbitraire. Trois choses, qu'il faut énoncer plutôt que laisser croire qu'elles découlent du théorème. Le taux κ est supposé *constant* : rien n'interdit qu'une crise soit absorbée plus vite, ou plus lentement, qu'une nouvelle ordinaire, et les données employées ici ne permettent pas de trancher. Le rappel est *linéaire* en l'écart au niveau de long terme, alors qu'un rappel accéléré loin de la moyenne serait tout aussi plausible. Enfin, $\mathcal{J}$ est positif par construction alors qu'un Ornstein–Uhlenbeck muni d'un terme brownien peut devenir négatif : la spécification de Barndorff-Nielsen & Shephard (2001) évite cet écueil en supprimant le terme brownien et en pilotant le processus par un subordinateur à sauts positifs, ce qui garantit une loi stationnaire portée par $\mathbb{R}^+$. Empiriquement la question ne se pose pas — $\mathcal{J}$ reste compris entre 2,17 et 21,13 nats sur le panel principal et entre 0,42 et 1,69 sur le panel de réplication, donc très loin de la frontière — mais formellement il faudrait soit supprimer $\sigma_{\mathcal{J}}$, soit écrire le processus sur $\log \mathcal{J}$.

Le postulat n'est enfin pas anodin sur le plan de la mesure : un estimateur doté de mémoire fabriquera une décroissance même en l'absence de toute relaxation économique, aussi la section 4 mesure-t-elle la décroissance qu'un monde sans mémoire produirait déjà.

Postulat 2 (Asymétrie de la contrainte)**.** La contrainte qu'impose l'information est unilatérale dans la direction des pertes, de sorte qu'un saut d'entropie s'accompagne d'une asymétrie négative du facteur de marché.

Pourquoi ce postulat est logiquement nécessaire. L'indice $\mathcal{J}$ est une fonction *paire* de l'asymétrie : changer le signe de l'asymétrie ne change pas sa valeur. La raison est immédiate. Le canal de forme est $\mathcal{D}_1(z) = D_{KL}(p_z \,\|\, \varphi)$, et la loi normale φ est symétrique ; donc si l'on remplace z par $-z$, la loi de référence est inchangée et la divergence l'est aussi :

$$\mathcal{D}_1(-z) = \mathcal{D}_1(z), \qquad \text{et par conséquent} \qquad \mathcal{J}(-x) = \mathcal{J}(x). \tag{10}$$

Le développement d'Edgeworth (7) le rend visible à l'œil : l'asymétrie S y entre au carré.

La conséquence est structurelle et non anecdotique. **Une distribution à longue queue à gauche — un krach — et son image en miroir à longue queue à droite — une envolée**

— **ont exactement le même $\mathcal{J}$.** L'indice mesure la *taille* de l'information, jamais son sens. Aucun raffinement de l'estimateur n'y changera quoi que ce soit : c'est une propriété de l'objet mesuré. Si l'article veut dire quoi que ce soit sur la direction, il doit donc ajouter un ingrédient extérieur. P2 est cet ingrédient, et c'est le plus petit possible : une seule affirmation, sur le signe, ajoutée à un cadre qui par construction n'en produit aucune.

Sur quoi il s'appuie. Non pas sur un mécanisme que nous affirmerions, mais sur une régularité empirique établie : l'*effet de levier* au sens de Black (1976), c'est-à-dire le fait que les rendements négatifs sont suivis de hausses de volatilité plus fortes que les rendements positifs de même amplitude. C'est l'un des faits stylisés les plus robustes de la finance empirique (Christie, 1982; Engle & Ng, 1993; Nelson, 1991). Traduit dans le langage de cet article : à quantité d'information égale, la réponse du marché est plus ample vers le bas que vers le haut, donc un saut de $\mathcal{J}$ arrive accompagné d'une asymétrie de marché négative.

Nous nous abstenons délibérément de choisir entre les explications causales concurrentes de cet effet — levier financier à proprement parler, rétroaction de la volatilité, ou retrait asymétrique de la liquidité du côté vendeur. Le postulat ne dépend d'aucune d'entre elles : il n'affirme que l'asymétrie, pas sa cause. Il est testable séparément (H5) et réfutable séparément, et la section 4 conclut d'ailleurs qu'il n'est pas établi.

3.3 La dynamique qui en résulte

La proposition 2 jointe à P1 donne un processus d'Ornstein–Uhlenbeck non gaussien à sauts unilatéraux, de la classe introduite par Barndorff-Nielsen & Shephard (2001) pour la volatilité stochastique :

$$d\mathcal{J}_t \;=\; -\kappa\left(\mathcal{J}_t - \bar{\mathcal{J}}\right) dt \;+\; \sigma_{\mathcal{J}}\, dW_t \;+\; \int_{z>0} z\, \mathcal{P}(dt, dz), \tag{11}$$

Le terme intégral demande d'être lu avec soin, car sa notation est compacte.

Ce que $\mathcal{P}$ n'est pas. Ce n'est ni une loi gaussienne, ni une fonction. La lettre $\mathcal{N}$ est réservée dans cet article à la loi normale, et la mesure de saut porte donc un symbole distinct.

Ce que $\mathcal{P}$ est. Une *mesure aléatoire de comptage*, dite mesure aléatoire de Poisson. On peut se la représenter comme un semis aléatoire de points dans le plan (date, taille) : chaque point est un événement informationnel, son abscisse est la date à laquelle il survient et son ordonnée la taille du saut qu'il provoque. Formellement, $\mathcal{P}(dt, dz)$ vaut 1 s'il existe un saut dans l'intervalle de temps $[t, t+dt)$ dont la taille tombe dans $[z, z+dz)$, et 0 sinon. L'intégrale $\int_{z>0} z\,\mathcal{P}(dt, dz)$ se lit alors simplement : « s'il y a un saut à la date t, ajouter sa taille z à $\mathcal{J}$; sinon n'ajouter rien ». C'est une écriture condensée de $\sum_j z_j$, la somme des sauts survenus.

Ce qui la caractérise. Deux ingrédients, réunis dans sa *mesure d'intensité* $\nu(dz)\,dt$, qui est le nombre espéré de sauts de taille comprise entre z et $z+dz$ pendant dt : d'une part une *fréquence d'arrivée* $\lambda = \nu(\mathbb{R}^+)$, en nombre de sauts par unité de temps, d'autre part une *loi des tailles* $\nu(dz)/\lambda$. Sur le panel principal, la section 4 estime $\lambda \approx 5$ sauts par an, une taille moyenne de 0,62 nat et un maximum de 3,21 nats.

Ce qu'est z. La taille d'un saut individuel, exprimée en nats. Conceptuellement, c'est l'information mutuelle de la nouvelle qui l'a provoqué, au sens de la proposition 2. Opérationnellement, c'est la variation de $\mathcal{J}$ détectée par le filtre à quatre sigmas de la section 4. Les deux ne coïncident qu'approximativement, et le papier ne prétend pas les identifier.

Pourquoi l'intégrale ne porte que sur $z > 0$. Parce que $\mathcal{J}$ mesure un *déficit* d'entropie et que, par la proposition 2, l'information ne peut qu'accroître ce déficit en espérance. Dans ce cadre, rien ne crée d'*augmentation soudaine* d'entropie : l'entropie n'est restituée que par la relaxation lente du premier terme, jamais par un saut. D'où des sauts unilatéraux.

Deux réserves, toutefois. La proposition 2 est un énoncé *en moyenne* : une réalisation particulièrement déroutante peut accroître l'entropie, donc une spécification fidèle autoriserait une petite probabilité de sauts négatifs plutôt que de les interdire. Et la mesure de Poisson suppose des arrivées indépendantes, alors que l'étude d'événement de la section 4 montre un regroupement net des sauts ; un processus auto-excitant de type Hawkes serait plus fidèle.

Notons enfin que le coefficient de diffusion est noté $\sigma_{\mathcal{J}}$ et non η, cette dernière lettre étant réservée au rayon des scénarios de stress (section 5). Lu sur l'entropie elle-même plutôt que sur $\mathcal{J}$, le signe s'inverse : l'entropie chute par sauts et remonte par diffusion. Les prédictions observables sont nettes, et ce sont elles que teste la section 4 : la loi de $\Delta\mathcal{J}$ est asymétrique à droite ; les grands mouvements sont à la hausse et les petits à la baisse ; et après un saut positif l'indice décroît avec une demi-vie $\ln 2/\kappa$.

3.4 Pourquoi queues épaisses, corrélation et sauts arrivent ensemble

Le cadre produit une prédiction qu'aucun modèle de volatilité ni de corrélation ne produit seul. Elle se déduit en quatre pas, sans vocabulaire technique.

1. Une nouvelle importante concerne *tous* les actifs à la fois : c'est la même information qui contraint chacun d'eux.
2. Si la nouvelle est mauvaise, tous les actifs baissent donc *le même jour*.
3. Or ce jour-là apparaît aussi, pris isolément, dans l'historique de chaque actif : c'est pour lui une journée de perte inhabituellement grande.
4. Accumuler de telles journées déforme la distribution des rendements de chaque actif : le côté des pertes s'allonge et s'alourdit davantage que le côté des gains.

Le pas 2 est ce que mesure le canal de dépendance : les actifs bougent ensemble, la corrélation mesurée monte, $-H^{dep}$ monte. Le pas 4 est ce que mesure le canal de forme : des pertes extrêmes plus nombreuses et plus grandes que les gains extrêmes, c'est-à-dire un kurtosis plus élevé et une asymétrie négative, donc $\mathcal{D}$ monte. Les deux canaux montent ensemble parce qu'ils décrivent le même jour vu de deux endroits différents — la coupe transversale pour l'un, la distribution de chaque actif pour l'autre.

En marché calme, les mouvements marquants sont propres à chaque actif : ils n'alignent pas la coupe transversale et n'ont donc aucune raison de faire monter les deux canaux en même temps.

La forme testable est un *couplage dépendant du régime* : la corrélation entre $-\Delta H^{dep}$ et $\Delta\mathcal{D}$ devrait être proche de zéro en marché calme et fortement positive sous stress. C'est H6, et c'est là que se trouve la réponse de l'article à la question « le lien entre queues épaisses, corrélation et sauts d'entropie exige-t-il un postulat supplémentaire ? » : non. Étant donné la proposition 2, le couplage découle du caractère commun de la nouvelle. Seul le *signe* exige P2.

4 Le programme empirique H1–H8 et ce que les témoins en laissent

Cette section résume, sans les reproduire, les estimateurs et les tests de la version arXiv v1. Elle sert à une chose : expliquer pourquoi, de toute la théorie des sections 1 à 3, seul le canal de dépendance passe dans le papier principal.

4.1 Les huit hypothèses

H1 (signature de régime). Sous stress, H^{dep} baisse, $\mathcal{D}$ monte, et donc $\mathcal{J}$ monte.

H2 (compensation partielle). $\Delta H_t^{dep} = -\beta\,\Delta H_t^{vol} + u_t$ avec $\beta > 0$, et $\beta_{\text{stress}} > \beta_{\text{calme}}$.

H3 (asymétrie des sauts). Les variations de $\mathcal{J}$ sont unilatérales, au-delà de ce que produit le même estimateur sur des données sans structure temporelle.

H4 (relaxation). $\mathcal{J}$ revient à la moyenne avec une demi-vie plus longue que la mémoire de l'estimateur.

H5 (signature d'asymétrie). Les sauts positifs de $\mathcal{J}$ coïncident avec une asymétrie négative du facteur de marché (postulat P2).

H6 (couplage des canaux). Dépendance et forme sont faiblement couplées en marché calme, fortement sous stress.

H7 (pouvoir prédictif). L'entropie d'aujourd'hui améliore, hors échantillon, la prévision du risque à 21 jours par rapport à la volatilité.

H8 (composition du budget de crise). Regroupés en épisodes, les sauts ont plus souvent le canal de dépendance pour contributeur dominant qu'un rééchantillonnage sans mémoire.

Estimation, en une phrase. Fenêtres glissantes de 252 jours, covariance rétrécie à la Ledoit & Wolf (2004), déficit marginal par l'approximation de Hyvärinen (1998) plutôt que par le développement d'Edgeworth (7) (inutilisable sur des rendements quotidiens), régime de stress défini par un seuil de volatilité calculé sur le passé seulement, sauts détectés par un filtre à quatre sigmas sur $\Delta\mathcal{J}$.

4.2 Pourquoi un témoin calibré est indispensable

Le point théorique qui gouverne toute la lecture des résultats est le suivant. $\mathcal{J}$ est une fonctionnelle *convexe et positive* des moments d'ordre deux à quatre estimés sur une fenêtre. Quand une observation à queue épaisse entre dans la fenêtre, les moments estimés sautent, et la fonctionnelle convexe saute *vers le haut* quel que soit le signe de l'observation. Quand l'observation vieillit (pondération exponentielle) ou sort de la fenêtre, la fonctionnelle redescend graduellement. L'appareil de mesure fabrique donc, à lui seul, la dent de scie que prédisent la proposition 2 et le postulat P1. Une simulation gaussienne i.i.d., sans aucun événement, produit déjà une demi-vie apparente de 35 jours et 37 sauts positifs contre aucun négatif au filtre à quatre sigmas.

D'où deux témoins, construits en rééchantillonnant la matrice de rendements observée et en faisant tourner la chaîne identique deux cents fois : le témoin *i.i.d.* (lignes tirées indépendamment, queues marginales et dépendance transversale conservées, toute chronologie détruite) et le témoin *par blocs* de 21 jours (qui conserve en outre le regroupement de volatilité). Une statistique qui franchit les deux est une preuve ; une statistique qui en franchit un seul n'est pas identifiée.

	Statistique	Données	i.i.d.	blocs-21	Verdict
H1	écart de régime H^{dep}	−0,99	−0,21	−0,51	**franchit les deux**
H1	écart de régime $\mathcal{J}$	1,93	2,14	1,97	échoue aux deux
H1	écart de régime $\mathcal{D}$	0,27	1,25	0,65	à contre-sens
H2	β (stress)	0,20	0,05	0,11	échoue aux deux
H3	sauts positifs	158	148,5	133,2	blocs seulement
H3	asymétrie de $\Delta\mathcal{J}$	12,26	14,80	12,97	à contre-sens
H4	demi-vie (jours)	120,8	92,1	162,8	entre les deux
H4	étendue de $\mathcal{J}$	18,95	10,05	13,77	**franchit les deux**
H5	corr($\Delta\mathcal{J}, \Delta S_{mkt}$)	−0,24	−0,04	−0,07	échoue aux deux
H6	écart de couplage	0,59	0,77	0,67	à contre-sens
H7	gain hors échantillon	aucun sur deux panels			rejetée
H8	part d'épisodes à dominante dépendance	46 %	19–33 %	n.i.	i.i.d. seulement

TABLE 2 – Verdicts face aux témoins (moyennes de deux cents réplications), panel principal de vingt titres du S&P 500, 1990–2022. Source : `paper/tables/tab_placebo_sp500.tex` et sections H7–H8 de la v1. n.i. : non identifié, à toute longueur de bloc testée entre 5 et 126 jours.

4.3 Le verdict

Deux statistiques franchissent les deux témoins sur le panel principal, et une seule se reproduit sur les 48 portefeuilles sectoriels de Kenneth French : l'écart de régime du canal de dépendance (−3,65 nats contre −0,56 et −2,46). La phase A l'a ensuite durci : il tient en version dévolatilisée (Forbes–Rigobon) et en version en rangs, cette dernière étant la plus forte face au témoin par blocs ($p = 0{,}03$ sur le S&P 500, 0,01 sur les secteurs), alors que le ratio d'absorption de Kritzman et al. (2011) échoue au témoin par blocs sur les deux panels.

4.4 Ce que le verdict dit de la théorie

Il faut séparer ce que le verdict touche et ce qu'il ne touche pas.

Ce qui n'est pas touché. Les énoncés des sections 1 et 2 sont des identités et des théorèmes. La proposition 2 aussi. Aucun résultat empirique ne peut les réfuter ; il peut seulement montrer que les estimateurs disponibles ne permettent pas de les voir à l'œuvre.

Ce qui est touché. Les deux postulats. P1 n'est soutenu que par l'amplitude (l'étendue de $\mathcal{J}$), pas par un taux de relaxation : la demi-vie se situe entre les deux témoins et son niveau dépend du témoin choisi. P2 n'est pas établi (H5). Le couplage des canaux (H6), que la section 3 dérivait du caractère commun de la nouvelle, est reproduit et même dépassé par des données rééchantillonnées.

Pourquoi le canal de dépendance survit. Une explication vraisemblable, cohérente avec la phase A, tient à la forme de l'estimateur. $\frac{1}{2}\log\det R = \frac{1}{2}\sum_k \log\lambda_k$ pèse tout le spectre de la matrice de corrélation, y compris les petites valeurs propres, qui s'effondrent quand la coupe transversale se couple sur quelques modes collectifs. Un seul gros rendement isolé déplace peu ces petites valeurs propres. À l'inverse, le canal de forme $\mathcal{D}$ réagit fortement à une seule observation extrême, ce qui est exactement la signature que reproduit le témoin. Les mesures de concentration (ratio d'absorption, part de la première valeur propre) ne regardent que le haut du spectre, où le témoin par blocs les rattrape.

Conséquence pour le papier principal. L'indicateur retient le seul canal identifié, en abandonnant $\mathcal{D}$ et donc $\mathcal{J}$. La théorie des sections 2 et 3 reste la justification de *pourquoi* ce canal mesure une information partagée (la multi-information gaussienne, équation (5) et annexe B), mais la dynamique postulée n'est pas utilisée.

5 Géométrie des scénarios en boule de Kullback–Leibler

Le papier principal retient l'usage le plus simple de cette géométrie : tarifer en nats un scénario publié, ce qui pour un pur déplacement de moyenne revient à la moitié du carré de la distance de Mahalanobis. Cette section donne la construction complète dont cet usage est un cas particulier, avec les démonstrations que la v1 se contentait d'énoncer, et un résultat nouveau sur le relèvement d'un scénario de portefeuille à la dimension pleine.

5.1 Divergence entre deux gaussiennes

Proposition 4 (Forme fermée)**.** *Pour $p_1 = \mathcal{N}(\mu_1, \Sigma_1)$ et $p_0 = \mathcal{N}(\mu_0, \Sigma_0)$ sur $\mathbb{R}^N$, avec $\delta = \mu_1 - \mu_0$,*

$$D_{KL}(p_1 \,\|\, p_0) = \tfrac{1}{2}\Big[\underbrace{\delta^\top \Sigma_0^{-1} \delta}_{\text{déplacement}} + \underbrace{\operatorname{tr}(\Sigma_0^{-1}\Sigma_1) - N - \log\det(\Sigma_0^{-1}\Sigma_1)}_{\text{déformation}} \Big]. \tag{12}$$

Démonstration. $D_{KL}(p_1 \,\|\, p_0) = \mathbb{E}_{p_1}[\log p_1 - \log p_0]$. Les deux logarithmes sont quadratiques ; l'astuce de la trace de l'annexe B donne $\mathbb{E}_{p_1}[(X-\mu_1)^\top \Sigma_1^{-1}(X-\mu_1)] = N$ et $\mathbb{E}_{p_1}[(X-\mu_0)^\top \Sigma_0^{-1}(X-\mu_0)] = \operatorname{tr}(\Sigma_0^{-1}\Sigma_1) + \delta^\top \Sigma_0^{-1}\delta$. On regroupe avec les termes en $\log\det$. □

Le terme de déplacement est la moitié du carré de la distance de Mahalanobis : c'est l'unité dans laquelle le papier principal audite les scénarios publiés. Le terme de déformation est positif et nul si et seulement si $\Sigma_1 = \Sigma_0$; en écrivant ν_k les valeurs propres de $\Sigma_0^{-1}\Sigma_1$, il vaut $\frac{1}{2}\sum_k (\nu_k - 1 - \log \nu_k)$, une somme de termes positifs, un par direction propre.

5.2 La boule projetée et le taux de change

Définition 2 (Scénario en boule d'entropie)**.** Étant donné la loi conditionnelle d'aujourd'hui p_0 et une sévérité $\eta > 0$, le scénario de sévérité η pour une fonctionnelle de risque ρ est

$$p_\eta^\star = \arg \max_{p \,:\, D_{KL}(p \,\|\, p_0) \le \eta} \rho(p). \tag{13}$$

Pour un portefeuille linéaire $w^\top r$ de moyenne m_0 et d'écart type s_0 sous p_0, posons $u = (m - m_0)/s_0$ et $v = s/s_0$. Par la proposition 4 en dimension un,

$$g(u, v) = \tfrac{1}{2}\left(u^2 + v^2 - 1 - 2\log v\right). \tag{14}$$

Proposition 5 (Solution de la boule projetée)**.** *Pour $\rho = -m + c\,s$ avec $c \ge 0$ (VaR et expected shortfall gaussiennes sont de cette forme), le maximum de ρ sous $g(u, v) \le \eta$ est atteint sur la frontière $g = \eta$ en un point vérifiant*

$$u = -t, \qquad v - v^{-1} = c\,t, \qquad t > 0.$$

Pour $c = 0$: $v = 1$ et $u = -\sqrt{2\eta}$. Un scénario purement directionnel de η nats est un mouvement de $\sqrt{2\eta}$ sigmas *; un nat achète $\sqrt{2} \approx 1{,}41$ sigma, et k sigmas coûtent $k^2/2$ nats.*

Démonstration. g est convexe sur $\mathbb{R}\times(0,\infty)$ (somme de $u^2/2$ et de $(v^2-1-2\log v)/2$, de dérivée seconde $1+v^{-2}>0$) et l'objectif $s_0(-u+cv)$ est linéaire : les conditions de Karush–Kuhn–Tucker sont suffisantes. L'objectif n'a pas de maximum intérieur, donc la contrainte est saturée. Le lagrangien donne $-1=\lambda u$ et $c=\lambda(v-v^{-1})$ avec $\lambda>0$; en posant $t=1/\lambda$ on obtient le système annoncé, et t est fixé par $g(-t,v(t))=\eta$. Pour $c=0$, $v-v^{-1}=0$ impose $v=1$ et $g=u^2/2=\eta$. □

5.3 Du portefeuille à la dimension pleine

La boule (13) se résout sur la loi du portefeuille, mais un test de résistance doit dire comment chaque actif bouge. Deux faits règlent la question.

Proposition 6 (Traitement des données)**.** *Pour toute loi p sur $\mathbb{R}^N$, et p^w, p_0^w les lois de $w^\top r$ sous p et p_0, $D_{KL}(p^w\,\|\,p_0^w)\le D_{KL}(p\,\|\,p_0)$.*

C'est l'inégalité de traitement des données (Cover & Thomas, 2006) appliquée à l'application $r\mapsto w^\top r$. Le prix *ambiant* d'un scénario (en dimension pleine) est donc toujours au moins son prix *vu du portefeuille* (en projection). Le tableau des bundles classiques de la v1 le vérifie ligne à ligne (9,97 contre 7,24 nats pour le bundle standard).

Proposition 7 (Relèvement minimal)**.** *Soit $p_0=\mathcal{N}(\mu_0,\Sigma_0)$, $m_0=w^\top\mu_0$, $s_0^2=w^\top\Sigma_0 w$, et une cible (m,s) avec $s>0$. Parmi les gaussiennes $\mathcal{N}(\mu_1,\Sigma_1)$ telles que $w^\top\mu_1=m$ et $w^\top\Sigma_1 w=s^2$, la divergence $D_{KL}(p_1\,\|\,p_0)$ est minimale pour*

$$\mu_1=\mu_0+u\,s_0\,\beta,\qquad \Sigma_1=\Sigma_0+(v^2-1)\,s_0^2\,\beta\beta^\top,\qquad \beta=\frac{\Sigma_0 w}{s_0^2},\tag{15}$$

et ce minimum vaut exactement $g(u,v)$, le prix vu du portefeuille.

Démonstration. Par la proposition 6, tout candidat coûte au moins le prix de sa projection, qui est $g(u,v)$ puisque la projection d'une gaussienne est gaussienne de moyenne m et d'écart type s. Il suffit donc de vérifier que (15) atteint cette borne. On a $w^\top\beta=1$, donc $w^\top\mu_1=m_0+us_0=m$ et $w^\top\Sigma_1 w=s_0^2+(v^2-1)s_0^2=s^2$. Dans (12) : $\delta^\top\Sigma_0^{-1}\delta=u^2s_0^2\,\beta^\top\Sigma_0^{-1}\beta=u^2$; $\operatorname{tr}(\Sigma_0^{-1}\Sigma_1)=N+(v^2-1)s_0^2\,\beta^\top\Sigma_0^{-1}\beta=N+v^2-1$; et par le lemme du déterminant matriciel, $\det(\Sigma_0^{-1}\Sigma_1)=1+(v^2-1)s_0^2\,\beta^\top\Sigma_0^{-1}\beta=v^2$. D'où $D_{KL}(p_1\,\|\,p_0)=\frac12(u^2+v^2-1-2\log v)=g(u,v)$. La matrice Σ_1 est définie positive pour tout $v>0$. □

Lecture actif par actif. Le vecteur β est celui des bêtas des actifs sur le portefeuille, $\beta_i=\operatorname{Cov}(r_i,w^\top r)/s_0^2$. Écrivons $r=\beta f+e$ avec $f=w^\top r$ et e non corrélé à f sous p_0. Le scénario (15) multiplie l'écart type du facteur portefeuille f par v, déplace sa moyenne de u sigmas, et laisse la loi de e inchangée. Chaque actif voit sa variance augmenter de $(v^2-1)s_0^2\beta_i^2$ et sa moyenne bouger de $us_0\beta_i$: les actifs à fort bêta prennent le choc, et les corrélations entre eux montent. C'est un scénario à un facteur, et il est le moins informatif de tous ceux qui atteignent la sévérité visée.

Remarque (Correction de la v1). La version arXiv v1 identifiait ce minimum par ses conditions du premier ordre, $\Sigma_1^{-1}=\Sigma_0^{-1}-\lambda ww^\top$, et le jugeait « non interprétable actif par actif ». Par la formule de Sherman–Morrison, cette perturbation de rang un de la précision *est* (15), une perturbation de rang un de la covariance le long de $\Sigma_0 w$, et elle s'interprète comme ci-dessus. La v1 ne l'utilisant nulle part, aucun chiffre n'en dépend.

Corollaire 1 (Coût de la dilatation uniforme)**.** *La dilatation uniforme $\Sigma_1=v^2\Sigma_0$, choix par défaut de la v1, a une composante de déformation égale à $N\cdot\frac12(v^2-1-2\log v)$, soit N fois celle du relèvement minimal.*

Démonstration. Toutes les valeurs propres de $\Sigma_0^{-1}\Sigma_1$ valent v^2 ; on applique la forme spectrale du terme de déformation. □

Pour le scénario décennal du panel principal ($v = 1{,}63$, $N = 20$), la composante de variance vaut 0,34 nat au minimum et $20 \times 0{,}34 \approx 6{,}8$ sous la dilatation uniforme, ce qui est le chiffre du tableau de composition de la v1. Le corollaire explique le constat empirique de la v1 selon lequel les compositions calibrées sur H1 (2,88 nats) et raffinées par H8 (0,71) coûtent *moins* que le défaut : le défaut déforme également toutes les directions propres, alors qu'une composition qui concentre le choc sur le mode commun se rapproche du scénario à un facteur (15), dont le coût total est 0,41 nat avec le déplacement de moyenne. Que la dilatation uniforme coûte N fois le minimum en variance est un résultat général ; que les compositions calibrées se placent entre les deux reste un constat sur ces panels, mais il devient attendu plutôt que surprenant.

5.4 Composer une sévérité donnée

Proposition 8 (Une sévérité, plusieurs compositions)**.** *Si $w^\top \Sigma_a w = w^\top \Sigma_b w = s^2$, alors pour tout $\alpha \in [0,1]$, $\Sigma_\alpha = (1-\alpha)\Sigma_a + \alpha\Sigma_b$ vérifie $w^\top \Sigma_\alpha w = s^2$.*

Démonstration. $w^\top \Sigma w$ est linéaire en Σ. □

La sévérité du portefeuille ne contraint donc pas la composition. Le prix ambiant, lui, est convexe en Σ_1 (le terme $-\log\det$ est convexe et le reste est linéaire), donc le long d'un mélange il est majoré par le mélange des prix, ce qui garantit qu'une composition intermédiaire ne coûte jamais plus que la plus chère de ses deux extrémités.

Un plafond physique pour la corrélation. À volatilités marginales fixées, $w^\top \Sigma w$ est maximal sur les matrices de corrélation valides pour $\rho_{ij} = 1$, où il vaut $(\sum_i w_i \sigma_i)^2$. Sur le panel principal ce plafond ne vaut qu'environ 1,5 fois la volatilité d'aujourd'hui : au-delà de l'échelon quinquennal, aucune hausse de corrélation seule ne suffit, et une part de hausse des volatilités est inévitable.

5.5 Calibrer le rayon, et la limite de cette calibration

Le rayon se lit sur le flux d'information de la projection, $I_t^{(h)} = D_{KL}\big(p_t^w \,\|\, p_{t-h}^w\big)$, dont les quantiles (sur blocs non chevauchants de 21 jours) convertissent une période de retour en rayon. Lire le rayon sur le flux à N dimensions le surestime d'un ordre de grandeur, par la proposition 6. Calibrée ainsi, l'échelle de la v1 donne un multiplicateur de volatilité décennal de 1,63, quand le quantile décennal de la hausse de volatilité réalisée sur un mois vaut 3,2. L'échelle est une règle cohérente et reproductible ; ses périodes de retour ne sont pas validées. C'est l'une des raisons pour lesquelles le papier principal garde l'audit (tarifer un scénario donné) et abandonne la génération (construire un scénario d'une période de retour donnée).

5.6 Le test de résistance inversé

Demander le scénario le moins coûteux qui produit une perte L donnée inverse la boule. Dans le cadre gaussien projeté, la proposition 5 se lit à l'envers. Dans le cadre non paramétrique, la solution est l'inclinaison exponentielle de l'échantillon (Csiszár, 1975), dont la taille d'échantillon effective s'effondre quand le rayon croît : à 9 nats, elle vaut 1,0 sur le panel principal, c'est-à-dire que la loi inclinée n'est plus que la pire journée observée. Toute implémentation devrait rapporter cette taille effective et basculer vers la boule gaussienne dès qu'elle tombe sous quelques dizaines.

6 Le pont vers le papier principal : décomposition par blocs

Cette section relie la théorie qui précède à l'indicateur du papier principal. Elle établit l'identité sur laquelle repose la « carte de contagion » et montre où le canal de dépendance se place dans l'indice structurel.

6.1 L'identité

Partitionnons les N séries en B blocs (par exemple les segments du CISS : monétaire, obligataire, actions, intermédiaires financiers, change), et notons R_{bb} les blocs diagonaux de la matrice de corrélation R et $R_D = \operatorname{diag}(R_{11}, \dots, R_{BB})$.

Proposition 9 (Décomposition intra/inter-blocs)**.**

$$\underbrace{-\tfrac{1}{2}\log\det R}_{\textit{dépendance totale}} \;=\; \sum_{b=1}^{B} \underbrace{\left(-\tfrac{1}{2}\log\det R_{bb}\right)}_{\textit{intra-bloc } b} \;+\; \underbrace{\left(-\tfrac{1}{2}\log\det\left(R_D^{-1/2} R R_D^{-1/2}\right)\right)}_{\textit{inter-blocs}}, \tag{16}$$

et chacun des $B{+}1$ termes est positif ou nul. Le terme inter-blocs est la multi-information gaussienne entre les blocs, $D_{KL}(\mathcal{N}(0,R) \,\|\, \bigotimes_b \mathcal{N}(0,R_{bb}))$; il est nul si et seulement si les blocs sont deux à deux non corrélés.

Démonstration. $R = R_D^{1/2}\left(R_D^{-1/2} R R_D^{-1/2}\right) R_D^{1/2}$ et le déterminant est multiplicatif, donc $\log\det R = \log\det R_D + \log\det(R_D^{-1/2} R R_D^{-1/2})$, avec $\log\det R_D = \sum_b \log\det R_{bb}$. Chaque R_{bb} est une matrice de corrélation, donc $-\frac{1}{2}\log\det R_{bb} \geq 0$ par l'inégalité de Hadamard (annexe B). La matrice $\tilde{R} = R_D^{-1/2} R R_D^{-1/2}$ a des blocs diagonaux égaux à l'identité, donc une diagonale unité, et Hadamard s'applique encore. Enfin la proposition 4 avec $\mu_1 = \mu_0$, $\Sigma_1 = R$, $\Sigma_0 = R_D$ donne $\frac{1}{2}[\operatorname{tr}(R_D^{-1}R) - N - \log\det(R_D^{-1}R)]$, et $\operatorname{tr}(R_D^{-1}R) = \sum_b \operatorname{tr}(I) = N$. □

Deux blocs : les corrélations canoniques. Pour $B = 2$, en notant $C = R_{11}^{-1/2} R_{12} R_{22}^{-1/2}$ et $\rho_1, \dots, \rho_k$ ses valeurs singulières (les corrélations canoniques entre les deux blocs), $\det\tilde{R} = \det(I - CC^\top) = \prod_j (1-\rho_j^2)$ et le terme inter-blocs vaut $-\frac{1}{2}\sum_j \log(1-\rho_j^2)$. C'est l'information mutuelle gaussienne entre les deux segments, somme des informations portées par chaque paire canonique. Pour $B > 2$, l'identité (16) s'applique de façon emboîtée et permet d'attribuer la contagion à des paires ou des groupes de segments par règle de chaînage.

6.2 Où se place le canal de dépendance dans l'indice structurel

La règle de chaînage de l'annexe D écrit $\mathcal{J} = \sum_i \mathcal{D}_1(x_i) + I(x)$. En remplaçant la multi-information $I(x)$ par sa part gaussienne $-H^{dep}$ et en appliquant (16) :

$$\mathcal{J} \;\approx\; \underbrace{\sum_i \mathcal{D}_1(x_i)}_{\text{forme}} \;+\; \underbrace{\sum_b \left(-\tfrac{1}{2}\log\det R_{bb}\right)}_{\text{intra}} \;+\; \underbrace{\left(-\tfrac{1}{2}\log\det\tilde{R}\right)}_{\text{inter}}. \tag{17}$$

Le papier principal conserve les deux derniers termes et abandonne le premier, qui est celui que le témoin reproduit (section 4). Le CISS entropique est donc l'indice structurel amputé de son canal de forme, et sa décomposition est exacte, sans approximation, parce qu'elle ne porte que sur la partie gaussienne.

6.3 Trois propriétés utiles à l'indicateur

Invariance d'échelle. Les termes de (16) ne dépendent que de R : ils sont invariants à toute remise à l'échelle série par série, ce qui permet d'agréger des marchés aux volatilités très différentes sans pondération ad hoc. La dévolatilisation de Forbes & Rigobon (2002) n'agit donc pas sur la formule mais sur le biais de l'*estimateur* de R en période d'hétéroscédasticité.

Version en rangs. En remplaçant R par la corrélation des scores normaux $\Phi^{-1}(\hat{F}_i(x_i))$, on estime la multi-information d'une copule gaussienne. La quantité devient invariante à toute transformation monotone des marges, ce qui explique sa robustesse aux queues observée en phase A.

Normalisation en N. Pour une corrélation constante ρ, $\det R = (1-\rho)^{N-1}\big(1+(N-1)\rho\big)$, de sorte que $-H^{dep}$ croît à peu près linéairement en N. Diviser par $N-1$, ou rapporter la valeur à la corrélation constante équivalente $\rho^\star$ qui donne le même déterminant, rend l'indicateur comparable d'un panel à l'autre. Pour $\rho^\star$ petit, $-H^{dep} \approx \frac{1}{4}N(N-1)\rho^{\star 2}$.

7 Indicateurs de suivi et solvabilité en assurance

Deux indicateurs de la v1. La séparation saut/diffusion livrait deux quantités quotidiennes : la composante de saut positif standardisée de $\mathcal{J}$ (quelle quantité d'information est arrivée aujourd'hui) et $\mathcal{J}_t$ rapporté à son maximum glissant (quelle part n'est pas encore résorbée). Ni l'un ni l'autre n'améliore la prévision de la volatilité (H7), et tous deux reposent sur des statistiques que le témoin n'identifie pas. Ils ne sont pas repris.

Assurance. Trois liens restent valables en principe. Un scénario en boule d'entropie produit une loi stressée complète, objet naturel pour l'ORSA. La décomposition des bundles classiques concerne la formule standard de Solvabilité II, dont le crédit de diversification repose sur une matrice de corrélation fixe. Enfin les mesures de risque entropiques sont cohérentes (Ahmadi-Javid, 2012; Artzner et al., 1999). Rien n'a cependant été testé sur des passifs, et les panels courts et peu fréquents des données d'assurance mettraient à mal chacun des estimateurs employés.

8 Questions ouvertes

1. **Arrivées auto-excitantes.** Le regroupement des sauts observé dans l'étude d'événement de la v1 contredit la mesure de Poisson de (11). Un processus de Hawkes est la spécification suivante.
2. **Positivité.** $\mathcal{J} \geq 0$ alors qu'un Ornstein–Uhlenbeck à terme brownien peut devenir négatif. Il faudrait soit supprimer $\sigma_{\mathcal{J}}$ (forme pure de Barndorff-Nielsen & Shephard 2001), soit modéliser $\log \mathcal{J}$.
3. **Dépendance de queue non linéaire.** $\mathcal{J}$ et le canal de dépendance ne voient que la part gaussienne de la multi-information. Une estimation de la multi-information de copule complète (par exemple par plus proches voisins sur les rangs) mesurerait ce qui manque, au prix d'une variance d'estimation bien plus forte.
4. **Queue du flux d'information.** Au-delà d'une vingtaine d'années, les quantiles de $I^{(h)}$ sont extrapolés. Un ajustement de Pareto généralisée serait la correction disciplinée.

5. **Relèvement minimal et scénarios publiés.** La proposition 7 donne un étalon : pour tout scénario publié, le rapport entre son prix ambiant et le prix minimal $g(u, v)$ de sa projection mesure combien d'information il dépense hors de la direction qui compte pour le portefeuille. C'est un prolongement direct de l'audit du papier principal.

A Unités, invariance, et ce qui est calculable

Le nat. L'entropie $H = -\sum_i p_i \log p_i$ n'est définie qu'une fois la base du logarithme choisie, et ce choix *est* le choix de l'unité. Avec $\log_2$ on obtient des bits (shannons), avec $\log_{10}$ des dits, et avec le logarithme népérien des *nats*. Un nat est l'information apportée par une observation qui divise l'espace des possibles par $e \approx 2{,}718$, là où un bit le divise par deux. La conversion est $1 \text{ nat} = 1/\log 2 \approx 1{,}4427$ bit. Tout ce papier emploie le logarithme népérien : entropies, déficits, divergences, rayons de scénario et indice structurel sont en nats.

Trois lectures opérationnelles, de la plus utile à la plus abstraite. D'abord le taux de change établi en section 5 : un scénario purement directionnel de η nats est un mouvement de $\sqrt{2\eta}$ sigmas, donc k sigmas coûtent $k^2/2$ nats. Ensuite le codage : $D_{KL}(p \,\|\, q)$ nats est l'excès de longueur de code attendu lorsqu'on encode des données de loi p avec un code optimal pour q. Enfin le test d'hypothèse : une divergence de un nat par observation signifie que le rapport de vraisemblance en faveur de p croît en moyenne d'un facteur e à chaque observation.

h dépend des unités, les divergences non. L'entropie différentielle d'une variable continue vérifie, pour toute transformation affine inversible,

$$h(aX + b) \;=\; h(X) + \log|a|, \qquad \text{et en dimension } N, \quad h(AX + b) = h(X) + \log|\det A|. \tag{18}$$

Exprimer les rendements en pourcentages plutôt qu'en décimales ajoute donc $N \log 100$ à h : le *niveau* de h, et par conséquent celui de H^{vol} et de H^{cov}, n'a aucune valeur absolue interprétable. En revanche $D_{KL}(p \,\|\, q)$, $I(X;Y)$, $\mathcal{D}$ et $\mathcal{J}$ sont invariants par tout changement de variable inversible, les jacobiens se simplifiant entre numérateur et dénominateur du logarithme. *Un chiffre en nats n'est comparable d'un jeu de données à l'autre que si c'est une divergence.* C'est la raison structurelle pour laquelle l'article construit un indice sans échelle.

Comment calcule-t-on $h(X)$? Dans le cas gaussien, en forme fermée (annexe B). Dans le cas général, on ne le peut pas sans connaître p. Des estimateurs non paramétriques existent — espacements de Vasicek (1976), plus proches voisins de Kozachenko–Leonenko, méthodes à noyau — mais tous se dégradent rapidement au-delà de trois ou quatre dimensions. Estimer une entropie différentielle en dimension 20 sur une fenêtre de 252 jours est hors de portée.

L'article ne calcule donc *jamais* $h(p)$. Il calcule $h(q)$ en forme fermée à partir de $\widehat{\Sigma}$, et le déficit $\mathcal{D}$ par une approximation de la *différence* d'entropies marginales. Une différence d'entropies est sans dimension et estimable ; une entropie différentielle nue ne l'est pas. Toute l'architecture — décomposer plutôt qu'estimer directement — découle de cette contrainte.

B Entropie gaussienne : démonstration de l'équation (5)

Étape A : entropie d'une gaussienne multivariée. Pour $q = \mathcal{N}(\mu, \Sigma)$ sur $\mathbb{R}^N$,

$$\log q(x) = -\tfrac{1}{2}\left[N \log 2\pi + \log\det\Sigma + (x-\mu)'\Sigma^{-1}(x-\mu)\right],$$

donc

$$h(q) = -\mathbb{E}_q[\log q] = \tfrac{1}{2} N \log 2\pi + \tfrac{1}{2} \log\det\Sigma + \tfrac{1}{2}\,\mathbb{E}\big[(X-\mu)'\Sigma^{-1}(X-\mu)\big]\,.$$

La dernière espérance se calcule par l'astuce de la trace : un scalaire égale sa trace, et la trace est cyclique, d'où

$$\mathbb{E}\big[(X-\mu)'\Sigma^{-1}(X-\mu)\big] = \mathbb{E}\big[\mathrm{tr}\big(\Sigma^{-1}(X-\mu)(X-\mu)'\big)\big] = \mathrm{tr}(\Sigma^{-1}\Sigma) = \mathrm{tr}(I_N) = N.$$

En regroupant, $h(q) = \frac{1}{2}\left[N\log 2\pi + \log\det\Sigma + N\right] = \frac{1}{2}\log\big((2\pi e)^N \det\Sigma\big)$. □

Étape B : factorisation du déterminant. Avec $\Sigma = DRD$, $D = \mathrm{diag}(\sigma_1,\dots,\sigma_N)$ et R la matrice de corrélation, la multiplicativité du déterminant donne $\det\Sigma = \det(D)\det(R)\det(D) = \left(\prod_i \sigma_i\right)^2 \det R$. □

Étape C : substitution. $\frac{1}{2}\log\det\Sigma = \frac{1}{2}\log\Big[\left(\prod_i\sigma_i\right)^2\det R\Big] = \sum_i \log\sigma_i + \frac{1}{2}\log\det R$, d'où $h(q) = \frac{N}{2}\log(2\pi e) + \sum_i\log\sigma_i + \frac{1}{2}\log\det R$, qui est l'équation (5). □

Signe du canal de dépendance. L'inégalité de Hadamard donne $\det R \le \prod_i R_{ii} = 1$ pour une matrice semi-définie positive. Une démonstration plus parlante passe par le spectre : $\det R = \prod_k \lambda_k$ avec $\sum_k \lambda_k = \mathrm{tr}\,R = N$, et l'inégalité arithmético-géométrique donne $\prod_k \lambda_k \le \left(\sum_k \lambda_k/N\right)^N = 1$, avec égalité si et seulement si toutes les valeurs propres valent 1, c'est-à-dire $R = I$. Donc $H^{dep} \le 0$: *la corrélation détruit toujours de l'entropie.*

Dans le cas bivarié, $\det R = 1-\rho^2$ et $H^{dep} = \frac{1}{2}\log(1-\rho^2)$; pour $\rho = 0{,}9$ cela vaut $-0{,}83$ nat. Remarquons que $-H^{dep}$ est alors exactement l'information mutuelle entre les deux actifs : la corrélation est de l'information partagée, donc de l'entropie détruite.

Note de lecture sur les tableaux. Les colonnes H^{cov} des tableaux de résultats de la version arXiv v1 rapportent $H^{vol} + H^{dep}$ et **omettent la constante** $\frac{N}{2}\log(2\pi e)$, qui vaut 28,38 nats pour $N = 20$. Ce décalage constant est sans conséquence puisque seules les différences entre régimes et les variations temporelles sont interprétées, mais il explique que les niveaux rapportés soient négatifs.

C Le déficit d'entropie : pourquoi $\mathcal{D} = h(q) - h(p)$

La divergence de Kullback–Leibler entre une loi p et une loi de référence q est $D_{KL}(p\,\|\,q) = \int p\log(p/q)$, positive et nulle si et seulement si $p = q$ presque partout. Elle n'est ni symétrique ni munie d'une inégalité triangulaire : ce n'est pas une distance, d'où le terme de divergence. Les lettres « KL » sont les initiales de Kullback et Leibler.

Proposition 10. *Si $q = \mathcal{N}(\mu,\Sigma)$ a les deux premiers moments de p, alors $D_{KL}(p\,\|\,q) = h(q) - h(p)$.*

Démonstration. $D_{KL}(p\,\|\,q) = -h(p) - \mathbb{E}_p[\log q(X)]$. Or $\log q$ est exactement quadratique en x, donc son espérance ne dépend que de la moyenne et de la covariance de la loi sous laquelle on l'évalue. Comme p et q partagent ces deux moments, $\mathbb{E}_p\big[(X-\mu)'\Sigma^{-1}(X-\mu)\big] = \mathrm{tr}(\Sigma^{-1}\Sigma) = N = \mathbb{E}_q[\cdot]$, d'où $\mathbb{E}_p[\log q] = \mathbb{E}_q[\log q] = -h(q)$ et donc $D_{KL}(p\,\|\,q) = h(q) - h(p)$. □

L'hypothèse de coïncidence des moments est essentielle : sans elle l'identité tombe. C'est tout le contenu de la proposition 1, lue comme une mesure plutôt que comme un théorème d'existence. Économiquement, $\mathcal{D}$ est le prix en nats du mensonge « le marché est gaussien » : l'incertitude apparente que la description gaussienne surestime, parce que la loi véritable est plus concentrée que ne le laisse croire sa seule covariance.

D L'indice structurel est une divergence

Proposition 11. *Avec $q_i = \mathcal{N}(\mu_i, \sigma_i^2)$ les marginales gaussiennes de mêmes échelles que p,*

$$D_{KL}(p \,\|\, \textstyle\prod_i q_i) \;=\; \mathcal{D} - H^{dep} \;=\; \mathcal{J}.$$

Démonstration. Par définition,

$$D_{KL}(p \,\|\, \textstyle\prod_i q_i) = -h(p) - \mathbb{E}_p[\sum_i \log q_i(X_i)] = -h(p) + \sum_i \left[\tfrac{1}{2}\log(2\pi\sigma_i^2) + \tfrac{1}{2}\right]$$

$$= -h(p) + \sum_i \log \sigma_i + \tfrac{N}{2}\log(2\pi e),$$

où l'on a utilisé $\mathbb{E}_p[(X_i - \mu_i)^2] = \sigma_i^2$, vrai par construction. En y injectant l'équation (6), soit $h(p) = \frac{N}{2}\log(2\pi e) + \sum_i \log \sigma_i + H^{dep} - \mathcal{D}$, les termes d'échelle et la constante se télescopent et il reste $\mathcal{D} - H^{dep}$. □

C'est une identité exacte, non une approximation, et c'est elle qui justifie la définition 1. Retirer le canal d'échelle de (6) pourrait passer pour un bricolage ; l'objet qui reste se trouve être une divergence de Kullback–Leibler en bonne et due forme, et hérite donc gratuitement de trois propriétés : elle est positive ; elle est nulle si et seulement si les rendements sont indépendants *et* gaussiens, ce qui fournit un point de référence bien défini plutôt qu'arbitraire ; et elle est invariante par changement d'unités actif par actif, puisque p et $\prod_i q_i$ se transforment de la même façon.

Il est utile de rapprocher cette identité de la règle de chaînage générale $D_{KL}(p \,\|\, \prod_i q_i) = \sum_i D_{KL}(p_i \,\|\, q_i) + I(x)$, où $I(x) = D_{KL}(p \,\|\, \prod_i p_i)$ est la multi-information. Le premier terme est la somme des déficits marginaux $\sum_i \mathcal{D}_1(x_i)$, le second la dépendance totale. L'estimateur employé dans l'article estime le premier terme par l'approximation de Hyvärinen (1998) et remplace le second par sa part linéaire $-H^{dep}$; la dépendance de queue non linéaire est donc omise de $\mathcal{J}$ et mesurée séparément par un taux de co-dépassement.

E Information mutuelle : les deux propositions et un exemple

Démonstration de la proposition 2. Par définition de l'entropie conditionnelle, $\mathbb{E}_Y[h(X \mid Y)] = h(X,Y) - h(Y)$, et par (9), $I(X;Y) = h(X) + h(Y) - h(X,Y)$. En sommant les deux, $\mathbb{E}_Y[h(X \mid Y)] = h(X) - I(X;Y)$. La positivité de I découle de celle de la divergence de Kullback–Leibler dont elle est un cas particulier, avec égalité si et seulement si $p_{XY} = p_X \otimes p_Y$.

Démonstration de la proposition 3. Immédiate : une contrainte supplémentaire ne peut que réduire l'ensemble réalisable, et le supremum d'une fonctionnelle sur un ensemble plus petit ne peut pas augmenter.

Pourquoi les deux ne sont pas équivalents. La première quantifie mais ne vaut qu'en moyenne ; la seconde vaut réalisation par réalisation mais porte sur le plafond et ne quantifie rien. Un contre-exemple discret suffit à montrer qu'une réalisation particulière peut *augmenter* l'entropie. Soit X binaire avec $\mathbb{P}(X = a) = 0{,}99$, d'entropie $H(X) = 0{,}056$ nat. Soit un signal Y qui, avec probabilité 0,98, lève complètement le doute ($H(X \mid Y = 0) = 0$), et avec probabilité 0,02 conduit à $\mathbb{P}(X = a \mid Y = 1) = 1/2$, soit $H(X \mid Y = 1) = \log 2 = 0{,}693$ nat — douze fois l'entropie a priori. La moyenne vaut néanmoins $0{,}98 \times 0 + 0{,}02 \times 0{,}693 = 0{,}014$ nat, bien en dessous de 0,056, et $I(X;Y) = 0{,}042$ nat. C'est exactement la raison pour laquelle l'article prédit une composante de saut *principalement*, et non exclusivement, unilatérale.

Exemple gaussien chiffré. Soit $X \sim \mathcal{N}(0, \sigma^2)$ le rendement de demain et $Y = X + \varepsilon$ un signal bruité, $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$ indépendant. Alors

$$I(X;Y) = \tfrac{1}{2}\log\!\left(1 + \frac{\sigma^2}{\sigma_\varepsilon^2}\right), \qquad \mathrm{Var}(X \mid Y) = \frac{\sigma^2 \sigma_\varepsilon^2}{\sigma^2 + \sigma_\varepsilon^2}, \tag{19}$$

la variance a posteriori ne dépendant pas de la réalisation y. Avec $\sigma = 1\%$ par jour :

Qualité du signal	σ_ε	$I(X;Y)$ (nats)	vol. a posteriori	équivalent $\sqrt{2\eta}$
tranchant	0,5%	0,805	0,45%	$1{,}27\sigma$
moyen	1,0%	0,347	0,71%	$0{,}83\sigma$
vague	3,0%	0,053	0,95%	$0{,}32\sigma$

Un facteur quinze sépare la taille du saut d'entropie provoqué par une nouvelle qui tranche de celui provoqué par une rumeur. La dernière colonne traduit chaque saut dans l'échelle de sévérité de la section 5 : c'est le mouvement directionnel qu'un scénario de même rayon produirait.

Références

Ahmadi-Javid, A. (2012). Entropic Value-at-Risk : A New Coherent Risk Measure. *Journal of Optimization Theory and Applications*, 155(3), 1105–1123.

Almog, A., & Shmueli, E. (2019). Structural Entropy : Monitoring Correlation-Based Networks Over Time With Application To Financial Markets. *Scientific Reports*, 9, 10832.

Ané, T., & Geman, H. (2000). Order Flow, Transaction Clock, and Normality of Asset Returns. *Journal of Finance*, 55(5), 2259–2284.

Artzner, P., Delbaen, F., Eber, J.-M., & Heath, D. (1999). Coherent Measures of Risk. *Mathematical Finance*, 9(3), 203–228.

Barndorff-Nielsen, O. E., & Shephard, N. (2001). Non-Gaussian Ornstein–Uhlenbeck-based Models and Some of Their Uses in Financial Economics. *Journal of the Royal Statistical Society B*, 63(2), 167–241.

Barndorff-Nielsen, O. E., & Shephard, N. (2004). Power and Bipower Variation with Stochastic Volatility and Jumps. *Journal of Financial Econometrics*, 2(1), 1–37.

Black, F. (1976). Studies of Stock Price Volatility Changes. *Proceedings of the Business and Economic Statistics Section, American Statistical Association*, 177–181.

Christie, A. A. (1982). The Stochastic Behavior of Common Stock Variances : Value, Leverage and Interest Rate Effects. *Journal of Financial Economics*, 10(4), 407–432.

Doob, J. L. (1942). The Brownian Movement and Stochastic Equations. *Annals of Mathematics*, 43(2), 351–369.

Engle, R. F., & Ng, V. K. (1993). Measuring and Testing the Impact of News on Volatility. *Journal of Finance*, 48(5), 1749–1778.

Nelson, D. B. (1991). Conditional Heteroskedasticity in Asset Returns : A New Approach. *Econometrica*, 59(2), 347–370.

Bollerslev, T., & Ghysels, E. (1996). Periodic Autoregressive Conditional Heteroscedasticity. *Journal of Business & Economic Statistics*, 14(2), 139–151.

Breuer, T., & Csiszár, I. (2013). Systematic Stress Tests with Entropic Plausibility Constraints. *Journal of Banking & Finance*, 37(5), 1552–1559.

Caraiani, P. (2018). Modeling the Comovement of Entropy between Financial Markets. *Entropy*, 20(6), 417.

Clark, P. K. (1973). A Subordinated Stochastic Process Model with Finite Variance for Speculative Prices. *Econometrica*, 41(1), 135–155.

Cover, T. M., & Thomas, J. A. (2006). *Elements of Information Theory*, 2e éd. Wiley.

Csiszár, I. (1975). *I*-Divergence Geometry of Probability Distributions and Minimization Problems. *Annals of Probability*, 3(1), 146–158.

Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.

Engle, R. (2002). Dynamic Conditional Correlation. *Journal of Business & Economic Statistics*, 20(3), 339–350.

Forbes, K. J., & Rigobon, R. (2002). No Contagion, Only Interdependence : Measuring Stock Market Comovements. *Journal of Finance*, 57(5), 2223–2261.

Holló, D., Kremer, M., & Lo Duca, M. (2012). CISS – A Composite Indicator of Systemic Stress in the Financial System. *ECB Working Paper* No. 1426.

Kritzman, M., Li, Y., Page, S., & Rigobon, R. (2011). Principal Components as a Measure of Systemic Risk. *Journal of Portfolio Management*, 37(4), 112–126.

Glasserman, P., & Xu, X. (2014). Robust Risk Measurement and Model Risk. *Quantitative Finance*, 14(1), 29–58.

Hyvärinen, A. (1998). New Approximations of Differential Entropy for Independent Component Analysis and Projection Pursuit. *Advances in Neural Information Processing Systems*, 10, 273–279. (Constantes telles que dans Hyvärinen & Oja, 2000, *Neural Networks* 13, 411–430.)

Jaynes, E. T. (1957). Information Theory and Statistical Mechanics. *Physical Review*, 106, 620–630.

Kyle, A. S. (1985). Continuous Auctions and Insider Trading. *Econometrica*, 53(6), 1315–1335.

Ledoit, O., & Wolf, M. (2004). A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.

Mandelbrot, B., & Taylor, H. M. (1967). On the Distribution of Stock Price Differences. *Operations Research*, 15(6), 1057–1062.

Monroe, I. (1978). Processes That Can Be Embedded in Brownian Motion. *Annals of Probability*, 6(1), 42–56.

Papla, D., & Siedlecki, R. (2024). Entropy as a Tool for the Analysis of Stock Market Efficiency During Periods of Crisis. *Entropy*, 26(12), 1079.

Politis, D. N., & Romano, J. P. (1994). The Stationary Bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.

Tauchen, G. E., & Pitts, M. (1983). The Price Variability–Volume Relationship on Speculative Markets. *Econometrica*, 51(2), 485–505.

Vasicek, O. (1976). A Test for Normality Based on Sample Entropy. *Journal of the Royal Statistical Society B*, 38(1), 54–59.

Zhou, R., Cai, R., & Tong, G. (2013). Applications of Entropy in Finance : A Review. *Entropy*, 15(11), 4909–4931.