

Sauts d'entropie et relaxation de l'information sur les marchés financiers :

du maximum d'entropie en temps-volume aux tests de résistance calibrés en entropie

Version de travail

Août 2026

Résumé

Cet article reconstruit la lecture informationnelle de la formation des prix autour d'une seule asymétrie. Nous fermons d'abord le pont qui mène du maximum d'entropie aux prix gaussiens, là où il est habituellement laissé ouvert, en définissant le prix comme un flux d'ordres accumulé et en appliquant le principe de maximum d'entropie en *temps-volume* plutôt qu'en temps calendaire : le volume échangé fixant le budget de variance, la distribution conditionnelle la moins engageante de l'incrément de log-prix est gaussienne, et la cohérence temporelle fait alors du log-prix un mouvement brownien subordonné à l'horloge de volume, donc du prix un mouvement brownien géométrique. Lu à l'envers, le même argument dit que des prix non gaussiens sont la signature d'une distribution conditionnelle qui n'est *pas* d'entropie maximale, c'est-à-dire d'une information contraignante.

Nous décomposons ensuite l'entropie d'un vecteur de rendements en trois canaux : l'échelle ($\sum_i \log \sigma_i$), la dépendance ($\frac{1}{2} \log \det R \leq 0$) et la forme (le déficit d'entropie $\mathcal{D} = D_{KL}(p \parallel q)$, qui n'est autre que l'asymétrie et les queues épaisses). La combinaison des deux derniers donne un indice structurel sans échelle $\mathcal{J}_t = \mathcal{D}_t - \frac{1}{2} \log \det R_t = D_{KL}(p_t \parallel \prod_i q_{i,t}) \geq 0$, qui mesure la distance du marché à la référence d'entropie maximale à volatilité inchangée. Puisque conditionner ne peut pas augmenter l'entropie espérée, un événement informationnel abaisse l'entropie conditionnelle *moyenne* d'exactement l'information mutuelle de la nouvelle, et abaisse au sens large le plafond de maximum d'entropie à chaque réalisation : les sauts d'entropie vers le bas sont un théorème, non une hypothèse. Ce que nous postulons, c'est l'autre moitié : que l'entropie remonte par diffusion (P1), et que la contrainte imposée par la nouvelle est unilatérale, de sorte qu'un saut s'accompagne d'une asymétrie négative (P2). Ensemble, ces éléments donnent à $\mathcal{J}$ une dynamique de saut et diffusion de type Barndorff-Nielsen-Shephard : hausses par sauts, baisses par diffusion.

Sept hypothèses sont testées sur 33 ans de rendements quotidiens d'actions individuelles (vingt composantes du S&P 500, 1990–2022), répliquées sur le panel `EuStockMarkets` et — c'est là l'essentiel — jugées face à deux témoins calibrés construits en rééchantillonnant les rendements observés : l'un i.i.d., qui conserve les queues marginales épaisses et détruit toute structure temporelle, l'autre par blocs de 21 jours, qui conserve en outre le regroupement de volatilité. Pris au pied de la lettre, les résultats paraissent solides : le stress élève $\mathcal{J}$ de 2,89 nats, les variations de $\mathcal{J}$ sont massivement unilatérales (158 sauts positifs contre 9 négatifs, asymétrie +12,3), les sauts positifs s'accompagnent d'une asymétrie de marché négative, et les canaux de dépendance et de queue se verrouillent sous stress (0,04 en marché calme contre 0,66). Face aux témoins, l'essentiel s'évapore. L'asymétrie des sauts, la signature d'asymétrie et le couplage des canaux sont tous reproduits — plusieurs sont même *dépassés* — par des données rééchantillonnées, parce qu'une fonctionnelle convexe positive de moments estimés monte brutalement et redescend en douceur dès qu'une observation à queue épaisse entre dans l'estimateur. Exactement deux statistiques

franchissent les deux témoins, et ce sont celles qu'il faut retenir : l'écart de régime du canal de *dépendance* ($-1,72$ nats contre $-0,29$ et $-0,64$) et l'étendue de $\mathcal{J}$ sur l'échantillon ($18,95$ contre $10,49$ et $14,23$). Ce qui distingue une crise d'une simple série de gros rendements, c'est que la coupe transversale se couple — le nombre effectif de modes de risque indépendants tombe de $13,2$ à $10,5$ sur 20 — et non que les marginales s'épaississent. La demi-vie de relaxation n'est pas identifiée : à 120 jours, elle se situe au-dessus du témoin i.i.d. (92) et en dessous du témoin par blocs (162). Deux autres résultats vont à l'encontre de l'intérêt de l'article : la compensation volatilité-dépendance observée sur des portefeuilles sectoriels ne se réplique pas sur des titres individuels, et aucun canal d'entropie n'améliore hors échantillon la prévision du risque futur par rapport à une référence de volatilité.

La contribution appliquée est une construction de test de résistance. Un scénario de sévérité η est la pire distribution conditionnelle contenue dans une boule de Kullback–Leibler de rayon η nats autour de la distribution conditionnelle courante du marché; le rayon est calibré sur le flux d'information réalisé du marché lui-même, $D_{KL}(p_t \| p_{t-h})$, de sorte qu'une sévérité porte une période de retour plutôt qu'un adjectif, et que le déplacement de la moyenne et l'inflation de la variance sont prélevés sur un même budget au lieu d'être choqués séparément. Un nat achète $\sqrt{2}$ sigma. La même métrique tarife les scénarios existants : un bundle classique — volatilités doublées, toutes les corrélations forcées à $0,9$, un choc de trois sigmas — se tarife à $9,97$ nats, entre les échelons vicennal et cinquannal, mais délivre une perte de queue qu'un scénario entropique atteint pour $5,47$; le comité a acheté une perte décennale au prix d'une invraisemblance trentennale. Nous décomposons ce prix pour montrer où il passe, et la composante chère n'est pas celle que l'intuition désigne.

Table des matières

Notations	3
1 Introduction	4
2 Du flux d'ordres au prix gaussien : le pont volume	6
2.1 Le prix comme flux d'ordres accumulé	6
2.2 Maximum d'entropie en temps-volume	6
2.3 Des incréments gaussiens au mouvement brownien puis au MBG	7
2.4 La contraposée	7
2.5 Où le pont est faible	8
3 Les trois canaux de l'entropie	8
3.1 Échelle et dépendance	8
3.2 Forme : le déficit d'entropie et sa composition	8
3.3 L'indice structurel	9
4 Dynamique de l'information : un théorème, deux postulats	9
4.1 Les sauts vers le bas sont un théorème	9
4.2 Deux postulats	10
4.3 La dynamique qui en résulte	12
4.4 Pourquoi queues épaisses, corrélation et sauts arrivent ensemble	13
5 Hypothèses	13

6	Données et estimation	14
6.1	Jeux de données	14
6.2	Estimateurs	14
6.3	Le témoin placebo	15
7	Résultats	16
7.1	Ce que le témoin calibré laisse debout	16
7.2	H1 : la signature de régime	18
7.3	H2 : la compensation est réelle, partielle, et confinée au stress	19
7.4	H3 : la composante de saut est unilatérale	20
7.5	H4 : la relaxation, face à la mémoire propre de l'estimateur	22
7.6	H5 : les sauts portent un signe	22
7.7	H6 : les canaux se verrouillent sous stress	23
7.8	H7 : l'entropie décrit, elle ne prévoit pas	24
7.9	Tout ceci n'est-il que de la volatilité ?	25
7.10	Réplication	25
8	Tests de résistance par l'entropie	26
8.1	La construction	26
8.2	Calibrer le rayon	26
8.3	Ce que cela apporte face aux tests de résistance en volatilité, moyenne et asymétrie	27
8.4	Deux indicateurs de suivi	29
8.5	Pertinence pour la solvabilité en assurance	29
9	Limites	30
10	Conclusion	30
A	Unités, invariance, et ce qui est calculable	31
B	Entropie gaussienne : démonstration de l'équation (5)	32
C	Le déficit d'entropie : pourquoi $\mathcal{D} = h(q) - h(p)$	33
D	L'indice structurel est une divergence	33
E	Information mutuelle : les deux propositions et un exemple	34

Notations

Deux mises en garde avant le tableau. D'abord, l'entropie différentielle h **dépend des unités** : $h(aX) = h(X) + \log |a|$, de sorte qu'exprimer les rendements en pourcentages plutôt qu'en décimales déplace h d'une constante. Les divergences ($D_{KL}(\cdot \| \cdot)$, I , $\mathcal{D}$, $\mathcal{J}$) sont au contraire invariantes par tout changement de variable inversible : c'est la raison d'être de l'indice structurel. Ensuite, K désigne un kurtosis et les lettres « KL » sont les initiales de Kullback et Leibler ; il n'y a aucun lien entre les deux.

Symbole	Signification	Nature
p_t	loi conditionnelle vraie des rendements en t	—
q_t	gaussienne de mêmes moyenne et covariance que p_t	—
$h(\cdot)$	entropie différentielle	nats, <i>dépend des unités</i>
$D_{KL}(p \parallel q)$	divergence de Kullback–Leibler	nats, invariante
$\mathcal{D}_t$	déficit d'entropie = $D_{KL}(p_t \parallel q_t) \geq 0$	nats, invariante
$\mathcal{D}_1(z)$	déficit d'un scalaire standardisé (néguentropie)	nats, invariante
H_t^{vol}	canal d'échelle = $\sum_i \log \sigma_{i,t}$	nats, <i>dépend des unités</i>
H_t^{dep}	canal de dépendance = $\frac{1}{2} \log \det R_t \leq 0$	nats, invariante
H_t^{cov}	$H_t^{vol} + H_t^{dep}$; la constante $\frac{N}{2} \log 2\pi e$ est omise	nats
$\mathcal{J}_t$	indice structurel = $\mathcal{D}_t - H_t^{dep} \geq 0$	nats, invariante
$I(X; Y)$	information mutuelle	nats, invariante
$I_t^{(h)}$	flux d'information = $D_{KL}(p_t \parallel p_{t-h})$	nats
S, K	asymétrie, kurtosis excédentaire	sans dimension
$\Sigma_t = D_t R_t D_t$	covariance, écarts types, corrélation	—
$\lambda_k, N_t^{\text{eff}}$	valeurs propres de R_t , nombre effectif de modes	$1 \leq N^{\text{eff}} \leq N$
$\kappa, \sigma_{\mathcal{J}}$	taux de relaxation et coefficient de diffusion de $\mathcal{J}$	—
η	rayon d'un scénario de stress	nats
N	nombre d'actifs	—

1 Introduction

Deux faits relatifs aux prix financiers cohabitent mal. Le premier est que le modèle gaussien est la réponse naturelle à une question d'ignorance : fixez une moyenne et une variance, ne sachez rien d'autre, et la distribution de maximum d'entropie est gaussienne. Le second est que les rendements ne sont pas gaussiens : ils ont des queues épaisses, une asymétrie négative, et leur dépendance se resserre précisément quand cela compte.

La réaction habituelle consiste à traiter le second fait comme un défaut du premier modèle et à le rapiécer : ajouter des sauts au prix, ajouter un facteur de volatilité stochastique, ajouter une copule. Cet article prend le chemin inverse. Si le gaussien est ce que délivre le maximum d'entropie, alors tout écart au gaussien est une mesure de la distance du marché à l'ignorance maximale, c'est-à-dire une mesure d'information. La question n'est donc pas comment rapiécer le gaussien, mais comment lire la taille, la dynamique et la direction de l'écart.

L'article s'organise autour d'une asymétrie de cet écart. L'information arrive par paquets et s'absorbe graduellement. Une surprise de banque centrale, un défaut, une guerre supprime l'incertitude en un instant ; le marché passe ensuite des semaines à en déduire les implications, et l'incertitude se reconstitue. Si l'entropie est la bonne monnaie de l'incertitude, sa dynamique devrait être en dents de scie : chutes brutales, remontées lentes. Cette forme n'est pas un fait stylisé qu'il aurait fallu supposer — la moitié en est un théorème. Conditionner ne peut pas augmenter l'entropie espérée, donc l'arrivée d'un signal abaisse l'entropie conditionnelle *moyenne* d'exactly l'information mutuelle entre le signal et le prix (proposition 2) ; et le plafond de maximum d'entropie, lui, baisse au sens large à chaque réalisation, sans qu'on puisse en général quantifier cette baisse (proposition 3). Les deux énoncés sont distincts et l'annexe E les sépare explicitement, avec un exemple gaussien chiffré. La taille *espérée* du saut, en nats, est le contenu informationnel de la nouvelle. Ce qu'il faut postuler, c'est la remontée et la direction.

Trois contributions en découlent.

Le pont volume (section 2). Le passage de « le maximum d'entropie donne un gaussien » à « les prix sont gaussiens » est couramment affirmé et rarement argumenté, parce que le maximum d'entropie est un énoncé sur une distribution à variance fixée et ne dit rien de l'origine de cette variance. Nous le fermons en définissant le prix comme un flux d'ordres accumulé et en appliquant le principe en temps-volume : le volume total échangé, qui est observable, fixe le budget de variance, et l'incrément de maximum d'entropie conditionnel au volume est gaussien de variance proportionnelle au volume. C'est l'hypothèse de mélange de distributions (Clark, 1973; Tauchen & Pitts, 1983; Ané & Geman, 2000), déduite plutôt que supposée. La cohérence temporelle fait ensuite du log-prix un mouvement brownien subordonné à l'horloge de volume, et le lemme d'Itô fait du prix un mouvement brownien géométrique. Le pont explique aussi, dans la même phrase, pourquoi les rendements en temps calendaire ne sont pas gaussiens : soit la distribution conditionnelle n'est pas d'entropie maximale (l'information contrainte), soit l'horloge de volume est aléatoire, soit les deux — et les deux sources laissent des empreintes différentes.

Trois canaux et un indice sans échelle (section 3). L'entropie gaussienne d'un vecteur de rendements se scinde exactement en un terme d'échelle et un terme de dépendance, et l'entropie véritable en diffère du déficit d'entropie $\mathcal{D} = D_{KL}(p \parallel q)$, où logent l'asymétrie et les queues épaisses. Le terme d'échelle domine le niveau de l'entropie différentielle et n'apprend rien sur l'information ; en le retirant, il reste $\mathcal{J} = \mathcal{D} - \frac{1}{2} \log \det R$, qui est exactement $D_{KL}(p \parallel \prod_i q_i)$ — la divergence à un produit de marginales gaussiennes de mêmes échelles. $\mathcal{J}$ est positif, invariant au niveau de volatilité, et additif sur ses deux canaux destructeurs d'entropie. C'est la variable d'état dont traite le reste de l'article. Empiriquement, il ne partage que 21% de sa variance avec la volatilité, et son canal de forme est essentiellement orthogonal à la volatilité ($r = 0,09$).

Tests de résistance en nats (section 8). Un scénario de sévérité η est la pire distribution conditionnelle contenue dans une boule KL de rayon η autour de celle d'aujourd'hui. La construction n'est pas nouvelle (Glasserman & Xu, 2014; Breuer & Csiszár, 2013) ; la calibration l'est. Le rayon se lit sur le flux d'information réalisé du marché, la révision à h pas $D_{KL}(p_t \parallel p_{t-h})$, mesurée dans la même unité que le rayon, si bien qu'une sévérité acquiert une période de retour. Parce que le déplacement de moyenne et l'inflation de variance sont choisis sur un même budget, le scénario ne peut pas être incohérent en interne, et parce que *tout* scénario peut être tarifé sur la même échelle, la question « ce test de résistance est-il assez sévère ? » devient arithmétique.

Un avertissement sur la mesure de tout ceci. L'indice structurel est une fonctionnelle convexe positive de moments d'ordre deux, trois et quatre estimés. Le bruit d'estimation sur des données à queues épaisses pousse une telle fonctionnelle *vers le haut* brutalement et la laisse décroître *en douceur*, ce qui est précisément la dent de scie que prédisent les postulats. Chaque statistique de saut et de relaxation ci-dessous est donc rapportée face à un témoin construit en rééchantillonnant les rendements observés — en conservant les queues marginales, en détruisant la chronologie. Le résultat est inconfortable et, nous le pensons, la chose la plus utile de l'article : l'asymétrie des sauts, qui paraît écrasante, ne survit pas ; la persistance et l'amplitude, si. Quiconque construit un indicateur de crise à partir d'une fonctionnelle convexe de moments estimés devrait faire tourner ce témoin avant de croire son propre graphique.

La section 4 énonce le théorème et les deux postulats et en dérive la dynamique de saut-diffusion ; la section 5 liste les hypothèses ; les sections 6–7 donnent les données, les estimateurs et les résultats, dont le témoin placebo que les statistiques de saut et de relaxation doivent franchir ; la section 8 construit le test de résistance ; la section 9 est honnête sur ce que rien de tout ceci n'établit.

2 Du flux d'ordres au prix gaussien : le pont volume

2.1 Le prix comme flux d'ordres accumulé

Sur $[t, t + \Delta]$, soit M le nombre de transactions exécutées, la transaction k portant le volume signé $\epsilon_k v_k$ avec $\epsilon_k \in \{-1, +1\}$ le sens (à l'initiative de l'acheteur ou du vendeur) et $v_k > 0$ la taille. Notons $V = \sum_k v_k$ le volume total et $Q = \sum_k \epsilon_k v_k$ le flux d'ordres signé net.

Hypothèse 1 (Impact linéaire). *Le log-prix répond linéairement au flux d'ordres signé net, $\Delta X_{t,\Delta} = X_{t+\Delta} - X_t = \lambda Q$, avec $\lambda > 0$ constant sur l'intervalle.*

C'est l'équilibre de Kyle (1985) : le teneur de marché, incapable de distinguer le flux informé du flux non informé, fixe une règle de prix linéaire et λ est l'inverse de la profondeur. C'est la définition du « prix comme fonction du volume échangé » dont a besoin le reste de la section, et c'est le maillon le plus faible de la chaîne ; la section 2.5 dit ce qui se passe quand il cède.

Hypothèse 2 (Signes échangeables et variance proportionnelle au volume). *Conditionnellement à V et à l'information disponible en t , la croyance du marché sur Q n'est contrainte que par ses deux premiers moments, avec $\mathbb{E}[Q | V] = m$ et $\text{Var}(Q | V) = \zeta^2 V$.*

La forme de la variance est celle qu'on obtient lorsque les signes des transactions sont échangeables à corrélation bornée et que les tailles ont une moyenne stable : pour des signes indépendants, $\text{Var}(Q) = \sum_k v_k^2 \approx \bar{v}V$. Le contenu économique est que *le volume, et non le temps, est la mesure naturelle de ce qui peut se produire.*

2.2 Maximum d'entropie en temps-volume

Proposition 1 (Maximum d'entropie sous contraintes de moments d'ordre un et deux). *Parmi les distributions absolument continues sur $\mathbb{R}^N$ de moyenne μ et de covariance $\Sigma \succ 0$, la gaussienne $\mathcal{N}(\mu, \Sigma)$ maximise de façon unique l'entropie différentielle, et $h^{\max}(\Sigma) = \frac{1}{2} \log((2\pi e)^N \det \Sigma)$.*

Démonstration. Soit $q = \mathcal{N}(\mu, \Sigma)$ et soit p de mêmes deux premiers moments et d'entropie différentielle finie. Comme $\log q$ est exactement quadratique, son espérance ne dépend que de ces moments, donc $\mathbb{E}_p[\log q] = \mathbb{E}_q[\log q] = -h(q)$. La positivité de l'entropie relative donne $0 \leq D_{KL}(p \| q) = -h(p) + h(q)$, d'où $h(p) \leq h(q)$, avec égalité si et seulement si $p = q$ presque partout. L'argument n'exige aucune différentiabilité de p ni l'existence préalable d'un maximiseur. $\square$

La voie variationnelle — un lagrangien sur les contraintes de normalisation, de moyenne et de covariance, dont la condition du premier ordre rend $\log p$ quadratique — explique *pourquoi* le maximiseur est gaussien, mais c'est l'argument par la divergence qui établit l'optimalité et l'unicité.

En appliquant la proposition 1 à l'hypothèse 2 en dimension un, puis en transportant par l'hypothèse 1 :

$$\Delta X_{t,\Delta} | V \sim \mathcal{N}(\lambda m, \lambda^2 \zeta^2 V). \quad (1)$$

L'équation (1) est le pont. Trois points méritent d'être soulignés.

D'abord, *la variable de conditionnement est le volume, pas le temps*. Le maximum d'entropie ne délivre pas une variance ; il délivre la distribution la moins engageante étant donné une variance. L'hypothèse 2 fournit cette variance à partir d'un observable, et cet observable est le volume échangé. L'équation (1) est l'hypothèse de mélange de distributions de Clark (1973) et Tauchen & Pitts (1983), obtenue ici comme un énoncé de maximum d'entropie plutôt que posée ; Ané & Geman

(2000) montrent empiriquement que les rendements mesurés en temps-transaction sont proches du gaussien alors que les rendements en temps calendaire ne le sont pas, ce qui est la prédiction de (1).

Ensuite, *la gaussianité est conditionnelle*. Inconditionnellement, ΔX est un mélange d'échelle de lois normales sur le volume aléatoire V , donc leptokurtique même si (1) est exacte. C'est le mécanisme de subordination de Mandelbrot & Taylor (1967), et cela signifie que les queues épaisses ne constituent pas à elles seules une preuve contre le maximum d'entropie.

Enfin, l'extension multivariée est immédiate : avec N actifs, $\Delta \mathbf{X} \mid V \sim \mathcal{N}(\mu V, \Sigma V)$, et la proposition 1 s'applique telle quelle.

2.3 Des incréments gaussiens au mouvement brownien puis au MBG

Soit $\theta_t = \int_0^t v_s ds$ l'horloge de volume cumulé. L'équation (1) donne la loi d'un incrément ; un processus demande davantage.

Hypothèse 3 (Cohérence temporelle). *Dans l'horloge de volume, les incréments sur des intervalles disjoints sont indépendants, les trajectoires sont continues, et la covariance d'un incrément est proportionnelle au volume écoulé.*

Sous l'hypothèse 3 à coefficients constants, il existe une matrice B telle que $BB^\top = \Sigma$ et $X_\theta = X_0 + \mu\theta + BW_\theta$ en temps-volume, donc en temps calendaire

$$X_t = X_0 + \mu\theta_t + BW_{\theta_t}, \quad (2)$$

un mouvement brownien *subordonné* à l'horloge de volume. Si l'intensité de négociation est constante, $\theta_t = \bar{v}t$ et (2) est un mouvement brownien ordinaire en temps calendaire ; en exponentiant et en appliquant Itô,

$$\frac{dS_{i,t}}{S_{i,t}} = (a_{i,t} + \frac{1}{2}\sigma_{i,t}^2) dt + \sigma_{i,t} dW_{i,t}, \quad (3)$$

de sorte que la dérive du prix n'est pas celle du log-prix — la même correction du second ordre qui reparaitra à la section 3 lorsqu'on différenciera $\log \det R_t$.

Il vaut la peine d'être précis sur ce que fait l'hypothèse 3. Par le théorème de Monroe (1978), toute martingale locale continue est un mouvement brownien changé de temps : la subordination seule n'a donc aucun contenu empirique. Le contenu est dans l'horloge : (1) dit que la bonne horloge est le volume, et l'hypothèse 3 dit que le marché est sans mémoire dans cette horloge. C'est le maximum d'entropie qui sélectionne le mouvement brownien dans la classe qu'autorise le théorème de Monroe.

2.4 La contraposée

La proposition 1 se lit dans les deux sens. Notons q_t la gaussienne de mêmes moyenne et covariance conditionnelles que p_t . Alors

$$\mathcal{D}_t \equiv h(q_t) - h(p_t) = D_{KL}(p_t \parallel q_t) \geq 0, \quad (4)$$

avec égalité si et seulement si p_t est gaussienne. Donc : *les prix sont non gaussiens exactement dans la mesure où leur distribution conditionnelle n'est pas d'entropie maximale*, et $\mathcal{D}_t$ mesure cette mesure. Dans le langage de la section 2, un $\mathcal{D}_t$ positif signifie que des contraintes au-delà des deux premiers moments sont actives — que quelqu'un sait quelque chose que le moment d'ordre deux n'encode pas.

Deux sources produisent un déficit positif, et les séparer importe. Une horloge de volume aléatoire produit un mélange d'échelle, symétrique et leptokurtique. Une information directionnelle contraignante produit de l'asymétrie. La section 3 scinde $\mathcal{D}$ exactement selon cette ligne.

2.5 Où le pont est faible

L'hypothèse 1 est linéaire ; l'impact empirique d'un métaordre est plus proche d'une racine carrée de la taille, ce qui rend concave l'application du flux au prix et la distribution de rendements induite moins épaisse en queue que le flux. L'hypothèse 2 traite les signes comme échangeables ; le flux d'ordres est en réalité fortement autocorrélé, ce qui gonfle $\text{Var}(Q)$ au-dessus de $\zeta^2 V$ et fait de l'horloge de volume un substitut imparfait de la variance. Aucune de ces défaillances ne change la *forme* de l'argument — le maximum d'entropie sous budget de variance reste gaussien — mais toutes deux signifient que l'horloge de volume est une approximation de l'horloge d'information plutôt que cette horloge même. Nous utilisons le raisonnement en temps-volume pour motiver le cadre et l'estimation en temps calendaire dans tout le travail empirique, de sorte qu'aucun résultat ci-dessous ne dépend de l'exactitude de (1).

3 Les trois canaux de l'entropie

3.1 Échelle et dépendance

Écrivons $\Sigma_t = D_t R_t D_t$ avec $D_t = \text{diag}(\sigma_{1,t}, \dots, \sigma_{N,t})$. Alors $\det \Sigma_t = \left(\prod_i \sigma_{i,t}^2 \right) \det R_t$ et

$$h(q_t) = \underbrace{\frac{N}{2} \log(2\pi e)}_{\text{constante}} + \underbrace{\sum_i \log \sigma_{i,t}}_{H_t^{\text{vol}}} + \underbrace{\frac{1}{2} \log \det R_t}_{H_t^{\text{dep}}}. \quad (5)$$

Par l'inégalité de Hadamard, $H_t^{\text{dep}} \leq 0$, avec égalité si et seulement si $R_t = I$: la *corrélation détruit toujours de l'entropie*, et $-H_t^{\text{dep}}$ est précisément la multi-information gaussienne (corrélation totale) du vecteur de rendements. Une lecture utile de la même quantité est spectrale : avec λ_k les valeurs propres de R_t et $\tilde{\lambda}_k = \lambda_k/N$, le nombre de participation $N_t^{\text{eff}} = \exp\left(-\sum_k \tilde{\lambda}_k \log \tilde{\lambda}_k\right)$ est le nombre effectif de modes de risque indépendants ; il vaut N pour $R = I$ et tend vers 1 lorsqu'un unique mode collectif absorbe la variance.

L'équation (5) est le plafond, pas l'entropie. C'est ce qu'implique la seule matrice de covariance, et la proposition 1 dit que la vérité se situe en dessous.

3.2 Forme : le déficit d'entropie et sa composition

En soustrayant (4) de (5) on obtient la décomposition de l'article, trois canaux et une constante :

$$h(p_t) = \frac{N}{2} \log(2\pi e) + \underbrace{H_t^{\text{vol}}}_{\text{échelle}} + \underbrace{H_t^{\text{dep}}}_{\text{dépendance}} - \underbrace{\mathcal{D}_t}_{\text{forme}}. \quad (6)$$

Le canal de forme, ce sont l'asymétrie et les queues épaisses, et le développement d'Edgeworth le dit explicitement : pour une variable standardisée d'asymétrie S et de kurtosis excédentaire K au voisinage de la gaussianité,

$$J \approx \frac{S^2}{12} + \frac{K^2}{48}. \quad (7)$$

L'équation (7) répond à la question « où un saut d'entropie serait-il visible ? » : dans les moments d'ordre trois et quatre, de manière additive, avec un canal d'asymétrie et un canal de queue. Elle est aussi la source du problème de signe que la section 4 doit résoudre, car S y entre au carré — la *néguentropie ne distingue pas un krach d'une envolée*. Comme estimateur, (7) est inutilisable sur des rendements quotidiens ; la section 6.2 documente à quel point et ce que nous utilisons à la place.

3.3 L'indice structurel

Le canal d'échelle est une nuisance pour notre propos : il domine numériquement le niveau de (6), il bouge avec la volatilité, et un changement d'unités le modifie. Les deux autres canaux sont sans échelle. En les combinant, et en utilisant la règle de chaînage exacte $D_{KL}(p \parallel \prod_i q_i) = \sum_i D_{KL}(p_i \parallel q_i) + I(x)$ où I est la multi-information :

Définition 1 (Indice d'information structurelle).

$$\mathcal{J}_t \equiv \mathcal{D}_t - H_t^{dep} = D_{KL}(p_t \parallel \prod_i q_{i,t}) \geq 0, \quad (8)$$

la divergence de la loi jointe conditionnelle des rendements à un produit de marginales gaussiennes de mêmes échelles.

$\mathcal{J}$ est nul si et seulement si les rendements sont indépendants et gaussiens ; il s'élève quand les actifs se couplent, quand les marginales s'épaississent ou quand elles s'asymétrisent. Il est mesuré en nats, il est invariant au niveau de volatilité, et il est additif sur ses deux canaux, de sorte qu'on peut toujours demander quelle part d'un mouvement vient de la dépendance et quelle part de la forme. C'est la variable d'état de la section 4.

4 Dynamique de l'information : un théorème, deux postulats

4.1 Les sauts vers le bas sont un théorème

Deux énoncés distincts sous-tendent la moitié descendante de la dynamique postulée. Les confondre est une erreur facile, et les versions antérieures de ce travail la commettaient ; nous les séparons donc explicitement.

Rappelons d'abord la définition de l'*information mutuelle* entre le vecteur de rendements X et un signal Y :

$$I(X; Y) = D_{KL}(p_{XY} \parallel p_X \otimes p_Y) = \iint p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dx dy, \quad (9)$$

c'est-à-dire la divergence de la loi jointe au produit des marginales : de combien la loi jointe s'écarte de l'indépendance. Elle est positive, symétrique, nulle si et seulement si $X \perp Y$, et — contrairement à h — invariante par reparamétrisation inversible. Pour un couple gaussien scalaire de corrélation ρ , $I = -\frac{1}{2} \log(1 - \rho^2)$.

Proposition 2 (Chute de l'entropie conditionnelle moyenne). *Soit X le vecteur de rendements et Y un signal. Alors*

$$\mathbb{E}_Y[h(X | Y)] = h(X) - I(X; Y) \leq h(X),$$

avec égalité si et seulement si $X \perp Y$.

Proposition 3 (Monotonie du plafond sous contrainte). *Soient $\mathcal{C} \subseteq \mathcal{C}'$ deux ensembles de contraintes et $\mathcal{Q}(\cdot)$ l'ensemble des lois qui les satisfont. Alors $\mathcal{Q}(\mathcal{C}') \subseteq \mathcal{Q}(\mathcal{C})$ et donc*

$$\sup_{p \in \mathcal{Q}(\mathcal{C}')} h(p) \leq \sup_{p \in \mathcal{Q}(\mathcal{C})} h(p).$$

Les deux résultats sont classiques (Cover & Thomas, 2006) et ne sont pas équivalents ; la démonstration détaillée et un exemple gaussien chiffré figurent en annexe E. Leurs portées diffèrent sur deux axes.

La proposition 2 *quantifie* la baisse — exactement $I(X;Y)$ nats — mais seulement *en moyenne* sur les réalisations du signal. Pour un y particulier, $h(X | Y = y)$ peut excéder $h(X)$: un signal suffisamment déroutant laisse le marché plus incertain qu’avant. Il faut donc s’attendre à une composante de saut principalement, et non exclusivement, unilatérale — ce que trouve la section 7.

La proposition 3 vaut au contraire *pour chaque réalisation*, mais porte sur le *plafond* de maximum d’entropie et non sur l’entropie réelle, et elle ne quantifie rien : elle dit que le plafond ne peut pas monter, pas de combien il descend.

Ce que les deux disent ensemble, et qui motive tout ce qui suit : la chute est *discontinue*, car le signal arrive en un point du temps, et sa taille espérée en nats est le contenu informationnel de la nouvelle — une amplitude mesurée sur une échelle qui ne dépend ni de l’actif, ni de la devise, ni des unités.

Une réserve d’honnêteté. Aucune de ces deux propositions n’est utilisée pour calculer quoi que ce soit dans la partie empirique. Nous mesurons $\mathcal{J}$, et non $h(X) - \mathbb{E}_Y[h(X | Y)]$: estimer une entropie différentielle en dimension 20 sur une fenêtre de 252 jours est hors de portée (annexe A). Le lien entre le théorème et les statistiques rapportées plus loin est un raisonnement, pas une identité estimée, et le lecteur doit le tenir pour tel.

4.2 Deux postulats

Postulat 1 (Relaxation). En l’absence d’information nouvelle, l’indice structurel décroît vers un niveau de long terme à taux constant : $d\mathcal{J}_t = -\kappa (\mathcal{J}_t - \bar{\mathcal{J}}) dt + \sigma_{\mathcal{J}} dW_t$ avec $\kappa > 0$.

L’économie derrière P1 est qu’une contrainte s’évante. La nouvelle est intégrée aux prix, le désaccord se reforme, les positions se dispersent, et la coupe transversale recouvre la liberté que le choc lui avait retirée. Rien dans la théorie de l’information ne délivre cela ; c’est l’hypothèse substantielle de l’article, et κ est l’objet à estimer.

Pourquoi un processus d’Ornstein–Uhlenbeck et pas autre chose ? Le choix n’est pas un choix de commodité : il est *forcé* dès qu’on impose trois exigences minimales, et il est le seul à les satisfaire toutes les trois.

1. *Markov*. L’avenir de $\mathcal{J}$ ne dépend du passé qu’à travers son niveau présent. C’est l’exigence de parcimonie : ne postuler aucune mémoire au-delà de ce que l’état courant contient déjà.
2. *Stationnaire*. $\mathcal{J}$ possède un niveau de long terme et une variance finis. Sans cela l’indice dérive, il n’est pas une variable d’état, et les comparaisons de régime de la section 7 n’ont pas de sens.
3. *Bruit gaussien*. Entre deux arrivées d’information, on ne prétend rien savoir du bruit au-delà de sa variance — c’est le principe de maximum d’entropie appliqué au bruit lui-même, exactement comme il l’a été aux rendements en section 2.

Le théorème de Doob (1942) énonce que **le processus d’Ornstein–Uhlenbeck est l’unique processus à la fois markovien, gaussien et stationnaire** en temps continu. Les trois exigences ne laissent donc aucune latitude sur la partie diffusive : elle est déterminée. Le terme de saut, lui, est ajouté précisément pour *briser* la gaussianité là où le cadre affirme qu’elle ne tient pas, c’est-à-dire aux arrivées d’information. La structure de (11) est ainsi un squelette imposé plus une composante délibérément non gaussienne, ce qui est exactement la classe introduite par Barndorff-Nielsen & Shephard (2001).

Ce qui, en revanche, reste arbitraire. Trois choses, qu’il faut énoncer plutôt que laisser croire qu’elles découlent du théorème. Le taux κ est supposé *constant* : rien n’interdit qu’une crise soit absorbée plus vite, ou plus lentement, qu’une nouvelle ordinaire, et les données employées ici ne permettent pas de trancher. Le rappel est *linéaire* en l’écart au niveau de long terme, alors qu’un rappel accéléré loin de la moyenne serait tout aussi plausible. Enfin, $\mathcal{J}$ est positif par construction alors qu’un Ornstein–Uhlenbeck muni d’un terme brownien peut devenir négatif : la spécification de Barndorff-Nielsen & Shephard (2001) évite cet écueil en supprimant le terme brownien et en pilotant le processus par un subordonateur à sauts positifs, ce qui garantit une loi stationnaire portée par $\mathbb{R}^+$. Empiriquement la question ne se pose pas — $\mathcal{J}$ reste compris entre 2,17 et 21,13 nats sur le panel principal et entre 0,42 et 1,69 sur le panel de réplcation, donc très loin de la frontière — mais formellement il faudrait soit supprimer $\sigma_{\mathcal{J}}$, soit écrire le processus sur $\log \mathcal{J}$.

Le postulat n’est enfin pas anodin sur le plan de la mesure : un estimateur doté de mémoire fabriquera une décroissance même en l’absence de toute relaxation économique, aussi la section 6.3 mesure-t-elle la décroissance qu’un monde sans mémoire produirait déjà.

Postulat 2 (Asymétrie de la contrainte). La contrainte qu’impose l’information est unilatérale dans la direction des pertes, de sorte qu’un saut d’entropie s’accompagne d’une asymétrie négative du facteur de marché.

Pourquoi ce postulat est logiquement nécessaire. L’indice $\mathcal{J}$ est une fonction *paire* de l’asymétrie : changer le signe de l’asymétrie ne change pas sa valeur. La raison est immédiate. Le canal de forme est $\mathcal{D}_1(z) = D_{KL}(p_z \parallel \varphi)$, et la loi normale φ est symétrique ; donc si l’on remplace z par $-z$, la loi de référence est inchangée et la divergence l’est aussi :

$$\mathcal{D}_1(-z) = \mathcal{D}_1(z), \quad \text{et par conséquent} \quad \mathcal{J}(-x) = \mathcal{J}(x). \quad (10)$$

Le développement d’Edgeworth (7) le rend visible à l’œil : l’asymétrie S y entre au carré.

La conséquence est structurelle et non anecdotique. **Une distribution à longue queue à gauche — un krach — et son image en miroir à longue queue à droite — une envolée — ont exactement le même $\mathcal{J}$.** L’indice mesure la *taille* de l’information, jamais son sens. Aucun raffinement de l’estimateur n’y changera quoi que ce soit : c’est une propriété de l’objet mesuré. Si l’article veut dire quoi que ce soit sur la direction, il doit donc ajouter un ingrédient extérieur. P2 est cet ingrédient, et c’est le plus petit possible : une seule affirmation, sur le signe, ajoutée à un cadre qui par construction n’en produit aucune.

Sur quoi il s’appuie. Non pas sur un mécanisme que nous affirmerions, mais sur une régularité empirique établie : l’*effet de levier* au sens de Black (1976), c’est-à-dire le fait que les rendements négatifs sont suivis de hausses de volatilité plus fortes que les rendements positifs de même amplitude. C’est l’un des faits stylisés les plus robustes de la finance empirique (Christie, 1982; Engle & Ng, 1993; Nelson, 1991). Traduit dans le langage de cet article : à quantité d’information égale, la réponse du marché est plus ample vers le bas que vers le haut, donc un saut de $\mathcal{J}$ arrive accompagné d’une asymétrie de marché négative.

Nous nous abstenons délibérément de choisir entre les explications causales concurrentes de cet effet — levier financier à proprement parler, rétroaction de la volatilité, ou retrait asymétrique de la liquidité du côté vendeur. Le postulat ne dépend d’aucune d’entre elles : il n’affirme que l’asymétrie, pas sa cause. Il est testable séparément (H5) et réfutable séparément, et la section 7 conclut d’ailleurs qu’il n’est pas établi.

4.3 La dynamique qui en résulte

La proposition 2 jointe à P1 donne un processus d’Ornstein–Uhlenbeck non gaussien à sauts unilatéraux, de la classe introduite par Barndorff-Nielsen & Shephard (2001) pour la volatilité stochastique :

$$d\mathcal{J}_t = -\kappa(\mathcal{J}_t - \bar{\mathcal{J}})dt + \sigma_{\mathcal{J}}dW_t + \int_{z>0} z\mathcal{P}(dt, dz), \quad (11)$$

Le terme intégral demande d’être lu avec soin, car sa notation est compacte.

Ce que $\mathcal{P}$ n’est pas. Ce n’est ni une loi gaussienne, ni une fonction. La lettre $\mathcal{N}$ est réservée dans cet article à la loi normale, et la mesure de saut porte donc un symbole distinct.

Ce que $\mathcal{P}$ est. Une *mesure aléatoire de comptage*, dite mesure aléatoire de Poisson. On peut se la représenter comme un semis aléatoire de points dans le plan (date, taille) : chaque point est un événement informationnel, son abscisse est la date à laquelle il survient et son ordonnée la taille du saut qu’il provoque. Formellement, $\mathcal{P}(dt, dz)$ vaut 1 s’il existe un saut dans l’intervalle de temps $[t, t + dt)$ dont la taille tombe dans $[z, z + dz)$, et 0 sinon. L’intégrale $\int_{z>0} z\mathcal{P}(dt, dz)$ se lit alors simplement : « s’il y a un saut à la date t , ajouter sa taille z à $\mathcal{J}$; sinon n’ajouter rien ». C’est une écriture condensée de $\sum_j z_j$, la somme des sauts survenus.

Ce qui la caractérise. Deux ingrédients, réunis dans sa *mesure d’intensité* $\nu(dz)dt$, qui est le nombre espéré de sauts de taille comprise entre z et $z + dz$ pendant dt : d’une part une *fréquence d’arrivée* $\lambda = \nu(\mathbb{R}^+)$, en nombre de sauts par unité de temps, d’autre part une *loi des tailles* $\nu(dz)/\lambda$. Sur le panel principal, la section 7 estime $\lambda \approx 5$ sauts par an, une taille moyenne de 0,62 nat et un maximum de 3,21 nats.

Ce qu’est z . La taille d’un saut individuel, exprimée en nats. Conceptuellement, c’est l’information mutuelle de la nouvelle qui l’a provoqué, au sens de la proposition 2. Opérationnellement, c’est la variation de $\mathcal{J}$ détectée par le filtre à quatre sigmas de la section 6.2. Les deux ne coïncident qu’approximativement, et le papier ne prétend pas les identifier.

Pourquoi l’intégrale ne porte que sur $z > 0$. Parce que $\mathcal{J}$ mesure un *déficit* d’entropie et que, par la proposition 2, l’information ne peut qu’accroître ce déficit en espérance. Dans ce cadre, rien ne crée d’*augmentation soudaine* d’entropie : l’entropie n’est restituée que par la relaxation lente du premier terme, jamais par un saut. D’où des sauts unilatéraux.

Deux réserves, toutefois. La proposition 2 est un énoncé *en moyenne* : une réalisation particulièrement déroutante peut accroître l’entropie, donc une spécification fidèle autoriserait une petite probabilité de sauts négatifs plutôt que de les interdire. Et la mesure de Poisson suppose des arrivées indépendantes, alors que l’étude d’événement de la section 7 montre un regroupement net des sauts ; un processus auto-excitant de type Hawkes serait plus fidèle.

Notons enfin que le coefficient de diffusion est noté $\sigma_{\mathcal{J}}$ et non η , cette dernière lettre étant réservée au rayon des scénarios de stress (section 8). Lu sur l’entropie elle-même plutôt que sur $\mathcal{J}$, le signe s’inverse : l’entropie chute par sauts et remonte par diffusion. Les prédictions observables sont nettes, et ce sont elles que teste la section 5 : la loi de $\Delta\mathcal{J}$ est asymétrique à droite ; les grands mouvements sont à la hausse et les petits à la baisse ; et après un saut positif l’indice décroît avec une demi-vie $\ln 2/\kappa$.

4.4 Pourquoi queues épaisses, corrélation et sauts arrivent ensemble

Le cadre produit une prédiction qu’aucun modèle de volatilité ni de corrélation ne produit seul. Elle se déduit en quatre pas, sans vocabulaire technique.

1. Une nouvelle importante concerne *tous* les actifs à la fois : c’est la même information qui contraint chacun d’eux.
2. Si la nouvelle est mauvaise, tous les actifs baissent donc *le même jour*.
3. Or ce jour-là apparaît aussi, pris isolément, dans l’historique de chaque actif : c’est pour lui une journée de perte inhabituellement grande.
4. Accumuler de telles journées déforme la distribution des rendements de chaque actif : le côté des pertes s’allonge et s’alourdit davantage que le côté des gains.

Le pas 2 est ce que mesure le canal de dépendance : les actifs bougent ensemble, la corrélation mesurée monte, $-H^{dep}$ monte. Le pas 4 est ce que mesure le canal de forme : des pertes extrêmes plus nombreuses et plus grandes que les gains extrêmes, c’est-à-dire un kurtosis plus élevé et une asymétrie négative, donc $\mathcal{D}$ monte. Les deux canaux montent ensemble parce qu’ils décrivent le même jour vu de deux endroits différents — la coupe transversale pour l’un, la distribution de chaque actif pour l’autre.

En marché calme, les mouvements marquants sont propres à chaque actif : ils n’alignent pas la coupe transversale et n’ont donc aucune raison de faire monter les deux canaux en même temps.

La forme testable est un *couplage dépendant du régime* : la corrélation entre $-\Delta H^{dep}$ et $\Delta \mathcal{D}$ devrait être proche de zéro en marché calme et fortement positive sous stress. C’est H6, et c’est là que se trouve la réponse de l’article à la question « le lien entre queues épaisses, corrélation et sauts d’entropie exige-t-il un postulat supplémentaire ? » : non. Étant donné la proposition 2, le couplage découle du caractère commun de la nouvelle. Seul le *signe* exige P2.

5 Hypothèses

H1 (signature de régime). En régime de stress, le canal de dépendance baisse ($H^{dep} \downarrow$), le canal de forme monte ($\mathcal{D} \uparrow$) et donc l’indice structurel monte ($\mathcal{J} \uparrow$).

H2 (compensation partielle). Les variations des deux canaux du plafond gaussien sont *de sens opposé et proportionnelles* : il existe un coefficient β tel que

$$\Delta H_t^{dep} = -\beta \Delta H_t^{vol} + u_t, \quad \mathbb{E}[u_t] = 0, \quad (12)$$

et l’hypothèse porte sur le *signe* : $\beta > 0$. Le coefficient β est le *taux de compensation* : la fraction d’un mouvement d’entropie d’échelle qui est absorbée par la dépendance. Il se lit directement — $\beta = 0$ signifie aucune compensation, $\beta = 1$ compensation totale et donc conservation de $\det \Sigma$, $0 < \beta < 1$ compensation partielle, $\beta < 0$ amplification. Une hypothèse secondaire porte sur les régimes : $\beta_{\text{stress}} > \beta_{\text{calme}}$.

Cette formulation remplace celle des versions antérieures de ce projet, qui affirmait d’un bloc que « H^{cov} est plus stable que ses composantes ». Cet énoncé mêlait deux affirmations distinctes — un signe et une magnitude — et ne se testait que de façon binaire. Le séparer permet de *rapporter* un coefficient avec son intervalle de confiance plutôt que de prononcer un verdict, et rend la comparaison entre jeux de données quantitative au lieu d’être contradictoire.

- H3 (asymétrie des sauts).** Les variations de $\mathcal{J}$ sont unilatérales : à seuil commun, les sauts positifs sont plus nombreux et plus lourds que les sauts négatifs, et $\Delta\mathcal{J}$ est asymétrique à droite — *au-delà de ce que le même estimateur produit sur des données de même loi marginale et sans structure temporelle*. Le qualificatif est toute l’hypothèse ; sans lui l’énoncé est intenable.
- H4 (relaxation).** $\mathcal{J}$ retourne à la moyenne avec $\kappa > 0$ et une demi-vie sensiblement plus longue que la mémoire de l’estimateur lui-même, jugée face au même témoin.
- H5 (signature d’asymétrie).** Les sauts positifs de $\mathcal{J}$ coïncident avec une asymétrie de marché négative et avec une hausse du canal d’asymétrie (postulat P2).
- H6 (couplage des canaux).** Les canaux de dépendance et de forme sont faiblement couplés en marché calme et fortement couplés sous stress.
- H7 (pouvoir prédictif).** Connaître l’entropie d’aujourd’hui dit quelque chose sur le risque des 21 prochains jours que la seule volatilité d’aujourd’hui ne dit pas déjà. Le mot « améliorer » s’entend exclusivement sur des dates que le modèle n’a jamais vues au moment de l’estimation ; la section 7.8 explicite le protocole.

6 Données et estimation

6.1 Jeux de données

Le panel principal réunit vingt composantes du S&P 500 à fréquence quotidienne, du 3 janvier 1990 au 28 décembre 2022 (8 312 jours de rendement ; 8 061 dates glissantes après une fenêtre de 252 jours), issues du jeu `sp500` distribué avec le paquet `skfolio`. Il s’agit de *titres individuels*, non de portefeuilles sectoriels. Ce choix est délibéré : agréger des firmes en secteurs impose mécaniquement une dépendance de facteur commun, et une version antérieure de ce projet citait une analyse sur titres individuels comme le test de robustesse dont elle avait le plus besoin. La période couvre les épisodes asiatique et LTCM de 1997–98, le krach des valeurs technologiques, la crise financière mondiale, la crise de la dette de la zone euro, 2015–16, 2018, la COVID-19 et la correction de 2022.

Le panel de réplication est `EuStockMarkets` (Bollerslev & Ghysels, 1996) : niveaux de clôture quotidiens du DAX, du SMI, du CAC et du FTSE, 1 860 jours de bourse contemporains de 1991 à 1998, $N = 4$. C’est un autre marché, une autre décennie et une autre taille de coupe transversale, ce qui en fait l’utilité ; il est bien trop petit pour porter seul un résultat.

Un lecteur ayant accès au fichier quotidien des 49 secteurs de Kenneth French peut reproduire chaque tableau dessus via `config/default.yaml` ; les résultats sectoriels cités ci-dessous à titre de comparaison proviennent de la version antérieure de ce projet.

6.2 Estimateurs

Covariance. Deux estimateurs tournent en parallèle. La référence est une fenêtre glissante de 252 jours avec rétrécissement de Ledoit–Wolf (Ledoit & Wolf, 2004), qui reproduit les statistiques de niveau de la version antérieure. L’estimateur réactif, utilisé pour tout ce qui touche aux sauts, est pondéré exponentiellement avec une demi-vie de 60 jours plus un rétrécissement de 10% vers la diagonale. Le choix compte : avec une fenêtre rectangulaire, une observation extrême qui *sort* de l’échantillon produit une discontinuité de la série d’entropie à une date où rien ne s’est passé, ce qui contaminerait tout test de saut. Les pondérations exponentielles suppriment cet artefact par construction.

Néguentropie. Le canal de forme est estimé marginalement, actif par actif, au moyen de l’approximation à contraste borné de Hyvärinen (1998), dont les deux termes se scindent naturellement en un canal impair (asymétrie) et un canal pair (poids de queue). La forme d’Edgeworth (7) n’est conservée que pour l’interprétation, car elle échoue gravement comme estimateur exactement là où vivent les données financières. Le tableau 1 rend cet échec explicite face à une référence non paramétrique.

Loi	S	K	J (Vasicek)	J Edgeworth	J Hyvärinen
Gaussienne	−0,00	0,03	0,012	0,000	0,000
Uniforme	0,00	−1,20	0,179	0,030	0,065
Normale asym. ($a = -4$)	−0,80	0,67	0,074	0,062	0,049
Laplace	−0,01	2,95	0,087	0,181	0,087
Student $t(8)$	−0,02	1,63	0,030	0,056	0,016
Student $t(5)$	0,10	5,13	0,061	0,549	0,052
Student $t(4)$	−0,00	18,34	0,102	7,006	0,105
Lognormale ($s = 0,5$)	1,76	5,78	0,203	0,954	0,167
Exponentielle	2,00	6,11	0,424	1,112	0,268

TABLE 1 – Néguentropie marginale en nats, $n = 200\,000$ tirages. La référence est l’estimateur d’entropie différentielle par espacements de Vasicek. La forme d’Edgeworth $S^2/12 + K^2/48$ surestime une Student- $t(4)$ d’un facteur 69 ; l’approximation de Hyvärinen y est à 3% de la vérité. Les rendements quotidiens d’actions se situent en plein dans la région $t(4)$ – $t(5)$, raison pour laquelle tous les déficits rapportés ci-dessous emploient la seconde. Reproduit par `scripts/negentropy_benchmark.py`.

Deux limites méritent d’être énoncées plutôt qu’enfouies. Estimer les déficits marginaux puis ajouter le terme de dépendance linéaire capture la non-gaussianité marginale et la dépendance de copule gaussienne, mais omet la dépendance de queue non linéaire ; nous la mesurons séparément par un taux moyen de co-dépassement par paires. Et l’approximation de Hyvärinen, précise dans la région leptokurtique, sous-estime d’environ la moitié la néguentropie d’une $t(8)$ modérément épaisse, de sorte que les niveaux rapportés ci-dessous sont conservateurs.

Détection des sauts. Un saut de $\mathcal{J}$ est signalé lorsque $|\Delta\mathcal{J}_t|$ dépasse quatre fois une échelle locale glissante construite sur la variation bipuissance (Barndorff-Nielsen & Shephard, 2004), laquelle est convergente pour l’échelle diffusive même en présence de sauts et est décalée d’un jour afin que le seuil jugeant une date ne la contienne jamais.

Inférence. Une fenêtre glissante de 252 jours fait que deux observations consécutives partagent 251 des 252 jours de rendement sous-jacents. Toute comparaison de régime emploie donc un bootstrap par blocs circulaires de 252 jours, sous une hypothèse nulle qui rompt le lien valeur–étiquette tout en préservant la persistance de la série et le regroupement de l’indicateur de régime. Les comparaisons prédictives utilisent une estimation en validation glissante à fenêtre croissante réajustée annuellement, une évaluation sur dates non chevauchantes, et un test de Diebold–Mariano (Diebold & Mariano, 1995) sur le différentiel d’erreur quadratique.

6.3 Le témoin placebo

L’indice structurel est une fonctionnelle convexe positive de moments d’ordre deux, trois et quatre estimés. Le seul bruit d’estimation le pousse *vers le haut* brutalement et le laisse décroître *en douceur* — ce qui est exactement la signature que prédit (11). Une statistique d’asymétrie de

sauts ou une demi-vie de relaxation n'est donc une preuve que relativement à ce témoin mécanique, jamais relativement à zéro.

Nous mesurons ce témoin de deux manières. D'abord une simulation contrôlée (`scripts/estimator_memory.py`) des rendements gaussiens i.i.d. à covariance constante — un monde sans aucune dynamique — passés dans la chaîne de production. Une unique journée de stress injectée produit un pic de 2,13 nats sur $\mathcal{J}$ qui décroît avec une demi-vie de **35 jours de bourse**, purement par la mémoire de l'estimateur ; sur données propres et sans aucun événement, le détecteur à quatre sigmas signale **37 sauts positifs et zéro saut négatif** et $\Delta\mathcal{J}$ a une asymétrie de +2,9. L'asymétrie mécanique est réelle et elle est grande.

Ensuite, deux témoins calibrés (`scripts/placebo_null.py`) qui rééchantillonnent les lignes de la matrice de rendements observée, en préservant la dépendance transversale et les queues marginales épaisses des données réelles. La version i.i.d. détruit tout ce dont traitent les postulats — regroupement de volatilité, dépendance variable dans le temps, dynamique d'arrivée de l'information. La version par blocs rééchantillonne des blocs de 21 jours, de sorte que le regroupement de court terme survit et que seules les dynamiques de régime à plus long horizon sont détruites. Vingt réplifications de chacune donnent les lois nulles rapportées au tableau 2. Toutes deux appliquent le filtre de volatilité identique pour définir les régimes de stress, de sorte que les comparaisons de régime de H1, H2 et H6 sont testées sur le même pied qu'elles sont estimées.

7 Résultats

7.1 Ce que le témoin calibré laisse debout

Le tableau 2 est le résultat empirique central de l'article et il est inconfortable. Deux témoins sont construits, tous deux en rééchantillonnant la matrice de rendements observée et en faisant tourner la chaîne identique — filtre de volatilité définissant le régime de stress compris — vingt fois chacun.

Le témoin i.i.d. rééchantillonne les lignes indépendamment. Il conserve les queues marginales épaisses et la dépendance transversale et détruit *toute* structure temporelle. Il demande : au-delà du fait que les fenêtres turbulentes contiennent de gros rendements, la mesure détecte-t-elle quelque chose ?

Le témoin par blocs rééchantillonne des blocs circulaires de 21 jours. Il conserve en outre le regroupement de volatilité de court terme et ne détruit que les dynamiques de régime à plus long horizon. Il pose la question plus dure : au-delà du regroupement, la mesure détecte-t-elle une dynamique de l'information ?

Aucun des deux témoins n'est emboîté dans l'autre d'une manière qui rendrait l'un uniformément conservateur, et ils se contredisent assez souvent pour qu'en rapporter un seul soit trompeur. Une statistique qui franchit les deux est une preuve ; une statistique qui en franchit un et échoue à l'autre n'est pas identifiée.

Ce qui franchit les deux témoins. Deux choses, et deux seulement. L'écart de régime du canal de *dépendance* : $-1,72$ nats contre $-0,29$ et $-0,64$, hors de chacune des quarante réplifications. Et l'*étendue* de l'indice structurel : $18,95$ nats contre $10,49$ et $14,23$. Autrement dit : ce qui sépare une crise d'une simple série de gros rendements, c'est que la coupe transversale se couple, et l'indice structurel voyage plus loin en marché réel que dans tout rééchantillonnage des mêmes rendements.

Statistique		Obs.	témoin i.i.d.		témoin blocs-21		Verdict
			moy.	5-95 %	moy.	5-95 %	
H1	écart H^{dep}	-1,72	-0,29	-0,46-0,14	-0,64	-1,14-0,37	franchit les deux
H1	écart $\mathcal{J}$	2,89	2,32	1,76-2,74	2,21	1,51-3,02	i.i.d. seulement
H1	écart $\mathcal{D}$	0,48	1,35	0,98-1,64	0,74	0,30-1,13	échoue aux deux
H2	$\text{corr}(\Delta H^{vol}, \Delta H^{dep})$	0,10	0,14	-0,29-0,47	0,16	-0,23-0,57	échoue aux deux
H3	sauts positifs	158	147,7	139-157	129,5	117-148	blocs seulement
H3	sauts négatifs	9	3,2	2-5	4,2	0-7	<i>plus</i> que les deux
H3	saut positif moyen (nats)	0,62	1,17	0,97-1,32	0,91	0,73-1,06	inférieur aux deux
H3	asymétrie de $\Delta\mathcal{J}$	12,26	14,55	12,0-16,9	13,80	10,6-18,8	échoue aux deux
H3	part de var. sauts pos.	0,838	0,904	0,87-0,92	0,828	0,77-0,87	échoue aux deux
H4	demi-vie (jours)	120,1	91,7	82-111	161,6	122-200	<i>signes opposés</i>
H4	$\text{sd}(\mathcal{J})$	2,03	1,61	1,38-1,92	2,17	1,45-2,78	i.i.d. seulement
H4	tendue($\mathcal{J}$)	18,95	10,49	8,4-12,3	14,23	10,0-17,9	franchit les deux
H5	écart ΔS_{mkt}	-0,053	-0,025	-0,100-0,040	-0,001	-0,051-0,081	limite (blocs)
H5	$\text{corr}(\Delta\mathcal{J}, \Delta S_{mkt})$	-0,243	-0,067	-0,247-0,160	-0,013	-0,239-0,293	limite (les deux)
H6	couplage, stress	0,66	0,90	0,86-0,93	0,76	0,63-0,83	échoue aux deux
H6	écart de couplage	0,617	0,746	0,64-0,88	0,667	0,54-0,75	échoue aux deux
-	$\text{corr}(\mathcal{J}, \log \text{vol})$	0,461	0,414	0,36-0,46	0,265	0,18-0,33	—

TABLE 2 – Statistiques observées face à deux témoins calibrés, vingt réplifications chacun. « Franchit les deux » signifie que la valeur observée se situe hors des quarante réplifications du côté prédit par l’hypothèse. Les écarts sont stress moins calme. Noter que plusieurs statistiques sont *plus grandes* dans un témoin que dans les données.

Ce qui ne franchit pas. L’asymétrie des sauts échoue franchement au témoin i.i.d. (H3). Le couplage des canaux échoue aux deux, et échoue dans la direction qui compte : les témoins couplent *plus* fortement que les données (H6). Le signal de régime du canal de forme est plus petit que celui des deux témoins. L’hypothèse de compensation se perd dans le bruit propre des témoins (H2).

Ce qui n’est pas identifié. La demi-vie de relaxation est de 120 jours contre 92 sous le témoin i.i.d. et 162 sous le témoin par blocs — les données se situent *entre* les deux, et le signe de la comparaison s’inverse. Le rééchantillonnage par blocs concatène parfois des blocs de forte volatilité et fabrique de longues excursions ; le rééchantillonnage i.i.d. en fabrique de courtes. La conclusion honnête est que le niveau de la demi-vie est un artefact du témoin qu’on choisit de croire, et que P1 est soutenu par le résultat d’amplitude plutôt que par la demi-vie. La signature d’asymétrie (H5) se situe au cinquième centile des deux témoins avec le bon signe, ce qui est suggestif et pas davantage.

Une remarque sur $\mathcal{J}$ et la volatilité. Sous le témoin par blocs, la corrélation entre $\mathcal{J}$ et la log-volatilité est de 0,27 ; dans les données elle est de 0,46. L’indice structurel suit la volatilité *de plus près* qu’un processus à seul regroupement, et non de moins près. Le tableau 6 montre que le canal de forme reste pourtant orthogonal à la volatilité : le suivi supplémentaire passe donc par le canal de dépendance — corrélation et volatilité bougent véritablement ensemble d’une manière que le seul regroupement ne reproduit pas.

Et une chose que rien de tout ceci n’atteint. La construction de test de résistance de la section 8 est une convention de mesure plus une optimisation convexe. Elle ne repose sur la véracité

d’aucune de H1–H7.

7.2 H1 : la signature de régime

Le tableau 3 compare le décile supérieur de la volatilité de marché glissante à 21 jours (807 dates) au reste (7 254). Les p -valeurs de bootstrap par blocs résument en une ligne une hypothèse nulle dans laquelle l’étiquette de régime ne porte aucune information sur le niveau.

Canal	Stress	Calme	Différence	p
H^{vol} (échelle)	−75,51	−80,98	+5,47	< 0,001
H^{dep} (dépendance)	−5,12	−3,40	−1,72	0,001
H^{cov} (plafond gaussien)	−80,63	−84,37	+3,75	0,013
$\mathcal{D}$ (forme)	1,96	1,48	+0,48	0,033
canal d’asymétrie	0,121	0,112	+0,009	0,449
canal de queue	1,837	1,364	+0,473	0,036
$\mathcal{J}$ (indice structurel)	8,02	5,13	+2,89	< 0,001
corrélation moyenne par paires	0,357	0,251	+0,106	0,001
nombre effectif de modes	10,50	13,20	−2,70	0,001
taux de co-dépassement de queue	0,305	0,219	+0,086	0,002
asymétrie de marché	−0,188	−0,221	+0,033	0,671
kurtosis excédentaire de marché	2,39	1,67	+0,72	0,141

TABLE 3 – H1 : moyennes des canaux par régime, actions individuelles du S&P 500, 1990–2022. Entropies en nats.

Tous les signes sont ceux que prédit H1. L’entropie de dépendance chute de 1,72 nats, le nombre effectif de modes de risque indépendants passe de 13,2 à 10,5 sur 20, le déficit de forme monte de 0,48 nat, et l’indice structurel monte de 2,89 nats — une hausse de 56%, la différence la plus significative du tableau. Le panel de réplification concorde sur chaque signe, $\mathcal{J}$ passant de 0,89 à 1,23 nat ($p < 0,001$).

Face au témoin calibré, l’hypothèse se scinde en deux. Le canal de *dépendance* porte un signal réel : l’écart de régime observé de −1,72 nats vaut environ six fois le −0,29 du témoin et se situe hors des vingt réplifications. C’est également le cas de l’écart sur $\mathcal{J}$ lui-même, mais d’une marge bien plus étroite (2,89 contre une moyenne de 2,32 sous le témoin). Le canal de *forme*, lui, non : son écart de régime observé de +0,48 nat est inférieur au +1,35 du témoin. Des données mélangées, où une fenêtre de « stress » est par construction une fenêtre contenant des rendements extrêmes isolés, épaississent les marginales mesurées davantage que ne le font les vrais épisodes de stress. La hausse de $\mathcal{D}$ sous stress n’est donc pas la preuve de quoi que ce soit au-delà de la présence de gros rendements.

La partie économiquement significative de H1 est ainsi plus étroite que le tableau brut ne le suggère, et c’est celle qu’on souhaiterait : ce qui distingue une vraie crise d’une série de gros rendements, c’est que *la coupe transversale se couple* — le nombre effectif de facteurs de risque indépendants s’effondre — et non que les marginales s’épaississent.

Deux entrées du tableau sont aussi instructives que les confirmations. Le *niveau* d’asymétrie de marché bouge à peine entre régimes ($p = 0,67$) : le stress n’est pas un état dans lequel les rendements sont durablement plus asymétriques à gauche, point sur lequel nous revenons avec H5, où la signature d’asymétrie apparaît au moment du saut plutôt que tout au long du régime. Et le plafond gaussien H^{cov} monte sous stress, de 3,75 nats — parce que le canal d’échelle le domine. L’entropie différentielle calculée à partir d’une matrice de covariance *augmente* en crise. Toute

tentative d'utiliser le niveau d'entropie gaussienne comme indicateur de stress a donc le signe à l'envers ; c'est précisément pourquoi l'article travaille avec le $\mathcal{J}$ sans échelle.

7.3 H2 : la compensation est réelle, partielle, et confinée au stress

Une version antérieure de ce projet, sur les 49 portefeuilles sectoriels de Fama–French, trouvait $\text{corr}(\Delta H^{vol}, \Delta H^{dep}) = -0,63$ sur 1990–2026 et une réduction de 57% de la variance de ΔH^{cov} : volatilité marginale et dépendance se compensaient au point de laisser le déterminant de covariance nettement plus stable que l'une ou l'autre composante. Sous la formulation binaire d'alors, ce résultat ne se répliquait pas sur titres individuels et l'affaire s'arrêtait là. L'estimation de (12) dit quelque chose de plus précis.

Taux de compensation $\hat{\beta}$ (IC 95 %)	Tout	Calme	Stress
S&P 500, 20 titres individuels	−0,06 (−0,32; +0,19)	−0,19 (−0,49; +0,11)	+0,19 (+0,07; +0,32)
EuStockMarkets, 4 indices	+0,11 (−0,14; +0,36)	+0,06 (−0,19; +0,31)	+0,36 (+0,29; +0,42)
R^2 de (12), S&P 500	0,01	0,08	0,16
R^2 de (12), EuStock	0,05	0,02	0,45
Rappel, portefeuilles sectoriels FF49 (version antérieure) : $\text{corr} = -0,63$ toutes dates ; β non disponible.			

TABLE 4 – H2 : taux de compensation β estimé par (12), écarts types HAC à 21 retards. $\beta > 0$ signifie que les deux canaux varient en sens opposé. Les valeurs en gras sont significativement positives.

Trois lectures, que la formulation binaire empêchait.

Le signe. Hors régime de stress, β n'est distinguable de zéro sur aucun des deux panels : les intervalles de confiance contiennent 0, et sur le S&P 500 le point estimé est même légèrement négatif, c'est-à-dire une amplification plutôt qu'une compensation. **En régime de stress, en revanche, β est significativement positif sur les deux jeux de données, +0,19 et +0,36, avec des intervalles nettement séparés de zéro.** H2 est donc soutenue en tant qu'hypothèse conditionnelle au régime, et rejetée en tant qu'hypothèse inconditionnelle. C'est précisément ce que $\beta_{\text{stress}} > \beta_{\text{calme}}$ prédisait.

La magnitude. Elle est modeste. Un β de 0,2 à 0,35 signifie qu'entre un cinquième et un tiers seulement d'un mouvement d'entropie d'échelle est absorbé par la dépendance ; le reste passe dans le plafond. On est loin du $\beta = 1$ qu'exigerait une véritable « conservation du volume de covariance ». L'ancienne formulation, en parlant de stabilité du plafond, suggérait implicitement β proche de 1 : c'était trop fort même là où le phénomène existe.

La qualité de l'ajustement. Le R^2 de (12) passe de 0,01 à 0,16 sur le S&P 500 et de 0,05 à 0,45 sur les indices européens lorsqu'on restreint au stress. La relation linéaire postulée n'est pas seulement de bon signe sous stress, elle y est aussi nettement mieux définie.

Deux réserves. D'abord, les écarts types HAC restent optimistes sur des fenêtres glissantes qui partagent 251 de leurs 252 jours ; les intervalles du tableau 4 sont à lire comme indicatifs. Ensuite et surtout, β n'a pas encore été confronté aux témoins calibrés de la section 7.1 : le tableau 2 teste la corrélation, pas la pente. Rien n'exclut qu'un rééchantillonnage produise lui aussi un β positif en régime de stress, pour la même raison mécanique qui lui fait reproduire H6 — les fenêtres turbulentes contiennent de grosses journées communes. **Tant que ce test n'est pas fait, H2 sous sa forme**

(12) **est une régularité mesurée, pas un résultat établi.** L'ajout de β aux statistiques de `scripts/placebo_null.py` est la prochaine étape.

Ce que cela ne change pas. La conséquence qui a motivé la section 3 demeure : avec β de l'ordre de 0,2 hors crise et un plafond gaussien qui monte avec la volatilité, le contenu informationnel d'une crise ne se lit pas dans $\det \Sigma$. C'est bien ailleurs qu'il faut le chercher.

7.4 H3 : la composante de saut est unilatérale

Pris au pied de la lettre, les indices semblent écrasants. Sur le panel principal, le détecteur à quatre sigmas trouve 158 sauts positifs contre 9 sauts négatifs ; les sauts positifs portent 83,8% de la variance de $\Delta \mathcal{J}$ contre 0,3% pour les sauts négatifs ; l'asymétrie de $\Delta \mathcal{J}$ vaut +12,3. Le panel de réplcation concorde (27 contre 5, asymétrie +6,7). La figure 1 est visiblement en dents de scie, avec des hausses brutales en 1997–98, 2002, septembre 2008, 2011, 2015, 2018 et un pic à 21 nats en mars 2020, chacune suivie d'une lente décroissance — exactement la forme que prédit (11).

L'asymétrie ne survit pas au témoin i.i.d. Sous ce témoin, le détecteur trouve *en moyenne 148 sauts positifs et 3 sauts négatifs*, avec une asymétrie de $\Delta \mathcal{J}$ de +14,6 — supérieure au +12,3 observé — et une part de variance des sauts positifs de 90%, là encore supérieure à l'observé. Chaque statistique d'unilatéralité des données se situe au bord ou à l'intérieur de ce témoin.

Le témoin par blocs est plus clément sur un point et pas sur les autres. Préserver le regroupement de volatilité abaisse le nombre de sauts positifs du témoin à 129,5, de sorte que le 158 observé se situe bien au-delà ; mais l'asymétrie de $\Delta \mathcal{J}$ (13,8) et la part de variance des sauts positifs (0,83) encadrent toujours les valeurs observées, et le saut positif moyen reste plus grand dans le témoin que dans les données. Un décompte qui franchit un témoin tandis que toutes les mesures de la *forme* de l'asymétrie échouent aux deux n'est pas un résultat. H3 n'est **pas soutenue**.

L'explication n'est pas subtile une fois énoncée. $\mathcal{J}$ est une fonctionnelle convexe positive de moments estimés d'ordre deux, trois et quatre. Une seule observation à queue épaisse entrant dans un estimateur pondéré exponentiellement le pousse brutalement vers le haut, et la mémoire propre de l'estimateur le laisse ensuite décroître en douceur. Les dynamiques en dents de scie sont ce que produit une loi marginale à queue épaisse passée dans cet appareil de mesure, que l'information arrive ou non par paquets. L'attrait visuel de la figure 1 est, dans cette mesure, un artefact.

Deux éléments méritent d'être sauvés. D'abord, le témoin est exigeant et sans doute trop exigeant pour le postulat tel qu'énoncé : parce que le rééchantillonnage i.i.d. préserve les queues épaisses, il préserve les *paquets* d'information et n'en brouille que la chronologie. Ce que le test rejette n'est donc pas « l'information arrive par lots discrets » mais l'affirmation plus faible et plus utile que *l'unilatéralité observée de $\Delta \mathcal{J}$ porte une information sur la dynamique d'arrivée au-delà de ce qu'implique déjà la loi marginale*. Elle n'en porte pas.

Ensuite, une comparaison du tableau 2 va dans l'autre sens et est instructive. Le plus grand saut positif observé vaut 3,21 nats contre une moyenne de 7,19 sous le témoin, et le saut positif moyen 0,62 contre 1,17 : les vrais sauts d'entropie font environ *la moitié* de la taille que produit le monde mélangé. La raison en est que les vraies journées extrêmes arrivent quand le marché est déjà agité, de sorte que l'échelle locale à laquelle on les mesure est déjà élevée ; dans le monde mélangé elles surgissent d'une ligne de base calme et paraissent d'autant plus surprenantes. C'est le regroupement de volatilité qui apparaît dans la mesure d'entropie — une preuve de structure temporelle, obtenue d'une statistique construite pour tester tout autre chose.




FIGURE 1 – L’indice structurel $\mathcal{J}_t$ sur vingt actions du S&P 500, 1990–2022, avec les sauts détectés. Les points rouges sont les sauts positifs, destructeurs d’entropie, les points bleus les sauts négatifs. La dent de scie — montée brutale, décroissance lente — est le contenu qualitatif de (11).




FIGURE 2 – Distribution de $\Delta\mathcal{J}_t$ standardisé (effectifs en échelle logarithmique). La queue droite s’étend bien au-delà de la gauche.

7.5 H4 : la relaxation, face à la mémoire propre de l'estimateur

L'estimation de (11) sur les seules dates hors saut — afin que le canal diffusif soit identifié sans contamination — donne $\kappa = 0,0058$ par jour ($t = -3,75$, HAC, $p = 0,0002$), une demi-vie de **120 jours de bourse** et un niveau de long terme de 3,34 nats. Le panel de réplication donne $\kappa = 0,0050$, une demi-vie de 139 jours, $p = 0,023$.

La demi-vie est l'endroit où les deux témoins divergent le plus nettement, et cette divergence est instructive. Sous rééchantillonnage i.i.d., le même estimateur renvoie 91,7 jours en moyenne, de sorte que le 120,1 observé dépasse chaque réplication. Sous rééchantillonnage par blocs, il renvoie 161,6 jours, de sorte que la valeur observée tombe *en dessous* de chaque réplication. Les données se situent entre les deux témoins, et le signe de la comparaison dépend entièrement de celui qu'on interroge. Le rééchantillonnage par blocs concatène parfois des blocs de forte volatilité et fabrique de longues excursions ; le rééchantillonnage i.i.d. brise les séries que contiennent les marchés réels et en fabrique de courtes. Le niveau de la demi-vie n'est donc **pas identifié**, et le chiffre de 120 jours ne doit pas se lire comme un temps d'absorption — la simulation gaussienne contrôlée de la section 6.3, où un choc unique décroît en 35 jours sans aucune économie, fixe le plancher de ce qui relève de la mémoire de l'estimateur.

Ce qui survit, c'est l'*amplitude*. L'étendue de $\mathcal{J}$ sur l'échantillon vaut 18,95 nats contre 10,49 sous le témoin i.i.d. et 14,23 sous le témoin par blocs, hors des quarante réplifications. Son écart type franchit le témoin i.i.d. (2,03 contre 1,61) mais pas celui par blocs. Les marchés réels déplacent l'indice structurel plus loin que ne le fait aucun rééchantillonnage des mêmes rendements, ce qui est la part de P1 que les données soutiennent : non pas un taux de relaxation particulier, mais une variable d'état qui voyage véritablement.

La figure 3 ajoute une réserve que l'estimation ponctuelle masque. En moyennant l'indice autour des sauts positifs détectés, on voit que $\mathcal{J}$ commence à monter une vingtaine de jours *avant* la date signalée, culmine environ treize jours après, et revient au niveau pré-événement au bout de quatre-vingts jours environ. Les événements informationnels se regroupent : un saut signalé n'est typiquement pas une arrivée isolée mais l'un des éléments d'une séquence. L'image propre d'un saut unique suivi d'une décroissance donnée par (11) est donc une idéalisation, et un processus d'arrivée auto-excitant de type Hawkes s'ajusterait mieux au regroupement observé que les arrivées poissonniennes supposées ici.

7.6 H5 : les sauts portent un signe

Le postulat P2 prédit que les sauts positifs s'accompagnent d'une asymétrie de marché négative. Aux dates de saut positif, la variation d'asymétrie de marché vaut en moyenne $-0,052$ contre $+0,001$ ailleurs ; le niveau d'asymétrie de marché à ces dates est de $-0,394$ contre $-0,214$; et $\text{corr}(\Delta\mathcal{J}, \Delta S_{mkt}) = -0,24$. Le canal d'asymétrie du déficit monte aux dates de saut ($+0,010$ contre $-0,0002$), de même que le co-dépassement de queue ($+0,008$ contre $-0,0002$, corrélation avec $\Delta\mathcal{J}$ de $+0,35$). Le panel de réplication est plus fort sur cette dimension : $\text{corr}(\Delta\mathcal{J}, \Delta S_{mkt}) = -0,38$ et une variation moyenne d'asymétrie de $-0,129$ aux dates de saut positif.

La réserve déjà visible au tableau 3 est que la signature d'asymétrie est une propriété d'*événement*, non de régime : trier les dates par volatilité ne révèle aucune différence significative d'asymétrie, les trier par saut d'entropie, si.

Face aux témoins, H5 est suggestive et rien de plus. Tous deux produisent l'effet dans la même direction sans aucune économie, car le lien mécanique est évident une fois énoncé : un gros rendement négatif élève simultanément $\mathcal{J}$ et abaisse l'asymétrie mesurée de la fenêtre dans laquelle il entre. La corrélation observée de $-0,243$ se situe à peu près au cinquième centile des deux témoins ($-0,067$




FIGURE 3 – Trajectoire moyenne de $\mathcal{J}_t$ autour des sauts positifs détectés, recentrée à la date de l'événement, avec la bande interquartile. La montée avant le jour zéro est le regroupement des sauts.

i.i.d., $-0,013$ blocs), et la variation moyenne d'asymétrie aux dates de saut fait de même sous le témoin par blocs tout en restant bien à l'intérieur du témoin i.i.d. Nous rapportons H5 comme *non établie* : la direction est la bonne, elle est cohérente sur deux témoins et deux jeux de données (le panel de réplication donne $-0,38$), mais une p -valeur de 0,05 à 0,10 sur vingt réplifications est une raison de chercher davantage, non un résultat. Le postulat P2 reste un postulat.

7.7 H6 : les canaux se verrouillent sous stress

$\text{corr}(-\Delta H^{dep}, \cdot)$	Tout	Calme	Stress
S&P 500 : avec $\Delta\mathcal{D}$ (forme)	0,34	0,04	0,66
S&P 500 : avec le canal de queue	0,34	0,03	0,68
S&P 500 : avec le canal d'asymétrie	0,06	0,15	-0,01
EuStock : avec $\Delta\mathcal{D}$	0,23	0,05	0,54

TABLE 5 – H6 : couplage entre les deux canaux destructeurs d'entropie, par régime.

Dans les données, le motif est frappant. En marché calme, le canal de dépendance et le canal de queue sont effectivement sans lien (0,03) ; sous stress leur corrélation vaut 0,68. Le panel de réplication le reproduit à 0,05 contre 0,54, et le couplage est porté entièrement par le canal de *queue*, le canal d'asymétrie n'y participant pas.

Les deux témoins le reproduisent aussi, et tous deux le reproduisent *plus fortement* que les données : un couplage sous stress de 0,90 (i.i.d.) et 0,76 (blocs) contre le 0,66 observé, et un écart stress-moins-calme de 0,75 et 0,67 contre le 0,62 observé. Le mécanisme est mécanique plutôt qu'économique. Une fenêtre contenant un gros rendement commun présente à la fois une corrélation mesurée plus élevée et des marginales mesurées plus épaisses, de sorte que les deux canaux bougent ensemble dans toutes données où existent de grosses journées, mélangées ou non. H6 n'est **pas soutenue** comme preuve d'une contrainte commune contraignante.

L'ajout du témoin par blocs change toutefois l'interprétation de l'écart entre témoin et données. Sous rééchantillonnage i.i.d., le couplage du témoin est quasi déterministe (0,90, écart type 0,03) ;

préserver le regroupement l'abaisse à 0,76 avec un écart type de 0,07, plus proche mais toujours au-dessus du 0,66 observé. Les vrais épisodes de stress couplent les deux canaux *moins* étroitement que l'un ou l'autre témoin. Si ce n'est pas du bruit, cela pointe à l'opposé de la section 4 : dépendance et poids de queue auraient des moteurs partiellement indépendants dans les vraies crises, ce qu'un récit de contrainte commune ne prédit pas.

Sur l'échantillon complet, la variance de $\Delta\mathcal{J}$ se répartit à 40% pour la dépendance et 60% pour la forme sur titres individuels, et à 58%/42% en sens inverse sur le panel à quatre indices — un rappel que l'équilibre entre canaux dépend de la coupe transversale mesurée.

7.8 H7 : l'entropie décrit, elle ne prévoit pas

La question, en une phrase. Si je connais aujourd'hui l'entropie du marché, est-ce que je sais quelque chose sur le risque des trois prochaines semaines que la volatilité d'aujourd'hui ne me disait pas déjà ?

Le protocole, en quatre pas. On compare deux modèles qui prévoient la même chose — la volatilité réalisée des 21 jours à venir, puis le drawdown, puis la pire perte quotidienne. Le *modèle de référence* n'utilise que le canal d'échelle. Le *modèle enrichi* y ajoute un canal d'entropie. Puis :

1. on estime les deux modèles sur le passé seulement, jamais sur l'avenir qu'on cherche à prévoir ;
2. on prévoit, et on note l'erreur commise ;
3. on réestime chaque année en ajoutant l'année écoulée, et on recommence ;
4. on ne compare les erreurs que sur des dates espacées de 21 jours, pour que deux prévisions successives ne portent pas sur les mêmes journées.

Ce que « confirmé » voudrait dire ici. Uniquement ceci : que le modèle enrichi commette, *sur des dates qu'il n'avait pas vues au moment d'être estimé*, des erreurs plus petites que le modèle de référence, et que l'écart soit trop grand pour être du hasard — ce que tranche le test de Diebold & Mariano (1995). Le point mérite d'être appuyé, car c'est là que la plupart des indicateurs de ce genre se trompent eux-mêmes : **ajouter n'importe quelle variable améliore mécaniquement l'ajustement sur les données ayant servi à estimer le modèle**. Un bon ajustement dans l'échantillon ne prouve rien du tout.

Le verdict. H7 est rejetée. Aucun canal — ni $\mathcal{J}$, ni le déficit $\mathcal{D}$, ni le terme de dépendance, ni l'indicateur de crise, ni la part non résorbée — n'améliore significativement la prévision hors échantillon. La meilleure amélioration observée, tous canaux et toutes cibles confondus, est de 3,9% d'erreur quadratique moyenne avec $p = 0,52$: indiscernable du hasard. Plusieurs spécifications sont significativement *moins bonnes* que la référence.

Et l'illustration exacte du piège décrit plus haut : *dans* l'échantillon, les coefficients sont hautement significatifs, $p < 10^{-4}$ pour $\mathcal{J}$ dans toutes les spécifications. C'est le motif qu'on attend de fenêtres chevauchantes, et c'est pourquoi ces chiffres ne sont pas présentés comme des preuves.

Ce qu'il faut en conclure. Que les canaux d'entropie sont *diagnostiques* et non *prédictifs* : ils décrivent bien l'état informationnel présent du marché, ils n'anticipent pas son prochain mouvement sous une spécification linéaire. Ce résultat réplique, sur un autre jeu de données et un protocole nettement plus exigeant, le résultat prédictif négatif obtenu par la version antérieure de ce projet. La valeur du cadre est donc à chercher là où la section 8 la cherche — dans la cohérence interne et la calibration des scénarios — et non dans des prévisions ponctuelles.

7.9 Tout ceci n'est-il que de la volatilité ?

Corrélation avec la log-volatilité glissante	S&P 500	EuStock
H^{vol} (canal d'échelle)	+0,56	+0,45
$-H^{dep}$ (canal de dépendance)	+0,56	+0,66
$\mathcal{D}$ (canal de forme)	+0,09	-0,06
$\mathcal{J}$ (indice structurel)	+0,46	+0,60
co-dépassement de queue	+0,32	+0,49

TABLE 6 – Ce que chaque canal partage avec la volatilité.




FIGURE 4 – Chaque canal en fonction de la log-volatilité glissante. Les canaux d'échelle et de dépendance la suivent ; le canal de forme, non.

Le tableau 6 et la figure 4 répondent à l'objection évidente. L'indice structurel partage environ un cinquième de sa variance avec la volatilité sur titres individuels ($r = 0,46$) : il lui est donc lié mais loin d'être redondant. Le canal de forme est *orthogonal* à la volatilité ($r = 0,09$ et $-0,06$) : l'épaisseur de queue de la distribution conditionnelle est une dimension de l'état du marché qu'une mesure de volatilité ne voit pas du tout. Puisque le canal de forme porte 60% de la variance de $\Delta\mathcal{J}$ sur le panel principal, l'essentiel de ce qui fait bouger l'indice est une information que la volatilité ne contient pas.

7.10 Réplication

La figure 5 applique la chaîne identique aux quatre indices européens, 1991–1998. Le panel est bien trop petit pour porter seul un résultat — quatre actifs donnent six corrélations par paires contre 190 pour le panel principal, et un seul cycle de stress — mais chaque signe rapporté plus haut se reproduit : $\mathcal{J}$ monte sous stress (1,23 contre 0,89, $p < 0,001$), les canaux se couplent sous stress et non en marché calme (0,54 contre 0,05), l'indice relaxe avec une demi-vie de 139 jours, et les sauts positifs portent une variation moyenne d'asymétrie de marché de $-0,129$ contre $+0,003$ ailleurs.




FIGURE 5 – Réplication : l'indice structurel sur le DAX, le SMI, le CAC et le FTSE, 1991–1998. Les hausses visibles coïncident avec les épisodes du SME de septembre 1992 et 1993 et avec la crise asiatique d'octobre–novembre 1997.

8 Tests de résistance par l'entropie

8.1 La construction

Définition 2 (Scénario en boule d'entropie). Étant donné la distribution conditionnelle d'aujourd'hui p_0 et une sévérité $\eta > 0$, le scénario de sévérité η pour une fonctionnelle de risque ρ est

$$p_\eta^* = \arg \max_{p: D_{KL}(p \| p_0) \leq \eta} \rho(p). \quad (13)$$

Pour un portefeuille linéaire et une référence gaussienne, seule la projection unidimensionnelle importe. Avec m_0, s_0 la moyenne et l'écart type du portefeuille et $u = (m - m_0)/s_0$, $v = s/s_0$, la contrainte est $g(u, v) = \frac{1}{2}(u^2 + v^2 - 1 - 2 \log v) \leq \eta$, et pour tout ρ de la forme $-m + cs$ — la VaR gaussienne et l'expected shortfall en sont toutes deux — la solution vérifie $u = -t$, $v - v^{-1} = ct$, où t est fixé par $g = \eta$. Le cas particulier $c = 0$ est le contrôle de cohérence à retenir :

un scénario purement directionnel de η nats est exactement un mouvement de $\sqrt{2\eta}$ sigmas. (14)

Un nat achète 1,41 sigma. C'est le taux de change entre information et risque, et c'est toute la raison pour laquelle la construction est utilisable par un comité : le paramètre de sévérité n'est pas une abstraction.

8.2 Calibrer le rayon

Le rayon n'est pas ici un choix de modélisation. Définissons le flux d'information à h pas

$$I_t^{(h)} = D_{KL}(p_t \| p_{t-h}), \quad (15)$$

la divergence entre la distribution conditionnelle du marché aujourd'hui et celle d'il y a h jours — de combien le marché a révisé sa propre vue. C'est une divergence en bonne et due forme entre deux

lois conditionnelles de rendements, mesurée dans la même unité que le rayon du scénario, ce qui rend la calibration cohérente. Les quantiles de $I^{(21)}$, amincis en blocs non chevauchants, convertissent une période de retour en rayon.

Période de retour	1 an	2 ans	5 ans	10 ans	20 ans	50 ans [†]
rayon η (nats)	1,04	1,63	2,34	3,88	7,54	13,16
choc directionnel (σ)	-0,58	-0,72	-0,84	-1,06	-1,45	-1,88
multiplicateur de volatilité	2,04	2,33	2,63	3,15	4,10	5,20
volatilité annualisée du portef.	41%	47%	53%	63%	82%	105%
ES ₉₉ à un jour	7,6%	8,8%	9,9%	12,0%	15,6%	19,9%

TABLE 7 – Échelle de sévérité pour un portefeuille équipondéré des vingt titres, calibrée sur 383 observations non chevauchantes de flux d’information à 21 jours. La référence d’aujourd’hui est une volatilité annualisée de 20% et une ES₉₉ à un jour de 3,4%. [†] au-delà de l’échantillon : l’échelon cinquantennal exige un quantile que 33 ans d’historique ne peuvent pas résoudre et constitue une extrapolation de la queue empirique.

Deux traits du tableau 7 méritent une lecture attentive. Le scénario dépense son budget surtout en *variance* plutôt qu’en direction — à l’échelon annuel, un doublement de la volatilité et seulement un choc de dérive de $0,58\sigma$ — parce que l’expected shortfall est plus sensible à l’échelle qu’à la position. Et le rayon n’est pas comparable d’un univers à l’autre : une divergence KL croît avec la dimension du vecteur de rendements, de sorte que l’échelle du panel à quatre indices va de 0,09 à 0,21 nat là où celle des vingt titres va de 1,04 à 13,2. Une échelle doit être calibrée pour le portefeuille auquel elle s’appliquera.




FIGURE 6 – À gauche : ES₉₉ à un jour sous stress en fonction du rayon du scénario, périodes de retour indiquées. À droite : ce qu’achète un nat, réparti entre le multiplicateur de volatilité et le choc directionnel.

8.3 Ce que cela apporte face aux tests de résistance en volatilité, moyenne et asymétrie

La comparaison n’est pas rhétorique, car la même métrique tarife un scénario classique. Prenons la distribution conditionnelle d’aujourd’hui et construisons le bundle des manuels : volatilités

marginales multipliées, toutes les corrélations par paires forcées à un même nombre élevé, un choc directionnel de plusieurs sigmas. Son prix informationnel est $D_{KL}(p_{\text{classique}} \parallel p_0)$, calculable en forme fermée.

Bundle classique	modéré	standard	sévère
multiplicateur de volatilité	1,5	2,0	3,0
toutes corrélations forcées à choc directionnel	0,70 -2σ	0,90 -3σ	0,95 -4σ
ES ₉₉ à un jour impliquée	9,1%	13,7%	20,3%
prix informationnel (nats)	6,80	9,97	20,19
dont : composante directionnelle	2,00	4,50	8,00
composante volatilité	4,39	16,14	58,03
composante corrélation	2,43	8,10	13,50
période de retour impliquée	~ 11 ans	> 30 ans	hors échantillon
scénario entropique à même ES₉₉	1,85	5,47	13,74
sa période de retour	2,3 ans	10,6 ans	~ 32 ans
surcoût informationnel	73%	45%	32%

TABLE 8 – Tarification des bundles de stress des manuels face au flux d’information propre au marché, et comparaison de chacun avec le scénario entropique délivrant la même expected shortfall. Échelons de référence du tableau 7 : le scénario vicennal vaut 7,54 nats, le cinquantennal 13,16 ; la pire journée unique en 33 ans se tarife à 9,03.

Le tableau 8 est le point appliqué de l’article, et il dit quelque chose de plus tranchant que « les scénarios classiques sont trop sévères ». Le bundle standard coûte 9,97 nats, ce qui le situe entre les échelons vicennal et cinquantennal — une sévérité défendable pour un test de résistance réglementaire, et que personne autour de la table n’avait le moyen de savoir avoir choisie. Ce qui n’est pas défendable, c’est l’efficience. Un scénario entropique délivre la même expected shortfall de 13,7% pour 5,47 nats. Le comité croit avoir spécifié quelque chose de l’ordre d’un événement trentennal ; mesuré par la perte qu’il produit réellement, il a spécifié un événement décennal et payé une invraisemblance trentennale. Le bundle modéré est pire : il se tarife comme un événement de onze ans et délivre une perte *biennale*, un surcoût de 73%.

Où passe l’argent ? La composante directionnelle est bon marché et exactement tarifée : déplacer la moyenne du portefeuille de k écarts types coûte $k^2/2$ nats, soit 4,5 pour trois sigmas. La composante chère est le doublement uniforme de chaque volatilité marginale, à 16,1 nats à elle seule — davantage que le bundle entier. Forcer toutes les corrélations à 0,9 coûte 8,1 nats à elle seule.

Les composantes ne sont pas additives, et la façon dont elles ne le sont pas est instructive : les trois somment à 28,7 nats alors que le bundle en coûte 9,97. Forcer les corrélations à la hausse effondre la covariance sur un sous-espace de rang quasi un auquel la distribution de référence accorde déjà une variance généreuse — le mode de marché — de sorte que mettre à l’échelle cette structure effondrée est bien moins coûteux que mettre à l’échelle la structure de rang plein ($\text{tr}(\Sigma_0^{-1}\Sigma_1)$ tombe de 20 à 10,5 quand les corrélations sont forcées, avant même que le multiplicateur de volatilité ne soit appliqué). Le choc de volatilité et le choc de corrélation se paient partiellement l’un l’autre.

C’est exactement la structure qu’a identifiée H6 dans les données. Les vraies crises n’égalisent pas les corrélations et ne gonflent pas toutes les volatilités indépendamment ; elles chargent la coupe transversale sur un ou deux modes collectifs et épaississent conjointement les queues des marginales. Un cadre qui choque volatilité, corrélation et forme comme trois scalaires séparés n’a aucun moyen de représenter cela, ni aucun moyen de s’apercevoir que son bundle achète la sévérité avec une marge

de 30 à 70%.

Quatre avantages concrets sur l'approche volatilité/moyenne/asymétrie en découlent.

1. **Une échelle de sévérité unique, dans une unité qui ne dépend pas de l'actif.** Les scénarios deviennent comparables entre desks, portefeuilles et classes d'actifs, et la sévérité se cite avec une période de retour plutôt qu'avec un adjectif.
2. **Cohérence interne par construction.** Les chocs de position et d'échelle proviennent d'un même budget et d'une même optimisation. Un bundle qui choque volatilité, corrélation et asymétrie indépendamment peut décrire, et décrit souvent, une distribution que le marché ne saurait produire.
3. **Les scénarios existants peuvent être audités plutôt que remplacés.** Tout gabarit réglementaire ou jugement de comité reçoit un prix en nats et une période de retour, de sorte que la question de savoir si un test de résistance est calibré devient arithmétique. C'est le bénéfice pratique du tableau 8.
4. **Le test de résistance inversé est offert.** Au lieu de demander ce que fait un scénario, on demande quel est le scénario le moins cher produisant une perte donnée. Sur le panel principal, la perte quotidienne empirique à 99% (3,2%) coûte 1,5 nat ; celle à 99,9% (7,7%) coûte 4,8 ; la pire journée en 33 ans (11,5%) coûte 9,0. Lire ces chiffres au regard du tableau 7 convertit en fréquence une perte qui préoccupe le conseil.

Une mise en garde sur le quatrième point. Les tests de résistance inversés calculés de façon non paramétrique, en inclinant l'échantillon empirique, dégénèrent à mesure que le rayon croît : à 9,0 nats, la mesure inclinée a une taille d'échantillon effective de 1,0, c'est-à-dire qu'elle est la pire journée unique déguisée en distribution. L'implémentation rapporte la taille d'échantillon effective précisément pour cette raison, et la construction en boule gaussienne devrait être employée dès qu'elle tombe sous quelques dizaines.

8.4 Deux indicateurs de suivi

La séparation saut/diffusion livre deux quantités productibles quotidiennement à coût négligeable. L'indicateur de *crise* est la composante de saut positif standardisée de $\mathcal{J}$: quelle quantité d'information est arrivée aujourd'hui, en unités de l'échelle diffusive locale, nulle lorsqu'aucun saut n'est détecté. L'indicateur de *part non résorbée* est $\mathcal{J}_t$ rapporté à son maximum glissant : quelle part de ce qui est déjà arrivé ne s'est pas encore relâchée. Sous P1, il devrait décroître avec une demi-vie $\ln 2/\kappa$; un marché où il reste proche de un sensiblement plus longtemps est un marché où le choc n'a pas été absorbé. Ni l'un ni l'autre n'améliore une prévision de volatilité (H7) ; tous deux décrivent un état que la volatilité ne décrit pas.

8.5 Pertinence pour la solvabilité en assurance

Trois points relient ceci au volet assurance du projet d'ensemble. D'abord, un scénario en boule d'entropie est un objet naturel pour l'ORSA : il produit une distribution stressée complète, non un vecteur de chocs, de sorte qu'il alimente directement un calcul de capital et porte un énoncé de plausibilité défendable. Ensuite, la décomposition en composantes du tableau 8 concerne la formule standard de Solvabilité II, dont le crédit de diversification est bâti sur une matrice de corrélation fixe : choquer volatilités et corrélations comme des scalaires séparés, ce qui est l'ajustement conservateur usuel, achète une perte de queue donnée avec une marge de 30 à 70% en termes de plausibilité, parce que cela ne représente pas la façon dont les crises observées redistribuent la dépendance — sur quelques modes collectifs plutôt qu'uniformément. Enfin, les propriétés de cohérence des mesures

de risque entropiques (Ahmadi-Javid, 2012; Artzner et al., 1999) rendent le cadre $\mathcal{J}$ compatible en principe avec des exigences de capital en modèle interne, bien que rien ici n'ait été testé sur des portefeuilles de passifs et que les panels courts et à basse fréquence typiques des données d'assurance mettraient à mal chacun des estimateurs employés plus haut.

9 Limites

Le pont est un argument, pas une preuve. La section 2.5 liste les défaillances de l'impact linéaire et de l'échangeabilité des signes. Rien d'empirique ci-dessous ne dépend de l'horloge de volume, mais le cadrage, si.

Le déficit est estimé marginalement. Le canal de forme capture la non-gaussianité marginale et la dépendance de copule gaussienne ; la dépendance de queue non linéaire est mesurée séparément plutôt qu'intégrée, de sorte que $\mathcal{J}$ sous-estime la divergence véritable, d'un montant lui-même maximal sous stress.

Le témoin mécanique avale une hypothèse entière. L'asymétrie des sauts est intégralement reproduite par des données i.i.d. de même loi marginale, et environ les deux tiers de la relaxation mesurée relèvent de la mémoire de l'estimateur. Les résultats de persistance et d'amplitude survivent ; le résultat d'asymétrie, non, et aucun lecteur ne devrait citer le chiffre de 158 contre 9 sans le témoin à côté. Vingt réplifications, c'est aussi peu : les quantiles du témoin au tableau 2 sont eux-mêmes estimés avec une erreur visible, et une centaine de réplifications affinerait les p -valeurs qui se situent actuellement à 0,05.

Les arrivées poissonniennes sont le mauvais modèle. La figure 3 montre un regroupement que (11) n'accommode pas. Un processus d'arrivée auto-excitant de Hawkes est la spécification suivante évidente.

Vingt titres, c'est une petite coupe transversale. Le canal de dépendance est sensible à N , l'équilibre entre canaux se déplace avec lui, et le rayon KL n'est pas comparable d'un univers à l'autre. Les résultats devraient être reproduits sur une large coupe transversale — le fichier sectoriel de Kenneth French, ou CRSP — avant qu'aucun chiffre présenté ici ne soit traité comme une constante de la nature.

L'échelle de sévérité extrapole en queue. Avec 383 observations non chevauchantes de flux d'information, les échelons au-delà d'une vingtaine d'années sont des interpolations de la queue empirique, non des mesures. Ajuster une queue de Pareto généralisée à $I^{(h)}$ serait la correction disciplinée.

Rien ici ne prévoit. H7 est rejetée sur deux jeux de données sous un protocole exigeant. Tout usage de ces mesures devrait être diagnostique.

10 Conclusion

La contribution théorique est une chaîne explicite sur ce qui, en chaque maillon, relève du théorème et ce qui relève de l'hypothèse. Le maximum d'entropie sous contraintes de moments

d'ordre un et deux donne une gaussienne ; appliqué en temps-volume, le volume échangé fournissant le budget de variance, il donne des rendements gaussiens conditionnels au volume, et la cohérence temporelle en fait un mouvement brownien subordonné puis un prix brownien géométrique. Lu à l'envers, des prix non gaussiens mesurent la distance à l'ignorance maximale, et cette distance se décompose en un canal de dépendance et un canal de forme dont la somme, l'indice structurel $\mathcal{J}$, est sans échelle et positive. Conditionner ne peut pas augmenter l'entropie espérée, donc l'entropie chute par sauts dont la taille *espérée* est l'information mutuelle de la nouvelle ; que cette entropie se rétablisse par diffusion, et que la chute soit unilatérale dans la direction des pertes, sont les deux postulats que l'article ajoute et teste.

Le tableau empirique est surtout un avertissement, et nous pensons que c'est là le résultat utile. Chaque affirmation descriptive du cadre est visible dans les données : le stress élève l'indice structurel, l'indice est en dents de scie, les sauts sont unilatéraux, ils portent une asymétrie négative, et les canaux de dépendance et de queue se couplent sous stress. Passé par un témoin qui conserve la loi marginale et brouille la chronologie, l'essentiel disparaît — et plusieurs statistiques ressortent *plus grandes* dans les données mélangées que dans les données réelles. Une fonctionnelle convexe positive de moments estimés d'ordre deux, trois et quatre monte brutalement et redescend en douceur dès qu'une observation à queue épaisse entre dans l'estimateur, et elle le fait que l'information arrive ou non par paquets. Cette mise en garde vaut pour tout indicateur de crise fondé sur l'entropie, et pas seulement pour celui-ci, et nous ne l'avons pas trouvée énoncée dans la littérature appliquée.

Exactement deux statistiques franchissent les deux témoins, et ce sont les deux qu'il faut retenir. Ce qui sépare une crise d'une série de gros rendements, c'est que la coupe transversale se couple : le signal de régime du canal de dépendance vaut entre trois et six fois celui des témoins, tandis que celui du canal de forme est inférieur aux deux. Et l'indice structurel voyage plus loin sur l'échantillon que dans tout rééchantillonnage des mêmes rendements. Le taux de relaxation lui-même n'est pas identifié — il se situe entre les deux témoins — de sorte que P1 est soutenu par l'amplitude et non par une demi-vie. Deux autres résultats vont à l'encontre de l'intérêt de l'article : la compensation volatilité-dépendance obtenue sur portefeuilles sectoriels ne survit pas au passage aux titres individuels, et aucun canal d'entropie ne prévoit quoi que ce soit hors échantillon.

La contribution appliquée est ce que le cadre apporte une fois qu'on cesse de lui demander de prévoir. Mesurer la sévérité d'un scénario en nats donne au test de résistance une unité ; calibrer cette unité sur le flux d'information réalisé du marché lui donne une fréquence ; et résoudre pour la pire distribution dans la boule qui en résulte donne un scénario qui ne peut pas être incohérent en interne. Appliqué à l'envers, il tarife les scénarios que les institutions font déjà tourner : sur cet échantillon, un bundle standard des manuels se situe entre les échelons vicennal et cinquantiennal mais achète sa perte de queue avec une marge de 45%, parce qu'il dépense l'essentiel de son budget à gonfler uniformément chaque volatilité marginale — ce qui n'est pas la voie que prennent les crises observées.

A Unités, invariance, et ce qui est calculable

Le nat. L'entropie $H = -\sum_i p_i \log p_i$ n'est définie qu'une fois la base du logarithme choisie, et ce choix *est* le choix de l'unité. Avec $\log_2$ on obtient des bits (shannons), avec $\log_{10}$ des dits, et avec le logarithme népérien des *nats*. Un nat est l'information apportée par une observation qui divise l'espace des possibles par $e \approx 2,718$, là où un bit le divise par deux. La conversion est $1 \text{ nat} = 1/\log 2 \approx 1,4427 \text{ bit}$. Tout ce papier emploie le logarithme népérien : entropies, déficits, divergences, rayons de scénario et indice structurel sont en nats.

Trois lectures opérationnelles, de la plus utile à la plus abstraite. D'abord le taux de change

établi en section 8 : un scénario purement directionnel de η nats est un mouvement de $\sqrt{2\eta}$ sigmas, donc k sigmas coûtent $k^2/2$ nats. Ensuite le codage : $D_{KL}(p \parallel q)$ nats est l'excès de longueur de code attendu lorsqu'on encode des données de loi p avec un code optimal pour q . Enfin le test d'hypothèse : une divergence de un nat par observation signifie que le rapport de vraisemblance en faveur de p croît en moyenne d'un facteur e à chaque observation.

h dépend des unités, les divergences non. L'entropie différentielle d'une variable continue vérifie, pour toute transformation affine inversible,

$$h(aX + b) = h(X) + \log |a|, \quad \text{et en dimension } N, \quad h(AX + b) = h(X) + \log |\det A|. \quad (16)$$

Exprimer les rendements en pourcentages plutôt qu'en décimales ajoute donc $N \log 100$ à h : le *niveau* de h , et par conséquent celui de H^{vol} et de H^{cov} , n'a aucune valeur absolue interprétable. En revanche $D_{KL}(p \parallel q)$, $I(X; Y)$, $\mathcal{D}$ et $\mathcal{J}$ sont invariants par tout changement de variable inversible, les jacobiens se simplifiant entre numérateur et dénominateur du logarithme. *Un chiffre en nats n'est comparable d'un jeu de données à l'autre que si c'est une divergence.* C'est la raison structurelle pour laquelle l'article construit un indice sans échelle.

Comment calcule-t-on $h(X)$? Dans le cas gaussien, en forme fermée (annexe B). Dans le cas général, on ne le peut pas sans connaître p . Des estimateurs non paramétriques existent — espacements de Vasicek (1976), plus proches voisins de Kozachenko–Leonenko, méthodes à noyau — mais tous se dégradent rapidement au-delà de trois ou quatre dimensions. Estimer une entropie différentielle en dimension 20 sur une fenêtre de 252 jours est hors de portée.

L'article ne calcule donc *jamaïs* $h(p)$. Il calcule $h(q)$ en forme fermée à partir de $\hat{\Sigma}$, et le déficit $\mathcal{D}$ par une approximation de la *différence* d'entropies marginales. Une différence d'entropies est sans dimension et estimable ; une entropie différentielle nue ne l'est pas. Toute l'architecture — décomposer plutôt qu'estimer directement — découle de cette contrainte.

B Entropie gaussienne : démonstration de l'équation (5)

Étape A : entropie d'une gaussienne multivariée. Pour $q = \mathcal{N}(\mu, \Sigma)$ sur $\mathbb{R}^N$,

$$\log q(x) = -\frac{1}{2} [N \log 2\pi + \log \det \Sigma + (x - \mu)' \Sigma^{-1} (x - \mu)],$$

donc

$$h(q) = -\mathbb{E}_q[\log q] = \frac{1}{2} N \log 2\pi + \frac{1}{2} \log \det \Sigma + \frac{1}{2} \mathbb{E}[(X - \mu)' \Sigma^{-1} (X - \mu)].$$

La dernière espérance se calcule par l'astuce de la trace : un scalaire égale sa trace, et la trace est cyclique, d'où

$$\mathbb{E}[(X - \mu)' \Sigma^{-1} (X - \mu)] = \mathbb{E}[\text{tr}(\Sigma^{-1} (X - \mu)(X - \mu)')] = \text{tr}(\Sigma^{-1} \Sigma) = \text{tr}(I_N) = N.$$

En regroupant, $h(q) = \frac{1}{2} [N \log 2\pi + \log \det \Sigma + N] = \frac{1}{2} \log((2\pi e)^N \det \Sigma)$. □

Étape B : factorisation du déterminant. Avec $\Sigma = DRD$, $D = \text{diag}(\sigma_1, \dots, \sigma_N)$ et R la matrice de corrélation, la multiplicativité du déterminant donne $\det \Sigma = \det(D) \det(R) \det(D) = (\prod_i \sigma_i)^2 \det R$. □

Étape C : substitution. $\frac{1}{2} \log \det \Sigma = \frac{1}{2} \log[(\prod_i \sigma_i)^2 \det R] = \sum_i \log \sigma_i + \frac{1}{2} \log \det R$, d'où $h(q) = \frac{N}{2} \log(2\pi e) + \sum_i \log \sigma_i + \frac{1}{2} \log \det R$, qui est l'équation (5). □

Signe du canal de dépendance. L'inégalité de Hadamard donne $\det R \leq \prod_i R_{ii} = 1$ pour une matrice semi-définie positive. Une démonstration plus parlante passe par le spectre : $\det R = \prod_k \lambda_k$ avec $\sum_k \lambda_k = \text{tr } R = N$, et l'inégalité arithmético-géométrique donne $\prod_k \lambda_k \leq (\sum_k \lambda_k / N)^N = 1$, avec égalité si et seulement si toutes les valeurs propres valent 1, c'est-à-dire $R = I$. Donc $H^{dep} \leq 0$: la corrélation détruit toujours de l'entropie.

Dans le cas bivarié, $\det R = 1 - \rho^2$ et $H^{dep} = \frac{1}{2} \log(1 - \rho^2)$; pour $\rho = 0,9$ cela vaut $-0,83$ nat. Remarquons que $-H^{dep}$ est alors exactement l'information mutuelle entre les deux actifs : la corrélation est de l'information partagée, donc de l'entropie détruite.

Note de lecture sur les tableaux. Les colonnes H^{cov} des tableaux 3 et suivants rapportent $H^{vol} + H^{dep}$ et omettent la constante $\frac{N}{2} \log(2\pi e)$, qui vaut 28,38 nats pour $N = 20$. Ce décalage constant est sans conséquence puisque seules les différences entre régimes et les variations temporelles sont interprétées, mais il explique que les niveaux rapportés soient négatifs.

C Le déficit d'entropie : pourquoi $\mathcal{D} = h(q) - h(p)$

La divergence de Kullback–Leibler entre une loi p et une loi de référence q est $D_{KL}(p \| q) = \int p \log(p/q)$, positive et nulle si et seulement si $p = q$ presque partout. Elle n'est ni symétrique ni munie d'une inégalité triangulaire : ce n'est pas une distance, d'où le terme de divergence. Les lettres « KL » sont les initiales de Kullback et Leibler.

Proposition 4. Si $q = \mathcal{N}(\mu, \Sigma)$ a les deux premiers moments de p , alors $D_{KL}(p \| q) = h(q) - h(p)$.

Démonstration. $D_{KL}(p \| q) = -h(p) - \mathbb{E}_p[\log q(X)]$. Or $\log q$ est exactement quadratique en x , donc son espérance ne dépend que de la moyenne et de la covariance de la loi sous laquelle on l'évalue. Comme p et q partagent ces deux moments, $\mathbb{E}_p[(X - \mu)' \Sigma^{-1} (X - \mu)] = \text{tr}(\Sigma^{-1} \Sigma) = N = \mathbb{E}_q[\cdot]$, d'où $\mathbb{E}_p[\log q] = \mathbb{E}_q[\log q] = -h(q)$ et donc $D_{KL}(p \| q) = h(q) - h(p)$. $\square$

L'hypothèse de coïncidence des moments est essentielle : sans elle l'identité tombe. C'est tout le contenu de la proposition 1, lue comme une mesure plutôt que comme un théorème d'existence. Économiquement, $\mathcal{D}$ est le prix en nats du mensonge « le marché est gaussien » : l'incertitude apparente que la description gaussienne surestime, parce que la loi véritable est plus concentrée que ne le laisse croire sa seule covariance.

D L'indice structurel est une divergence

Proposition 5. Avec $q_i = \mathcal{N}(\mu_i, \sigma_i^2)$ les marginales gaussiennes de mêmes échelles que p ,

$$D_{KL}(p \| \prod_i q_i) = \mathcal{D} - H^{dep} = \mathcal{J}.$$

Démonstration. Par définition,

$$D_{KL}(p \| \prod_i q_i) = -h(p) - \mathbb{E}_p[\sum_i \log q_i(X_i)] = -h(p) + \sum_i \left[\frac{1}{2} \log(2\pi\sigma_i^2) + \frac{1}{2} \right] = -h(p) + \sum_i \log \sigma_i + \frac{N}{2} \log(2\pi e),$$

où l'on a utilisé $\mathbb{E}_p[(X_i - \mu_i)^2] = \sigma_i^2$, vrai par construction. En y injectant l'équation (6), soit $h(p) = \frac{N}{2} \log(2\pi e) + \sum_i \log \sigma_i + H^{dep} - \mathcal{D}$, les termes d'échelle et la constante se télescopent et il reste $\mathcal{D} - H^{dep}$. $\square$

C'est une identité exacte, non une approximation, et c'est elle qui justifie la définition 1. Retirer le canal d'échelle de (6) pourrait passer pour un bricolage ; l'objet qui reste se trouve être une divergence de Kullback–Leibler en bonne et due forme, et hérite donc gratuitement de trois propriétés : elle est positive ; elle est nulle si et seulement si les rendements sont indépendants *et* gaussiens, ce qui fournit un point de référence bien défini plutôt qu'arbitraire ; et elle est invariante par changement d'unités actif par actif, puisque p et $\prod_i q_i$ se transforment de la même façon.

Il est utile de rapprocher cette identité de la règle de chaînage générale $D_{KL}(p \parallel \prod_i q_i) = \sum_i D_{KL}(p_i \parallel q_i) + I(x)$, où $I(x) = D_{KL}(p \parallel \prod_i p_i)$ est la multi-information. Le premier terme est la somme des déficits marginaux $\sum_i \mathcal{D}_1(x_i)$, le second la dépendance totale. L'estimateur employé dans l'article estime le premier terme par l'approximation de Hyvärinen (1998) et remplace le second par sa part linéaire $-H^{dep}$; la dépendance de queue non linéaire est donc omise de $\mathcal{J}$ et mesurée séparément par un taux de co-dépassement.

E Information mutuelle : les deux propositions et un exemple

Démonstration de la proposition 2. Par définition de l'entropie conditionnelle, $\mathbb{E}_Y[h(X | Y)] = h(X, Y) - h(Y)$, et par (9), $I(X; Y) = h(X) + h(Y) - h(X, Y)$. En sommant les deux, $\mathbb{E}_Y[h(X | Y)] = h(X) - I(X; Y)$. La positivité de I découle de celle de la divergence de Kullback–Leibler dont elle est un cas particulier, avec égalité si et seulement si $p_{XY} = p_X \otimes p_Y$.

Démonstration de la proposition 3. Immédiate : une contrainte supplémentaire ne peut que réduire l'ensemble réalisable, et le supremum d'une fonctionnelle sur un ensemble plus petit ne peut pas augmenter.

Pourquoi les deux ne sont pas équivalents. La première quantifie mais ne vaut qu'en moyenne ; la seconde vaut réalisation par réalisation mais porte sur le plafond et ne quantifie rien. Un contre-exemple discret suffit à montrer qu'une réalisation particulière peut *augmenter* l'entropie. Soit X binaire avec $\mathbb{P}(X = a) = 0,99$, d'entropie $H(X) = 0,056$ nat. Soit un signal Y qui, avec probabilité 0,98, lève complètement le doute ($H(X | Y = 0) = 0$), et avec probabilité 0,02 conduit à $\mathbb{P}(X = a | Y = 1) = 1/2$, soit $H(X | Y = 1) = \log 2 = 0,693$ nat — douze fois l'entropie a priori. La moyenne vaut néanmoins $0,98 \times 0 + 0,02 \times 0,693 = 0,014$ nat, bien en dessous de 0,056, et $I(X; Y) = 0,042$ nat. C'est exactement la raison pour laquelle l'article prédit une composante de saut *principalement*, et non exclusivement, unilatérale.

Exemple gaussien chiffré. Soit $X \sim \mathcal{N}(0, \sigma^2)$ le rendement de demain et $Y = X + \varepsilon$ un signal bruité, $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$ indépendant. Alors

$$I(X; Y) = \frac{1}{2} \log \left(1 + \frac{\sigma^2}{\sigma_\varepsilon^2} \right), \quad \text{Var}(X | Y) = \frac{\sigma^2 \sigma_\varepsilon^2}{\sigma^2 + \sigma_\varepsilon^2}, \quad (17)$$

la variance a posteriori ne dépendant pas de la réalisation y . Avec $\sigma = 1\%$ par jour :

Qualité du signal	σ_ε	$I(X; Y)$ (nats)	vol. a posteriori	équivalent $\sqrt{2\eta}$
tranchant	0,5%	0,805	0,45%	1,27 σ
moyen	1,0%	0,347	0,71%	0,83 σ
vague	3,0%	0,053	0,95%	0,32 σ

Un facteur quinze sépare la taille du saut d'entropie provoqué par une nouvelle qui tranche de celui provoqué par une rumeur. La dernière colonne traduit chaque saut dans l'échelle de sévérité de la section 8 : c'est le mouvement directionnel qu'un scénario de même rayon produirait.

Références

- Ahmadi-Javid, A. (2012). Entropic Value-at-Risk : A New Coherent Risk Measure. *Journal of Optimization Theory and Applications*, 155(3), 1105–1123.
- Almog, A., & Shmueli, E. (2019). Structural Entropy : Monitoring Correlation-Based Networks Over Time With Application To Financial Markets. *Scientific Reports*, 9, 10832.
- Ané, T., & Geman, H. (2000). Order Flow, Transaction Clock, and Normality of Asset Returns. *Journal of Finance*, 55(5), 2259–2284.
- Artzner, P., Delbaen, F., Eber, J.-M., & Heath, D. (1999). Coherent Measures of Risk. *Mathematical Finance*, 9(3), 203–228.
- Barndorff-Nielsen, O. E., & Shephard, N. (2001). Non-Gaussian Ornstein–Uhlenbeck-based Models and Some of Their Uses in Financial Economics. *Journal of the Royal Statistical Society B*, 63(2), 167–241.
- Barndorff-Nielsen, O. E., & Shephard, N. (2004). Power and Bipower Variation with Stochastic Volatility and Jumps. *Journal of Financial Econometrics*, 2(1), 1–37.
- Black, F. (1976). Studies of Stock Price Volatility Changes. *Proceedings of the Business and Economic Statistics Section, American Statistical Association*, 177–181.
- Christie, A. A. (1982). The Stochastic Behavior of Common Stock Variances : Value, Leverage and Interest Rate Effects. *Journal of Financial Economics*, 10(4), 407–432.
- Doob, J. L. (1942). The Brownian Movement and Stochastic Equations. *Annals of Mathematics*, 43(2), 351–369.
- Engle, R. F., & Ng, V. K. (1993). Measuring and Testing the Impact of News on Volatility. *Journal of Finance*, 48(5), 1749–1778.
- Nelson, D. B. (1991). Conditional Heteroskedasticity in Asset Returns : A New Approach. *Econometrica*, 59(2), 347–370.
- Bollerslev, T., & Ghysels, E. (1996). Periodic Autoregressive Conditional Heteroscedasticity. *Journal of Business & Economic Statistics*, 14(2), 139–151.
- Breuer, T., & Csiszár, I. (2013). Systematic Stress Tests with Entropic Plausibility Constraints. *Journal of Banking & Finance*, 37(5), 1552–1559.
- Caraiani, P. (2018). Modeling the Comovement of Entropy between Financial Markets. *Entropy*, 20(6), 417.
- Clark, P. K. (1973). A Subordinated Stochastic Process Model with Finite Variance for Speculative Prices. *Econometrica*, 41(1), 135–155.
- Cover, T. M., & Thomas, J. A. (2006). *Elements of Information Theory*, 2^e éd. Wiley.
- Csiszár, I. (1975). *I*-Divergence Geometry of Probability Distributions and Minimization Problems. *Annals of Probability*, 3(1), 146–158.
- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.

- Engle, R. (2002). Dynamic Conditional Correlation. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- Glasserman, P., & Xu, X. (2014). Robust Risk Measurement and Model Risk. *Quantitative Finance*, 14(1), 29–58.
- Hyvärinen, A. (1998). New Approximations of Differential Entropy for Independent Component Analysis and Projection Pursuit. *Advances in Neural Information Processing Systems*, 10, 273–279. (Constantes telles que dans Hyvärinen & Oja, 2000, *Neural Networks* 13, 411–430.)
- Jaynes, E. T. (1957). Information Theory and Statistical Mechanics. *Physical Review*, 106, 620–630.
- Kyle, A. S. (1985). Continuous Auctions and Insider Trading. *Econometrica*, 53(6), 1315–1335.
- Ledoit, O., & Wolf, M. (2004). A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- Mandelbrot, B., & Taylor, H. M. (1967). On the Distribution of Stock Price Differences. *Operations Research*, 15(6), 1057–1062.
- Monroe, I. (1978). Processes That Can Be Embedded in Brownian Motion. *Annals of Probability*, 6(1), 42–56.
- Papla, D., & Siedlecki, R. (2024). Entropy as a Tool for the Analysis of Stock Market Efficiency During Periods of Crisis. *Entropy*, 26(12), 1079.
- Politis, D. N., & Romano, J. P. (1994). The Stationary Bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- Tauchen, G. E., & Pitts, M. (1983). The Price Variability–Volume Relationship on Speculative Markets. *Econometrica*, 51(2), 485–505.
- Vasicek, O. (1976). A Test for Normality Based on Sample Entropy. *Journal of the Royal Statistical Society B*, 38(1), 54–59.
- Zhou, R., Cai, R., & Tong, G. (2013). Applications of Entropy in Finance : A Review. *Entropy*, 15(11), 4909–4931.

Note sur les versions. **Cette version française est la version de référence.** Elle intègre des corrections d'exposition que la version anglaise `paper/main.tex` ne porte pas encore : séparation de la proposition sur le conditionnement en deux énoncés distincts (l'entropie conditionnelle moyenne baisse d'exactly $I(X; Y)$; le plafond de maximum d'entropie baisse au sens large sans quantification), levée des collisions de notation ($\mathcal{D}_1$ contre $\mathcal{J}$, $\sigma_{\mathcal{J}}$ contre η , $\mathcal{P}$ contre N), ajout d'un tableau de notations et des annexes A à E. Les résultats numériques sont inchangés et proviennent du même code (`python -m src.run_empirical`). En cas de divergence entre les deux versions, c'est celle-ci qui fait foi jusqu'à ce que l'anglaise soit resynchronisée.